
PROBABILIDAD I

Segundo del Grado en Matemáticas

Hugo Marquerie

Profesor: Pablo Fernández Gallardo

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre 2023 - 2024

1 de Febrero, 2024

1 Tema 1: Sucesos y probabilidades

1.1 Formalizando

Definición 1.1 (Espacio muestral). En un experimento aleatorio, el espacio muestral es el conjunto (no vacío) de sus posibles resultados y se denota por Ω . Puede ser:

1. Finito: $\Omega = \{\omega_1, \dots, \omega_N\}$
2. Infinito numerable: $\Omega = \{\omega_1, \omega_2, \dots\}$
3. Infinito no numerable, ej.: $\Omega = [0, 1) \vee \Omega = \mathcal{P}([0, 1))$

Definición 1.2 (Espacio de sucesos por Kolmogórov). Dado el espacio muestral Ω de un experimento aleatorio, $\mathcal{F} \subset \mathcal{P}(\Omega)$ es su espacio de sucesos

$$\iff (\mathcal{F} \neq \emptyset) \wedge (A \in \mathcal{F} \implies A^C \in \mathcal{F}) \wedge \left(A_1, A_2, \dots \in \mathcal{F} \implies \bigcup_{j=1}^{\infty} A_j \in \mathcal{F} \right)$$

Observación 1.1. De la definición se deduce:

$$\bullet \phi \in \mathcal{F} \wedge \Omega \in \mathcal{F} \quad \bullet A_1, \dots, A_n \in \mathcal{F} \implies \bigcup_{j=1}^n A_j \in \mathcal{F} \quad \bullet \forall A, B \in \mathcal{F} \implies A \cap B \in \mathcal{F}$$

Definición 1.3 (Función o medida de probabilidad). Dado espacio muestral (Ω) y de sucesos (\mathcal{F}) de un experimento aleatorio, la aplicación $P: \mathcal{F} \longrightarrow [0, 1]$: es una medida de probabilidad

$$\iff (P(\Omega) = 1) \wedge \left[P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} P(A_j) \iff A_i \cap A_j = \emptyset \text{ cuando } i \neq j \right]$$

Proposición 1.1. De la definición se deduce:

1. $P\left(\bigcup_{j=1}^n A_j\right) = \sum_{j=1}^n P(A_j)$
2. $P(A^C) = 1 - P(A)$
3. $P(\emptyset) = 0$
4. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
5. $A \subseteq B \implies P(A) \leq P(B)$

Ejemplo 1.1. En un experimento aleatorio con espacio muestral finito, tomamos

$\Omega = \{\omega_1, \dots, \omega_N\} \wedge \mathcal{F} = \mathcal{P} \rightarrow 2^N$. Asignamos $P(\{\omega_j\}) = p_j \wedge j = 1, \dots, N$ tales que $p_j \geq 0 \wedge \sum_{j=1}^N p_j = 1$. Entonces, $\forall A \in \mathcal{F} : P(A) = \sum_{\omega \in A} P(\omega)$

Caso particular: $\forall j \in \mathbb{N}_N : p_j = \frac{1}{N} \implies \forall A \in \mathcal{F} : P(A) = \frac{|A|}{N} = \frac{\text{“Casos favorables”}}{\text{“Total de casos”}}$

Ejemplos varios:

1. (Muy tonto) $\Omega \neq \phi$, tomas $A \subset \Omega : A \neq \phi, \Omega$.

Dato $p \in (0, 1)$. $\mathcal{F} = \{\phi, A, A^c, \Omega\}$ con $P(A) = p$.

2. (Bastante general) $(\Omega = \{\omega_1, \dots, \omega_N\} \implies |\Omega| = N) \wedge (\mathcal{F} = P(\Omega) \rightarrow |\mathcal{F}| = 2^N)$.

Dato: $p_1, \dots, p_N \geq 0 \implies \sum_{j=1}^N p_j = 1$. Asignamos $\forall j \in \mathbb{N}_N : p_j := P(\{\omega_j\})$.

Definimos $\forall A \subset \Omega : P(A) = \sum_{\omega \in A} P(\omega)$.

3. Lanzas n veces una moneda. Dato: $p \in (0, 1)$.

$$\implies \Omega = \{111 \dots 1, \dots, 000 \dots 0\} \wedge |\Omega| = 2^N \wedge \text{escogemos } \mathcal{F} = P(\Omega)$$

$$\implies \forall \omega \in \Omega : P(\omega) = p^{\#\text{unos de } \omega} (1-p)^{\#\text{ceros de } \omega}$$

Comprobamos:

$$\begin{aligned} \sum_{\omega \in \Omega} P(\omega) &= \sum_{k=0}^n \left(\sum_{\substack{\omega \in \Omega \\ \#\text{0s de } \omega = k}} P(\omega) \right) = \sum_{k=0}^n p^k (1-p)^{n-k} (|\{\omega \in \Omega : \#\text{1s de } \omega = k\}|) \\ &= \sum_{k=0}^n p^k (1-p)^{n-k} \binom{n}{k} = (p + 1 - p)^n = 1 \end{aligned}$$

4. Lanzamos moneda hasta que sale una cara. Dato $p \in (0, 1)$.

$$\implies \Omega = \{C, XC, XXC, \dots\} \wedge \text{escogemos } \mathcal{F} = P(\Omega)$$

$$P(C) =: p \implies P(XC) = p(1-p) \wedge P(XXC) = p(1-p)^2 \wedge \dots$$

$$\text{Comprobamos: } \sum_{j=1}^{\infty} p(1-p)^{j-1} = p \sum_{k=0}^{\infty} (1-p)^k = p \frac{1}{1-(1-p)} = 1$$

1.2 Probabilidad condicionada y total, independencia y Bayes

Tienes (Ω, \mathcal{F}, P) y un suceso $A \in \mathcal{F} \rightarrow P(A)$. Llega “nueva información”: ha ocurrido el suceso $B \in \mathcal{F} \rightarrow$ ¿Debo reasignar la probabilidad de A ?

Ejemplo 1.2 (Dependencia). Lanzas 10 veces una moneda (regular).

$$A = \{\text{salen 6 caras}\} \implies P(A) = \frac{\binom{10}{6}}{2^{10}} \approx 20.51\%$$

$$B = \{\text{sale C en } 1^0\} \implies P(A) \text{ sube a } \frac{\binom{9}{5}}{2^9}$$

Definición 1.4. Sea (Ω, \mathcal{F}, P) un espacio de probabilidad y los sucesos $A, B \in \mathcal{F} : P(B) > 0$, $P(A|B)$ es la probabilidad de A condicionada a B

$$\iff P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Observación 1.2. En general, $P(A|B) \neq P(B|A)$

Proposición 1.2 (Cálculo de $P(A|B)$ para cada $A \in \mathcal{F}$). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad y $B \in \mathcal{F}$ un suceso con $P(B) > 0$

$\implies (\Omega, \mathcal{F}, Q_B)$, con $Q_B: \mathcal{F} \longrightarrow [0, 1] : Q_B(A) = P(A|B)$, es un espacio de probabilidad

Demostración. Basta ver que Q_B es una función de probabilidad.

$$\left(Q_B(A) = P(A|B) = \frac{P(A \cap B)}{P(B)} \in [0, 1] \right) \wedge \left(Q_B(\Omega) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1 \right)$$

Sean $A_1, A_2, \dots \in \mathcal{F}$ disjuntos dos a dos.

$$\begin{aligned} \implies Q_B \left(\bigcup_{j=1}^{\infty} A_j \right) &= P \left(\bigcup_{j=1}^{\infty} A_j \mid B \right) = \frac{P \left(\bigcup_{j=1}^{\infty} A_j \cap B \right)}{P(B)} \\ &= \frac{1}{P(B)} P \left(\bigcup_{j=1}^{\infty} (A_j \cap B) \right) = \frac{1}{P(B)} \sum_{j=1}^{\infty} P(A_j \cap B) = \sum_{j=1}^{\infty} Q_B(A_j) \end{aligned}$$

■

Definición 1.5 (Independencia). Sean $A, B \in \mathcal{F}$ dos sucesos con $P(A), P(B) \geq 0$ son independientes

$$\iff P(A|B) = P(A) \wedge P(B|A) = P(B) \text{ (para entender)}$$

$$\iff P(A \cap B) = P(A) \cdot P(B) \text{ (la adecuada)}$$

• A, B disjuntos \implies no independientes.

• $A_1, \dots, A_N \in \mathcal{F}$ independientes $\iff \forall J \subset \mathbb{N}_N : P \left(\bigcap_{j \in J} A_j \right) = \prod_{j \in J} P(A_j)$

$$\iff P \left(\overline{A_1} \cap \dots \cap \overline{A_N} \right) = \prod_{i=1}^N P \left(\overline{A_i} \right) \text{ donde } \overline{A_i} = A_i, (A_i)^c$$

Ejercicio 1.2.1. Encontrar un espacio de probabilidad en el que haya un conjunto de sucesos independientes dos a dos pero no completamente independientes.

$$\text{SOL: } \Omega = \{1, 2, 3, 4\} \wedge A = \{1, 2\} \wedge B = \{2, 3\} \wedge C = \{1, 3\}$$

Proposición 1.3 (Regla de Bayes). Sean (Ω, \mathcal{F}, P) un espacio de probabilidad y $A, B \in \mathcal{F}$ sucesos con $P(A), P(B) > 0$

$$\implies P(A|B) = P(B|A) \cdot \frac{P(A)}{P(B)}$$

Demostración.

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \wedge P(B|A) = \frac{P(A \cap B)}{P(A)}$$

$$\implies P(A|B) \cdot P(B) = P(A \cap B) = P(B|A) \cdot P(A) \implies P(A|B) = P(B|A) \cdot \frac{P(A)}{P(B)}$$

■

1.2.1 Probabilidad total

Proposición 1.4. Sean (Ω, \mathcal{F}, P) un espacio de probabilidad y $\{B_1, B_2, \dots\}$ una partición de Ω : $(\forall i, j : i \neq j : B_i \cap B_j = \emptyset) \wedge \left(\bigcup_{j=1}^{\infty} B_j = \Omega \right)$

$$\implies \forall A \in \mathcal{F} : P(A) = P\left(\bigcup_{j=1}^{\infty} (A \cap B_j)\right) = \sum_{j=1}^{\infty} P(A \cap B_j) = \sum_{j=1}^{\infty} P(A|B_j) \cdot P(B_j)$$

$$\implies \forall A \in \mathcal{F} : \boxed{P(A) = \sum_{j=1}^{\infty} P(A|B_j) \cdot P(B_j)}$$

■

Ejemplo 1.3. Sean $U_1 = \{10b, 3n\} \wedge U_2 = \{5b, 5n\} \wedge U_3 = \{2b, 6n\}$ tres urnas con bolas blancas (b) y negras (n). Procedimiento:

$$1. \text{ Sorteamos una urna } P(U_1) = \frac{1}{4} \wedge P(U_2) = \frac{1}{4} \wedge P(U_3) = \frac{1}{2}$$

2. Sacamos bola de la urna seleccionada.

¿Cuál es la probabilidad de que sea blanca?

$$P(b) = P(b|U_1)P(U_1) + P(b|U_2)P(U_2) + P(b|U_3)P(U_3)$$

Ejemplo 1.4 (Peso de la evidencia). Sean $U_1 = \{80\% b, 20\% n\} \wedge U_2 = \{20\% b, 80\% n\}$ dos urnas con bolas blancas (b) y negras (n). Procedimiento:

1. Sorteamos la urna con $1/2$ y $1/2$ de probabilidad.

2. Sacamos 10 bolas (con reemplazamiento).

Observamos la evidencia: $bb \dots nb$ ¿qué urna se usó?

$$P(U_1|5b5n) = P(5b5n|U_1) \frac{P(U_1)}{P(5b5n)} = \frac{P(5b5n|U_1)P(U_1)}{P(5b5n|U_1)P(U_1) + P(5b5n|U_2)P(U_2)}$$

$$\implies P(5b5n|U_1) = \binom{10}{5} 0.8^5 0.2^5 = P(5b5n|U_2) \implies P(U_1|5b5n) = \frac{1}{2}$$

Este es el resultado que esperábamos, prestemos atención a otro caso más contraintuitivo.


$$P(U_1|6b4n) = \frac{P(6b4n|U_1)P(U_1)}{P(6b4n|U_1)P(U_1) + P(6b4n|U_2)P(U_2)}$$

$$= \frac{\binom{10}{6} 0.8^6 0.2^4 \cdot 1/2}{\binom{10}{6} 0.8^6 0.2^4 \cdot 1/2 + \binom{10}{6} 0.8^4 0.2^6 \cdot 1/2} \approx 90\%$$

Si dibujamos la gráfica de la función

$$f(x) = P(U_1|xb(10-x)n)$$

podemos ver que el cambio es muy brusco. Es decir, una pequeña diferencia en la evidencia puede cambiar mucho la probabilidad de que se haya usado una urna u otra.




Ejemplo 1.5 (Falsos positivos/negativos). Hay una enfermedad ($E \vee S$) y hay una prueba para detectar ($+ \vee -$). Datos: $P(+|E) = 95\% \wedge P(-|S) = 99\%$.

Te haces la prueba y sale +:

$$P(E|+) = P(+|E) \frac{P(E)}{P(+)} = \frac{P(+|E)P(E)}{P(+|E)P(E) + P(+|S)P(S)}$$

Conozco todas estas probabilidades excepto $p := P(E) \implies P(S) = 1 - p$.



Si definimos $f(p) := P(E|+)$

$$\implies \{f(0.5) = 98.95\% \wedge f(1/100) = 48.97\% \wedge f(1/1000) = 8.68\%\}$$

Es decir, si la incidencia es muy baja, no tiene sentido hacer pruebas masivamente porque la mayoría de positivos serán falsos.

Ejemplo 1.6 (Sobre independencia). $(\Omega, \mathcal{F}, P) \wedge A_1, \dots, A_n$ sucesos independientes tal

que $\forall j \in \mathbb{N}_n : P(A_j) = \frac{1}{n}$. ¿Qué sabemos sobre $P\left(\bigcup_{j=1}^n A_j\right)$?

$$\text{En general, sabemos que } \frac{1}{n} \leq P\left(\bigcup_{j=1}^n A_j\right) \leq \sum_{j=1}^n P(A_j) \leq 1$$

$$n = 2: P(A \cup B) = P(A) + P(B) - P(A \cap B) = 3/4$$

$$n = 3: P(A \cup B \cup C) = \binom{3}{1} \frac{1}{3} - \binom{3}{2} \frac{1}{3^2} + \binom{3}{3} \frac{1}{3^3} = 19/27$$

$$\begin{aligned}
n \text{ general: } P\left(\bigcup_{j=1}^n A_j\right) &= \sum_{j=1}^n P(A_j) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j) + \cdots \text{ (Inclusión exclusión)} \\
\Rightarrow P\left(\bigcup_{j=1}^n A_j\right) &= \binom{n}{1} \frac{1}{n} - \binom{n}{2} \frac{1}{n^2} + \binom{n}{3} \frac{1}{n^3} + \cdots = \sum_{j=1}^n \binom{n}{j} \frac{1}{n^j} (-1)^{j+1} \\
\Rightarrow P\left(\bigcup_{j=1}^n A_j\right) &= 1 - \sum_{j=0}^n \binom{n}{j} \left(\frac{-1}{n}\right)^j = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - \frac{1}{e}
\end{aligned}$$

1.2.2 Continuidad de la probabilidad: detalle técnico

Proposición 1.5. Sean (Ω, \mathcal{F}, P) un espacio de probabilidades y $A_1, \dots : A_1 \subset A_2 \subset \dots$ una sucesión creciente de conjuntos

$$\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) = \lim_{n \rightarrow \infty} P(A_n)$$

Demostración. Se trata de describir $\bigcup_{j=1}^n A_j$ como la unión de conjuntos disjuntos.

$$\begin{aligned}
P\left(\bigcup_{j=1}^n A_j\right) &= P\left(A_1 \cup \bigcup_{j=1}^{n-1} (A_{j+1} \setminus A_j)\right) = P(A_1) + \sum_{j=1}^{n-1} (P(A_{j+1}) - P(A_j)) = P(A_n) \\
\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) &= P(A_1) + \sum_{j=1}^{\infty} (P(A_{j+1}) - P(A_j)) = \lim_{n \rightarrow \infty} P(A_n)
\end{aligned}$$

■

Proposición 1.6. Si la sucesión A_1, \dots es decreciente $\Rightarrow P\left(\bigcap_{j=1}^{\infty} A_j\right) = \lim_{n \rightarrow \infty} P(A_n)$

Teorema 1.1 (Continuidad de la probabilidad). En el espacio de probabilidades (Ω, \mathcal{F}, P) , sea A_1, A_2, \dots una sucesión : $\forall j \in \mathbb{N} : A_j \in \mathcal{F}$

$$\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{j=1}^n A_j\right)$$

Demostración. Definimos $B_i := \bigcup_{j=1}^i A_j \Rightarrow \bigcup_{j=1}^{\infty} A_j = \bigcup_{i=1}^{\infty} B_i$ (B_i) es creciente.

$$\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) = P\left(\bigcup_{i=1}^{\infty} B_i\right) = \lim_{n \rightarrow \infty} P(B_n) = P\left(\bigcup_{j=1}^n A_j\right)$$

■

2 Tema 2: Variables aleatorias discretas

Definición 2.1. Sea (Ω, \mathcal{F}, P) un espacio de probabilidades, $X: \Omega \rightarrow \mathbb{R}$ es una variable aleatoria discreta* (v.a.d.)

$$\iff (1) X(\Omega) \text{ es numerable}^* \wedge (2) \forall x \in \mathbb{R} : \{\omega \in \Omega : X(\omega) = x\} \in \mathcal{F}$$

En realidad, solo interesa (2) cuando $x = x_j$

Definición 2.2. Sea X una v.a.d. en (Ω, \mathcal{F}, P) , $p_X: \mathbb{R} \rightarrow [0, 1]$ es su función de masa

$$\iff x \mapsto p_X(x) = P(X = x) := P(\{\omega \in \Omega : X(\omega) = x\})$$

Vemos que

$$\sum_{j \geq 1} p_X(x_j) = \sum_{j \geq 1} P(X = x_j) = \sum_{j \geq 1} P(\{\omega \in \Omega : X(\omega) = x_j\}) = P\left(\bigcup_{\omega \in \Omega} \{\omega\}\right) = P(\Omega) = 1$$

Lo relevante es el conjunto de posibles valores de X ($\{x_1, x_2, \dots\}$) numerable y el conjunto (también numerable) de probabilidades $\{p_1, p_2, \dots\}$ donde

$$\left(\forall j \geq 1 : p_j = P(x = x_j) \wedge p_j \geq 0\right) \wedge \sum_{j \geq 1} p_j = 1$$

Teorema 2.1. Sea $S = \{x_1, x_2, \dots\}$ un conjunto y $(\Pi_1, \Pi_2, \dots, \Pi_j)$ una lista tal que $\forall i \leq j : \Pi_i \geq 0 \wedge \sum_{j \geq 1} \Pi_j = 1$

$$\implies \exists (\Omega, \mathcal{F}, P) \wedge X \text{ v.a.d.} : (\forall x \notin S : p_X(x) = 0) \wedge p_X(x_i) = \Pi_i$$

Demostración. Fijamos $\Omega = S$ y $\mathcal{F} = \mathcal{P}(S)$.

$$A \in \mathcal{F} \implies P(A) = \sum_{j: x_j \in A} \Pi_j \wedge X(x_j) = x_j$$

■

Ejemplo 2.1 (Diferentes modelos de distribución de probabilidad).

1. X sigue una distribución **uniforme** en $\{1, \dots, N\}$, $N \geq 2$ ($X \sim \text{UNIF}(N)$).

$$\iff S = \{1, \dots, N\} \wedge \Pi_j = 1/N, \dots, 1/N$$

Se usa para modelizar un lanzamiento de un dado regular de N caras.

2. X sigue una distribución de **Bernoulli** con parámetro p ($X \sim \text{BER}(p)$)

$$\iff \begin{cases} p_X(x) = 0 \iff x \neq 0, 1 \\ p_X(1) = p \wedge p_X(0) = 1 - p \end{cases} \iff \begin{cases} P(X = 1) = p \\ P(X = 0) = 1 - p \end{cases}$$

donde 1 es éxito y 0 fracaso. Se usa para modelizar el resultado de un experimento con dos posibles resultados, i.e. una moneda no necesariamente regular.

3. X sigue una distribución **binomial** de parámetros $n \geq 1 \wedge p \in (0, 1)$ ($X \sim \text{BIN}(n, p)$)

$$\iff S = \{0, 1, \dots, n\} \wedge \forall j \in \{0, 1, \dots, n\} : P(x = j) = \binom{n}{j} p^j (1-p)^{n-j}$$

Sirve para modelizar el número de caras que salen al lanzar n veces una moneda de probabilidad p .

$$\begin{aligned} n! \sim n^n e^{-n} \sqrt{2\pi n} &\implies \binom{n}{n/2} \sim \frac{n^n e^{-n} \sqrt{2\pi n}}{(n/2)^{(n/2)} e^{-(n/2)} \sqrt{2\pi(n/2)} (n/2)^{(n/2)} e^{-(n/2)} \sqrt{2\pi(n/2)}} \\ &\implies \frac{n^n \sqrt{n}}{(n/2)^{(n/2)} \sqrt{2\pi(n/2)} (n/2)^{(n/2)} \sqrt{(n/2)}} = \frac{n^n \sqrt{n}}{(n/2)^n \sqrt{2\pi(n/2)}} = \frac{n^n \sqrt{2}}{(n/2)^n \sqrt{\pi n}} = 2^n \sqrt{\frac{2}{\pi n}} \end{aligned}$$

4. La variable X sigue una distribución **geométrica** de parámetro $p \in (0, 1)$ ($X \sim \text{GEOM}(p)$).

$$\iff S = \{1, 2, \dots\} \wedge \forall j \geq 1 : P(x = j) = p(1-p)^{j-1}$$

Sirve para modelizar el número de lanzamientos hasta que sale un resultado C en cuestión con $P(X = C) = p$.

Observación 2.1. Cuidado porque existen variables aleatorias que también se dicen de distribución geométrica en las que $S = \{0, 1, 2, \dots\}$. Se habla de cuantas veces has obtenido el resultado complementario a C antes de que halla salido C .

5. La variable X sigue una distribución de **Poisson** con parámetro $\lambda > 0$ ($X \sim \text{POISSON}(\lambda)$)

$$\iff S = \{0, 1, \dots\} \wedge \forall j \geq 0 : P(x = j) = e^{-\lambda} \frac{\lambda^j}{j!}$$

Se usa para modelizar la frecuencia de eventos determinados durante un intervalo de tiempo fijado a partir de la frecuencia media de aparición de dichos eventos.

Proposición 2.1. Sea $X \sim \text{BIN}(n, p)$ una v.a.d.

$$\implies \text{cuando } n \text{ es grande, } \text{BIN}(n, p) \sim \text{POISSON}(np)$$

Demostración. Fijo $\lambda > 0 \wedge p = \frac{\lambda}{n}$.

$$\lim_{n \rightarrow \infty} \binom{n}{k} \frac{\lambda^k}{n^k} \left(1 - \frac{\lambda}{n}\right)^{n-k} = \frac{\lambda^k}{k!} \lim_{n \rightarrow \infty} \frac{n!}{(n-k)!} \frac{1}{n^k} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} = e^{-k} \frac{\lambda^k}{k!}$$

■

Ejemplo 2.2 (¿Hay más ejemplos?).

- Binomial negativa
- Hipergeométrica

- Dada cualquier serie convergente $\sum_{n=1}^{\infty} a_n = s$, se puede definir la variable aleatoria X tal que $S = \{1, 2, \dots\} \wedge P(x = k) = \frac{a_k}{s}$

2.1 Funciones transformadoras de variables aleatorias (discretas)

Sea X una v.a.d. y $g: \mathbb{R} \rightarrow \mathbb{R}$ una función, definimos $Y := g(X)$.

$$\implies \{\omega \in \Omega : Y(\omega) = g(X(\omega)) = y\} \in \mathcal{F} \implies Y \text{ es una v.a.d}$$

Por otro lado,

$$\forall y \in \mathbb{R} : P(Y = y) = P(g(X) = y) = P(X \in g^{-1}(y)) = \sum_{x \in g^{-1}(y)} P(X = x) = \sum_{x \in g^{-1}(y)} p_X(x)$$

Ejemplo 2.3 ($Y = x^2$).

$$p_Y(y) = P(Y = y) = P(X^2 = y) = \begin{cases} 0, & y < 0 \\ P(X = 0) = p_X(0), & y = 0 \\ P(X = \pm\sqrt{y}) = p_X(\sqrt{y}) + p_X(-\sqrt{y}), & y > 0 \end{cases}$$

2.2 Resúmenes: esperanza, varianza, momentos

Definición 2.3 (Esperanza). Sea X una v.a.d. en el espacio de probabilidad (Ω, \mathcal{F}, P) y con función de masa p_X , $E(X)$ es la esperanza de X (también llamada media o *expectatio*)

$$\iff E(X) = \sum_{x \in X(\Omega)} x \cdot P(X = x) = \sum_{j \geq 1} x_j \cdot p_X(x_j)$$

Pero ojo, solo si la serie es absolutamente convergente.

$$\begin{cases} \text{Si } x_1, \dots, x_N \text{ finito, la suma obviamente converge.} \\ \text{Si los } x_j \text{ son positivos, la serie converge si y solo si es acotada. Si no lo es diverge a } \infty. \end{cases}$$

Ejemplo 2.4 (Cálculo de la esperanza).

- $x_1, \dots, x_N \wedge p_1, \dots, p_N \implies E(X) = \sum_{j=1}^N x_j \cdot p_j$
- $X \sim \text{BER}(p) \implies E(X) = 1 \cdot p + 0 \cdot (1 - p) \implies \boxed{E(X) = p}$
- $X \sim \text{UNIF}(1, \dots, N) \implies E(X) = \frac{1}{N} \sum_{n=1}^N n \implies \boxed{E(X) = \frac{N+1}{2}}$
- $X \sim \text{BIN}(n, p) \implies E(X) = \sum_{j=0}^n j \binom{n}{j} p^j (1-p)^{n-j} \implies \boxed{E(X) = np}$

Se obtiene derivando el binomio de Newton $(1+x)^n = \sum_{j=0}^n \binom{n}{j} x^j$

$$\implies \frac{d}{dx}(1+x)^n = \sum_{j=0}^n \binom{n}{j} j \cdot x^{j-1} \implies xn(1+x)^{n-1} = \sum_{j=0}^n \binom{n}{j} j x^j$$

$$\begin{aligned} \text{Si } x = \frac{p}{1-p} &\implies \frac{p}{1-p} n \left(1 + \frac{p}{1-p}\right)^{n-1} = \sum_{j=0}^n \binom{n}{j} j \left(\frac{p}{1-p}\right)^j \\ &\implies \frac{p}{1-p} n \left(\frac{1}{1-p}\right)^{n-1} = \sum_{j=0}^n \binom{n}{j} j \left(\frac{p}{1-p}\right)^j \\ &\implies np = (1-p)^n \sum_{j=0}^n \binom{n}{j} j \left(\frac{p}{1-p}\right)^j = \sum_{j=0}^n j \binom{n}{j} p^j (1-p)^{n-j} = E(X) \end{aligned}$$

■

$$\bullet X \sim \text{GEOM}(p) \implies E(X) = \sum_{k=1}^{\infty} k \cdot p \cdot (1-p)^{k-1} \implies \boxed{E(X) = \frac{1}{p}}$$

$$\forall x : |x| < 1 : \frac{1}{1-x} = \sum_{n=0}^{\infty} x^n \implies \frac{1}{(1-x)^2} = \sum_{n=1}^{\infty} n x^{n-1} \implies E(X) = p \frac{1}{p^2} = \frac{1}{p}$$

■

$$\begin{aligned} \bullet X \sim \text{POISSON}(\lambda) &\implies E(X) = \sum_{j=0}^{\infty} j \frac{\lambda^j}{j!} e^{-\lambda} \implies \boxed{E(X) = \lambda} \\ &\implies E(X) = e^{-\lambda} \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda \end{aligned}$$

■

Ejemplo 2.5. Sea X una v.a.d. con $\forall k \geq 0 : P(X = k) = \frac{6}{\pi^2} \frac{1}{k^2}$

$$\implies E(X) = \sum_{k=1}^{\infty} k \frac{6}{\pi^2} \frac{1}{k^2} = \frac{6}{\pi^2} \sum_{k=1}^{\infty} \frac{1}{k} \text{ que diverge a } \infty$$

Ejemplo 2.6. Sea X una v.a.d. que toma valores en $\{(-1)^{k+1}k : k \geq 1\} = \{1, -2, 3, -4, \dots\}$

$$P(X = (-1)^{k+1}k) = \frac{6}{\pi^2} \frac{1}{k^2} \implies E(X) = \sum_{k=1}^{\infty} \frac{(-1)^{k+1}}{k} \text{ que sabemos que tiende a } \ln 2$$

Sin embargo, la serie no converge absolutamente, por tanto, mediante argumentos de reordenación, se puede argumentar que $E(X)$ toma cualquier valor real. Entonces $E(X)$ no tiene sentido.

Teorema 2.2. Sea X una v.a.d. que toma los valores x_j con probabilidades p_j para $j \geq 1$.

Sea $g: \mathbb{R} \rightarrow \mathbb{R}$ una función.

$$\implies E(g(X)) = \sum_{j \geq 1} g(x_j) p_j$$

Demostación. Sabemos que $g(X)$ es una v.a.d. que toma valores en $\{g(x_j) : j \geq 1\}$, donde $|\{g(x_j)\}| \leq |\{x_j\}|$ porque g puede no ser inyectiva.

$$\text{Como } P(g(X) = y) = \sum_{x \in g^{-1}(y)} P(X = x)$$

$$\implies E(g(X)) = \sum_{y \in g(X(\Omega))} y \cdot P(g(X) = y) = \sum_{y \in g(X(\Omega))} y \left(\sum_{x \in g^{-1}(y)} P(X = x) \right)$$

Como $\forall y \in g(X(\Omega)) : \exists |g^{-1}(y)|$ cantidad de $i_s \geq 1 : g(x_i) = y$ se tiene

$$E(g(X)) = \sum_{j \geq 1} g(x_j) p_j$$

■

Observación 2.2.

1. Si X es tal que $P(X = a) = 1 \implies E(X) = a$
2. $X \sim \text{UNIF}(\{-1, 0, 1\}) \wedge Y = X^2 \implies E(X) = 0 \wedge E(Y) = 2/3$
3. $E(aX + b) = aE(X) + b$ porque

$$\sum_{j \geq 1} (ax_j + b)p_j = a \sum_{j \geq 1} x_j p_j + b \sum_{j \geq 1} p_j = aE(X) + b$$

4. En general $E(g(X)) \neq g(E(X))$ (Motivo de excomuni3n)

Ejemplo 2.7 ($X \sim \text{POISSON}(\lambda) \implies E(X) = \lambda$). Si $Y = g(X) = e^X$

$$\implies E(Y) = E(e^Y) = \sum_{j=0}^{\infty} e^j \frac{\lambda^j}{j!} e^{-\lambda} = e^{-\lambda} \sum_{j=0}^{\infty} \frac{(e\lambda)^j}{j!} = e^{-\lambda} e^{e\lambda} = e^{\lambda(e-1)} \neq e^\lambda$$

Definici3n 2.4 (Varianza). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad y X una v.a.d. con funci3n de masa p_X , $V(X)$ es la varianza de X

$$\iff V(X) = E[(X - E(X))^2]$$

Si X toma valores x_1, x_2, \dots con probabilidades p_1, p_2, \dots y denominamos $\mu := E(X)$

$$\begin{aligned} \implies V(X) &= \sum_{j \geq 1} (x_j - \mu)^2 \cdot p_j = \sum_{j \geq 1} (x_j^2 - 2x_j\mu + \mu^2) \cdot p_j \\ &= \sum_{j \geq 1} x_j^2 p_j - 2 \sum_{j \geq 1} x_j \mu p_j + \sum_{j \geq 1} \mu^2 p_j = E(X^2) - 2\mu^2 + \mu^2 \end{aligned}$$

$$\implies \boxed{V(X) = E[(X - E(X))^2] = E(X^2) - E(X)^2}$$

Observación 2.3.

1. $V(X)$ es medida de dispersión de X alrededor de $E(X)$.

2. $V(X) \geq 0$

3. $V(X) = 0 \implies P(X = E(X)) = 1$

4. $\boxed{V(aX + b)} = E[(aX + b - E(aX + b))^2] = E[(aX - aE(X))^2] = \boxed{a^2 V(X)}$

5. Las unidades de $V(X)$ son las de X^2

\implies definimos la desviación típica de X como $\boxed{\sigma(X) := \sqrt{V(X)}}$

6. ¿Por qué no $E(|X - E(X)|)$?

Porque el valor absoluto no es diferenciable y no se puede trabajar con él.

Ejemplo 2.8.

1. $X \sim \text{BER}(p) \implies E(X) = p \wedge \boxed{V(X) = p - p^2 = p(1 - p)}$

2. $X \sim \text{UNIF}(\{1, \dots, N\}) \implies E(X) = \frac{N+1}{2} \wedge \boxed{V(X) = \frac{N^2 - 1}{12}}$
 $\implies V(X) = \frac{1}{N} \sum_{j=1}^N j^2 = \frac{1}{N} \cdot \frac{N(N+1)(2N+1)}{6} = \frac{(N+1)(N-1)}{12}$

3. $X \sim \text{BIN}(n, p) \implies E(X) = np \wedge \boxed{V(X) = np(1 - p)}$

Demostración. ■

4. $X \sim \text{GEOM}(p) \implies E(X) = \frac{1}{p} \wedge \boxed{V(X) = \frac{1-p}{p^2}}$

Demostración. ■

5. $X \sim \text{POISSON}(\lambda) \implies E(X) = \lambda \wedge \boxed{V(X) = \lambda}$

Demostración.

$$E(X^2) = \sum_{k=0}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!}$$

■

Definición 2.5 (Momentos de X). Sea X una v.a.d. con función de masa p_X , μ_k es el k -ésimo momento de $X \iff \mu_k = E[(X - E(X))^k]$

Observación 2.4. Algunos momentos tienen nombre propio:

1. $\mu_1 = 0$ 2. $\mu_2 = V(X)$ 3. μ_3 es la **asimetría** de X 4. μ_4 es la **curtosis** de X

Teorema 2.3 (Desigualdad de Markov). Sea X una v.a.d. : $P(X < 0) = 0 \wedge E(X) < \infty$
 $\implies \forall t > 0 : P(X \geq t) \leq \frac{E(X)}{t}$

Demostración. Notación: En (Ω, \mathcal{F}, P) , $A \subset \mathcal{F}$ y $\mathbb{1}_A(\omega) = \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \notin A \end{cases}$

Fijamos $t > 0$ y definimos $Y_t(\omega) = t \cdot \mathbb{1}_{\{x \geq t\}}(\omega) = \begin{cases} t & \text{con probabilidad } P(x \geq t) \\ 0 & \text{con probabilidad } 1 - P(x \geq t) \end{cases}$
 $\implies \forall \omega : Y_t(\omega) \leq X(\omega) \implies E(Y_t) = t \cdot P(X \geq t) \leq E(X)$

Así que $\forall t > 0 : P(X \geq t) \leq \frac{E(X)}{t}$ ■

Teorema 2.4 (Desigualdad de Chebyshev). Sea X una v.a.d. : $E(X), V(X) < \infty$.
 $\implies \forall \lambda > 0 : P(|X - E(X)| \geq \lambda \cdot \sigma(X)) \leq \frac{1}{\lambda^2}$

$$\iff \forall \alpha > 0 : \boxed{P(|X - E(X)| \geq \alpha) \leq \frac{V(X)}{\alpha^2}}$$

Demostración. Definimos $Y = |X - E(X)|^2$ y aplicamos la desigualdad de Markov.

$$\implies \forall t > 0 : P(Y \geq t) \leq \frac{E(Y)}{t} \implies \forall t > 0 : P(|X - E(X)|^2 \geq t) \leq \frac{E(Y)}{t}$$

Como $E(Y) = E(|X - E(X)|^2) = V(X)$ por la def de varianza,

$$\implies \forall t > 0 : P(|X - E(X)| \geq \sqrt{t}) \leq \frac{V(X)}{t}$$

Definimos $\alpha := \sqrt{t} \implies \forall \alpha > 0 : P(|X - E(X)| \geq \alpha) \leq \frac{V(X)}{\alpha^2}$

y para la desigualdad equivalente definimos $\lambda := \frac{\alpha}{\sigma(X)}$

$$\implies \forall \lambda > 0 : P(|X - E(X)| \geq \lambda \cdot \sigma(X)) \leq \frac{1}{\lambda^2}$$
 ■

2.2.1 Esperanza condicionada

Definición 2.6 (Esperanza condicionada). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad $B \in \mathcal{F}$ un suceso tal que $P(B) > 0$ y X una v.a.d. con esperanza $E(X)$, $E(X|B)$ es la **esperanza de X condicionada a B**

$$\iff E(X|B) := \sum_{x \in X(\Omega)} x \cdot P(X = x|B) = \sum_{x \in X(\Omega)} x \cdot \frac{P((X = x) \wedge B)}{P(B)}$$

(Siempre que la serie sea absolutamente convergente).

Teorema 2.5 (Esperanza total). En (Ω, \mathcal{F}, P) , sea X una v.a.d. y $\{B_1, B_2, \dots\}$ una partición de Ω

$$\implies E(X) = \sum_{i \geq 1} E(X|B_i) \cdot P(B_i)$$

(Siempre que la serie sea absolutamente convergente).

Demostración.

$$\begin{aligned} \sum_{i \geq 1} E(X|B_i) \cdot P(B_i) &= \sum_{i \geq 1} \sum_{x \in X(\Omega)} x \cdot P(X = x|B_i) \cdot P(B_i) \\ &= \sum_{x \in X(\Omega)} x \cdot \sum_{i \geq 1} \frac{P((X = x) \wedge B_i)}{P(B_i)} \cdot P(B_i) = \sum_{x \in X(\Omega)} x \cdot P(X = x) \end{aligned}$$

■

Ejemplo 2.9. Lanzamos una moneda con probabilidad p de cara y $1 - p$ de cruz y definimos X como la longitud de la racha inicial, i.e. el número de caras/cruces consecutivos.

$$\begin{aligned} \implies E(X) &= E(X|C) \cdot p + E(X|\times) \cdot (1 - p) \\ \implies E(X) &= \left(\sum_{j \geq 1} j \cdot P(X = j|C) \right) p + \left(\sum_{j \geq 1} j \cdot P(X = j|\times) \right) (1 - p) \\ \implies E(X) &= p \sum_{k=1}^{\infty} k p^{k-1} (1 - p) + (1 - p) \sum_{k=1}^{\infty} k (1 - p)^{k-1} p \\ \implies E(X) &= \frac{1}{1 - p} \cdot p + \frac{1}{p} \cdot (1 - p) = \frac{1}{p(1 - p)} - 2 \end{aligned}$$

También se puede abordar el problema pensando en las variables geométricas:

$$\begin{aligned} E(X) &= E(X|C) \cdot p + E(X|\times) \cdot (1 - p) = \frac{p}{1 - p} + \frac{1 - p}{p} = \frac{p^2 + (1 - p)^2}{p(1 - p)} \\ \implies E(X) &= \frac{p^2 + 1 - 2p + p^2}{p(1 - p)} = \frac{2p(p - 1) + 1}{p(1 - p)} = \frac{1}{p(1 - p)} - 2 \end{aligned}$$

2.3 Varias variables aleatorias

En (Ω, \mathcal{F}, P) , sea $\mathcal{X} = X_1, X_2, \dots, X_n$ una colección de variables aleatorias discretas.

En el caso $n = 2$, tenemos X e Y variables aleatorias discretas, se genera una tabla con las probabilidades conjuntas:

$$p_{X,Y}(x, y) := P(\omega \in \Omega : X(\omega) = x \wedge Y(\omega) = y) = P(X = x \wedge Y = y)$$

Definición 2.7 (Función de masa conjunta). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., $p_{X,Y}$ es su función de masa conjunta

$$\iff p_{X,Y} : \mathbb{R}^2 \longrightarrow [0, 1] \wedge \forall (x, y) \in X(\Omega) \times Y(\Omega) : p_{X,Y}(x, y) = P(X = x \wedge Y = y)$$

tal que $\sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) = 1$ y $\forall (x, y) \notin X(\Omega) \times Y(\Omega) : p_{X,Y}(x, y) = 0$

Ya tenemos X e Y en (Ω, \mathcal{F}, P) con $P_{X,Y}$

1. ¿Qué sabemos de X e Y por separado?
2. Esperanzas: nos interesa calcular $E(X)$, $E(Y)$, $E(X + Y)$, $E(X \cdot Y)$
3. Independencia

Definición 2.8 (Funciones marginales). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., p_X, p_Y son sus funciones de masa marginales

$$\iff p_X(x) = \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) \quad \wedge \quad p_Y(y) = \sum_{x \in X(\Omega)} p_{X,Y}(x, y)$$

Teorema 2.6. En (Ω, \mathcal{F}, P) , sean X e Y v.a.d. y sea $g : \mathbb{R}^2 \longrightarrow \mathbb{R}$ una función

$$\implies E(g(X, Y)) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x, y) \cdot p_{X,Y}(x, y)$$

Si converge absolutamente.

Demostración. Si consideramos la variable aleatoria Z que toma valores en $X(\Omega) \times Y(\Omega)$ con función de masa $p_Z = p_{X,Y}$, entonces $E(g(X, Y)) = E(g(Z))$. Como $X(\Omega) \times Y(\Omega)$ es numerable, podemos renombrar sus elementos como $\{z_1, z_2, \dots\}$ y entonces del teorema 2.2 obtenemos:

$$E(g(X, Y)) = E(g(Z)) = \sum_{j \geq 1} g(z_j) \cdot p_Z(z_j) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x, y) \cdot p_{X,Y}(x, y)$$

■

Observación 2.5. Si $g: \mathbb{R} \rightarrow \mathbb{R}$

$$\begin{aligned} \implies E(g(X)) &= \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x) \cdot p_{X,Y}(x, y) = \sum_{x \in X(\Omega)} \left(g(x) \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) \right) \\ &\implies E(g(X)) = \sum_{x \in X(\Omega)} g(x) p_X(x) \end{aligned}$$

De manera análoga, $E(g(Y)) = \sum_{y \in Y(\Omega)} g(y) p_Y(y)$

Ejemplo 2.10 ($E(aX + bY) = aE(X) + bE(Y)$).

$$\begin{aligned} E(aX + bY) &= \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} (ax + by) \cdot p_{X,Y}(x, y) \\ \implies E(aX + bY) &= a \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} x \cdot p_{X,Y}(x, y) + b \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} y \cdot p_{X,Y}(x, y) \end{aligned}$$

Definición 2.9 (Independencia de v.a.d.). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., X e Y son independientes

$$\iff \forall (x, y) \in X(\Omega) \times Y(\Omega) : X = x \text{ y } Y = y \text{ son sucesos independientes.}$$

$$\iff \forall (x, y) \in X(\Omega) \times Y(\Omega) : P(X = x \wedge Y = y) = P(X = x) \cdot P(Y = y)$$

Teorema 2.7. En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., X e Y son independientes

$$\iff \exists g, h: \mathbb{R} \rightarrow \mathbb{R} : p_{X,Y}(x, y) = g(x) \cdot h(y)$$

Demostración. (\implies) Trivial: $g(x) = p_X(x) \wedge h(y) = p_Y(y)$.

(\impliedby) Suponemos que $\exists g, h: \mathbb{R} \rightarrow \mathbb{R} : p_{X,Y}(x, y) = g(x) \cdot h(y)$, veamos las funciones marginales.

$$\implies p_X(x) = \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) = \sum_{y \in Y(\Omega)} g(x) \cdot h(y) = g(x) \sum_{y \in Y(\Omega)} h(y)$$

Análogamente $p_Y(y) = h(y) \sum_{x \in X(\Omega)} g(x)$

$$\implies p_X(x) \cdot p_Y(y) = \left(g(x) \sum_{z \in Y(\Omega)} h(z) \right) \left(h(y) \sum_{w \in X(\Omega)} g(w) \right)$$

$$\implies p_X(x) \cdot p_Y(y) = g(x) \cdot h(y) \sum_{z \in Y(\Omega)} \sum_{w \in X(\Omega)} g(w) \cdot h(z) = p_{X,Y}(x, y)$$

$$\forall (x, y) \in X(\Omega) \times Y(\Omega) : P(X = x \wedge Y = y) = p_X(x) \cdot p_Y(y) = P(X = x) \cdot P(Y = y)$$

■

Ejemplo 2.11. Sean X e Y dos v.a.d. tales que

$$p_{X,Y}(x, y) = e^{-(\lambda+\mu)} \frac{\lambda^x \mu^y}{x!y!} \text{ con } x, y \in \mathbb{Z} \text{ y } \lambda, \mu > 0$$

\implies Se puede interpretar como $X \sim \text{POISSON}(\lambda)$ e $Y \sim \text{POISSON}(\mu)$ independientes.

Observación 2.6. Si X e Y son independientes $\implies E(X \cdot Y) = E(X) \cdot E(Y)$.

Sin embargo, la implicación recíproca no es cierta.

(**Motivo de excomuni3n**)

Definici3n 2.10 (Covarianza). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., $\text{cov}(X, Y)$ es la covarianza de X e Y

$$\iff \boxed{\text{cov}(X, Y) = E[(X - E(X)) \cdot (Y - E(Y))] = E(X \cdot Y) - E(X) \cdot E(Y)}$$

29/02/2024

Observaci3n 2.7.


1. C3lculo de la covarianza

$$\text{cov}(X, Y) = \sum_{i,j} x_i y_j P(X = x_i \wedge Y = y_j) - \left(\sum_i x_i P(X = x_i) \right) \left(\sum_j y_j P(Y = y_j) \right)$$

2. Signo de la covarianza (y coeficiente de correlaci3n)

$$\text{cov}(X, Y) = \sum_{i,j} (x_i - E(X))(y_j - E(Y))P(X = x_i \wedge Y = y_j)$$

Entonces, si la covarianza es positiva, X e Y tienden a crecer juntas. Si es negativa, tienden a decrecer juntas. Si es 0, no hay relaci3n lineal entre X e Y .



3. C3lculo fundamental

$$\begin{aligned} V(X + Y) &= E((X + Y)^2) - (E(X + Y))^2 \\ &= E(X^2 + 2XY + Y^2) - (E(X) + E(Y))^2 \\ &= E(X^2) + 2E(XY) + E(Y^2) - (E(X))^2 - 2E(Y)E(X) - (E(Y))^2 \\ &\implies \boxed{V(X + Y) = V(X) + V(Y) + 2\text{cov}(X, Y)} \end{aligned}$$

Pero cuidado: $V(X - Y) = V(X) + V(Y) - 2\text{cov}(X, Y)$

De forma más general:

$$\begin{aligned} V(aX + bY) &= V(aX) + V(bY) + 2 \operatorname{cov}(aX, bY) \\ &= a^2 V(X) + b^2 V(Y) + 2ab \operatorname{cov}(X, Y) \\ \implies &\boxed{V(aX + bY) = a^2 V(X) + b^2 V(Y) + 2ab \operatorname{cov}(X, Y)} \end{aligned}$$

4. Si X e Y son independientes $\implies \operatorname{cov}(X, Y) = 0$

Definición 2.11 (coeficiente de correlación). Sean X e Y dos v.a.d., ρ es su coeficiente

de correlación $\iff \rho := \frac{\operatorname{cov}(X, Y)}{\sqrt{V(X) \cdot V(Y)}} \implies \rho$ no tiene unidades y $|\rho(X, Y)| \leq 1$.

Proposición 2.2 (Desigualdad de Cauchy-Schwarz). Sean X e Y dos v.a.d.

$$\implies E(X \cdot Y)^2 \leq E(X^2) \cdot E(Y^2)$$

La igualdad se da cuando una variable es transformación lineal de la otra, i.e. $Y = aX + b$.

Demostración. Definimos $W = sX + Y$, $W^2 \geq 0$ con probabilidad 1.

$$\begin{aligned} \implies 0 \leq E(W^2) &= E((sX + Y)^2) = E(s^2 X^2 + Y^2 + 2sXY) \\ &= s^2 E(X^2) + E(Y^2) + 2sE(XY) \\ &= E(X^2) \cdot s^2 + 2E(XY) \cdot s + E(Y^2) \end{aligned}$$

Vemos que el resultado es una parábola si se toma como función de s .

Como $\forall s \in \mathbb{R} : E(X) \geq 0$ y $E(X^2) \geq 0$, sabemos que la parábola o bien toca el eje X una única vez, o no lo hace nunca. Esto es equivalente a pedir que el valor del discriminante sea menor o igual que 0.

$$4E(XY)^2 - 4E(X^2)E(Y^2) \leq 0 \implies E(XY)^2 \leq E(X^2)E(Y^2)$$

■

Por tanto, $\boxed{\operatorname{cov}(X, Y)^2 = E((X - E(X))(Y - E(Y)))^2 \leq V(X) \cdot V(Y) \cdot \operatorname{cov}(X, Y)}$

Además $\rho(aX + b, cY + d) = \operatorname{sgn}(ac) \cdot \rho(X, Y)$.

04/03/2024

2.3.1 Detalle sobre independencia

Teorema 2.8. Sean X e Y dos v.a.d. en (Ω, \mathcal{F}, P) y $g, h: \mathbb{R} \longrightarrow \mathbb{R}$ dos funciones

$$X \text{ e } Y \text{ independientes} \iff E(g(X) \cdot h(Y)) = E(g(X)) \cdot E(h(Y))$$

Demostración. (\implies) $E(g(X) \cdot h(Y)) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x) \cdot h(y) \cdot P(X = x \wedge Y = y)$

Como X e Y son independientes, $P(X = x \wedge Y = y) = P(X = x) \cdot P(Y = y)$, entonces

$$E(g(X) \cdot h(Y)) = \left(\sum_{x \in X(\Omega)} g(x) P(X = x) \right) \left(\sum_{y \in Y(\Omega)} h(y) P(Y = y) \right) = E(g(X)) \cdot E(h(Y))$$

(\impliedby) Sean $\hat{x}, \hat{y} \in \mathbb{R}$, queremos probar que $P(X = \hat{x} \wedge Y = \hat{y}) = P(X = \hat{x}) \cdot P(Y = \hat{y})$

$$\text{Definimos } g(x) := \begin{cases} 1 & \text{si } x = \hat{x} \\ 0 & \text{si } x \neq \hat{x} \end{cases} \quad \wedge \quad h(y) := \begin{cases} 1 & \text{si } y = \hat{y} \\ 0 & \text{si } y \neq \hat{y} \end{cases}$$

$$\implies E(g(X) \cdot h(Y)) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x) h(y) P(X = \hat{x} \wedge Y = \hat{y}) = P(X = \hat{x} \wedge Y = \hat{y})$$

Como $E(g(X)) = P(X = \hat{x})$ y $E(h(Y)) = P(Y = \hat{y})$ y $E(g(X)h(Y)) = E(g(X))E(h(Y))$

$$\boxed{P(X = \hat{x} \wedge Y = \hat{y}) = E(g(X) \cdot h(Y)) = E(g(X)) \cdot E(h(Y)) = \boxed{P(X = \hat{x}) \cdot P(Y = \hat{y})}}$$

■

¿Qué pasaría con (X_1, \dots, X_n) para $n = 2$?

1. Modelo \longrightarrow función de masa conjunta $p_{X_1, \dots, X_n}(x_1, \dots, x_n)$

$$\begin{cases} \sum_{x_1 \in X_1(\Omega)} \cdots \sum_{x_n \in X_n(\Omega)} p_{X_1, \dots, X_n}(x_1, \dots, x_n) = 1 \\ p_{X_1, \dots, X_n}(x_1, \dots, x_n) \geq 0 \end{cases}$$

2. Marginales $p_{X_1}(x_1) = \sum_{x_2 \in X_2(\Omega)} \cdots \sum_{x_n \in X_n(\Omega)} p_{X_1, \dots, X_n}(x_1, \dots, x_n)$

3. Independencia (la función de masa conjunta se factoriza)

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = p_{X_1}(x_1) \cdots p_{X_n}(x_n) \iff \text{independencia completa}$$

Pero puede haber otras nociones de independencia (ej: 2 a 2).

4. **Matriz varianzas-covarianzas y matriz correlaciones** respectivamente

$$V = \begin{pmatrix} V(X_1) & \cdots & \text{cov}(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \cdots & V(X_n) \end{pmatrix} \quad \wedge \quad \Sigma = \begin{pmatrix} 1 & \cdots & \rho(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \rho(X_n, X_1) & \cdots & 1 \end{pmatrix}$$

Ambas son simétricas y definidas positivas.

Ejemplo 2.12. Queremos modelizar experimentos del tipo lanzar 18 veces un dado y sumar

los resultados obtenidos.

$$S_n = X_1 + \cdots + X_n \implies \begin{cases} E(S_n) = \sum_{i=1}^n E(X_i) \\ V(S_n) = \sum_{i=1}^n V(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j) \end{cases}$$

Si suponemos las X_i independientes e idénticas $\implies \forall i \in \mathbb{N}_n : E(X_i) =: \mu \wedge V(X_i) =: \sigma^2$
 $\implies E(S_n) = n\mu \wedge V(S_n) = n^2\sigma^2$

Si definimos $Z_n := \frac{1}{n}S_n = \frac{1}{n}(X_1 + \cdots + X_n) \implies E(Z_n) = \mu \wedge V(Z_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$
 $\implies Z_n$ no es aleatoria si $n \rightarrow \infty$ (ley de los grandes números)

05/03/2024

2.4 Funciones generatrices de probabilidad

2.4.1 Series de potencias

Sea $(a_n)_{n=0}^\infty$ una sucesión y $f(x) := \sum_{n=0}^\infty a_n x^n$ una función, ¿en qué valores de x está definida?

Sabemos que existe $R \in [0, \infty)$ radio de convergencia tal que

$$\sum_{n=0}^\infty a_n x^n \rightarrow \begin{cases} \text{converge} & \text{si } |x| < R \\ \text{diverge} & \text{si } |x| > R \end{cases} \iff \frac{1}{R} = \limsup_{n \rightarrow \infty} |a_n|^{1/n}$$

Ejemplo 2.13.

$$\sum_{n=0}^\infty \frac{x^n}{n!} = e^x \quad \wedge \quad \sum_{n=0}^\infty x^n = \frac{1}{1-x}, |x| < 1 \quad \wedge \quad \sum_{n=0}^m \binom{m}{n} x^n = (1+x)^m$$

2.4.2 Funciones generatrices

$$(a_n)_{n=0}^\infty \longleftrightarrow f(x) = \sum_{n=0}^\infty a_n x^n \implies \begin{cases} x \cdot f(x) \longleftrightarrow (0, a_0, \dots) \\ x \cdot f'(x) \longleftrightarrow (0a_0, 1a_1, 2a_2, \dots) \end{cases}$$

$$f(x) \cdot g(x) = \sum_{n=0}^\infty a_n x^n \sum_{n=0}^\infty b_n x^n = \sum_{n=0}^\infty \left(\sum_{k=0}^n a_k b_{n-k} \right) x^n$$

Definición 2.12 (Función generatriz de probabilidad). Sea X una variable aleatoria discreta que toma valores en $\{0, 1, 2, \dots\}$ donde $\forall j \geq 0 : p_j = P(X = j)$, $G_X(s)$ es su función

$$\text{generatriz de probabilidad} \iff \boxed{G_X(s) = \sum_{n=0}^{\infty} p_n s^n}$$

Ejemplo 2.14.

1. $X \sim \text{BER}(p) \implies G_X(s) = (1-p) + ps$
2. $X \sim \text{BIN}(n, p) \implies G_X(s) = \sum_{j=1}^n \binom{n}{j} (1-p)^{n-j} (ps)^j = (1-p + ps)^n$
3. $X \sim \text{GEOM}(p) \implies G_X(s) = \sum_{j=1}^{\infty} (1-p)^{j-1} ps^j = \frac{ps}{1 - (1-p)s}$

Demostración.

$$G_X(s) = \sum_{j=1}^{\infty} (1-p)^{j-1} ps^j = p \sum_{k=0}^{\infty} (1-p)^k s^{k+1} = ps \sum_{k=0}^{\infty} ((1-p)s)^k = \frac{ps}{1 - (1-p)s}$$

■

$$4. X \sim \text{POISSON}(\lambda) \implies G_X(s) = \sum_{j=0}^{\infty} e^{-\lambda} \frac{\lambda^j}{j!} s^j = e^{\lambda(s-1)}$$

$$\text{Demostración. } G_X(s) = \sum_{j=0}^{\infty} e^{-\lambda} \frac{\lambda^j}{j!} s^j = e^{-\lambda} \sum_{j=0}^{\infty} \frac{(\lambda s)^j}{j!} = e^{-\lambda} e^{\lambda s} = e^{\lambda(s-1)}$$

■

¿Para qué?

1. Cálculo de momentos con $(p_n)_{n=0}^{\infty}$

$$G_X(s) = \sum_{n=0}^{\infty} p_n s^n \implies G'_X(s) = \sum_{n=1}^{\infty} n p_n s^{n-1} \implies G'_X(1) = \sum_{n=1}^{\infty} n p_n = E(X)$$

Si seguimos derivando, obtenemos

$$\implies G''_X(s) = \sum_{n=2}^{\infty} n(n-1) p_n s^{n-2} = \sum_{n=2}^{\infty} n^2 p_n s^{n-2} - \sum_{n=2}^{\infty} n p_n s^{n-2}$$

$$\implies G''_X(1) = \sum_{n=2}^{\infty} n^2 p_n - \sum_{n=2}^{\infty} n p_n = E(X^2) - E(X)$$

$$\implies V(X) = E(X^2) - E(X)^2 = G''_X(1) + G'_X(1)(1 - G'_X(1))$$

Ejemplo 2.15.

$$\begin{aligned} \text{(a) } X \sim \text{BER}(p) &\implies G_X(s) = (1-p) + ps \\ &\implies G'_X(s) = p = E(X) \wedge G''_X(s) = 0 \implies V(X) = p(1-p) \end{aligned}$$

$$\begin{aligned}
(b) \quad X \sim \text{BIN}(n, p) &\implies G_X(s) = (1 - p + ps)^n \\
&\implies G'_X(s) = n(1 - p + ps)^{n-1}p \implies G'_X(1) = np = E(X) \\
&\implies G''_X(s) = n(n-1)(\dots)^{n-2}p^2 \implies G''_X(1) = n(n-1)p^2 \\
&\implies V(X) = n(n-1)p^2 + np(1 - np) = np(1 - p)
\end{aligned}$$

2. Suma de independientes

Teorema 2.9. Sean X, Y dos v.a.d. independientes con valores en $\{0, 1, 2, \dots\}$ y con funciones generatrices de probabilidad $G_X(s), G_Y(s)$ respectivamente

$$\implies G_{X+Y}(s) = G_X(s) \cdot G_Y(s)$$

Demostración.

$$G_{X+Y}(s) = \sum_{n=0}^{\infty} P(X + Y = n) s^n = \sum_{n=0}^{\infty} \left(\sum_{k=0}^n P(X = k \wedge Y = n - k) \right) s^n$$

Por otro lado,

$$\begin{aligned}
G_X(s) \cdot G_Y(s) &= \left(\sum_{n=0}^{\infty} P(X = n) s^n \right) \left(\sum_{n=0}^{\infty} P(Y = n) s^n \right) \\
&= \sum_{n=0}^{\infty} \left(\sum_{k=0}^n P(X = k) P(Y = n - k) \right) s^n \implies G_{X+Y}(s) = G_X(s) \cdot G_Y(s)
\end{aligned}$$

■

Otra manera:

$$G_X(s) = E(s^X) \wedge G_{X+Y}(s) = E(s^{X+Y}) = E(s^X \dots s^Y) = E(s^X) \cdot E(s^Y) = G_X(s) \cdot G_Y(s)$$

■

Corolario 2.1. Sean X_1, X_2, \dots, X_n v.a.d. independientes con valores en $\{0, 1, 2, \dots\}$ y con funciones generatrices de probabilidad $G_{X_1}(s), G_{X_2}(s), \dots, G_{X_n}(s)$ respectivamente

$$\implies G_{X_1+X_2+\dots+X_n}(s) = \prod_{i=1}^n G_{X_i}(s)$$

Si las X_i son “idénticas” $\implies G_{X_1+X_2+\dots+X_n}(s) = (G_{X_1}(s))^n$

06/03/2024

Teorema 2.10 (Unicidad). Sean X, Y dos v.a.d. con valores en $\{0, 1, 2, \dots\}$ y con funciones generatrices de probabilidad $G_X(s), G_Y(s)$ respectivamente

$$\implies G_X(s) = G_Y(s) \iff \forall n \geq 0 : P(X = n) = P(Y = n)$$

Ejemplo 2.16. Sean $X \sim \text{POISSON}(\lambda)$ \wedge $Y \sim \text{POISSON}(\mu)$ independientes con $\lambda, \mu > 0$. Definimos $Z = X + Y$.

$$\implies \forall x \geq 0 : P(Z = k) = P(X + Y = k) = \sum_{j=0}^k P(X = j \wedge Y = k - j) = \dots$$

Pero, a través de funciones generatrices obtenemos:

$$G_X(s) = e^{\lambda(s-1)} \wedge G_Y(s) = e^{\mu(s-1)} \implies G_Z(s) = e^{(\lambda+\mu)(s-1)} \implies Z \sim \text{POISSON}(\lambda + \mu)$$

Ejemplo 2.17.

1. Sean I_1, I_2, \dots, I_n v.a.d. independientes con $\forall k \in \mathbb{N}_n : I_k \sim \text{BER}(p)$ y definimos $Z = I_1 + I_2 + \dots + I_n$.

$$\implies G_Z(s) = [(1-p) + ps]^n \implies Z \sim \text{BIN}(n, p)$$

2. Sean $X \sim \text{BIN}(n, p)$ \wedge $Y \sim \text{POISSON}(\lambda)$ independientes y definimos $Z = X + Y$.

$$\implies G_Z(s) = ((1-p) + ps)^n \cdot e^{\lambda(s-1)}$$

3 Ejercicios

3.1 Hoja 1

3.2 Hoja 2

7. b $X \sim \text{GEOM}(p) \iff P(X > n+m | X > m) = P(X > n)$

Solución: Lo que nos está diciendo la caracterización es que una distribución geométrica no tiene memoria, la probabilidad de no tener éxito en los próximos n intentos no depende de los intentos anteriores.

Demostración. (\implies) Suponemos que $X \sim \text{GEOM}(p)$

$$\implies P(X > n+m | X > m) = \frac{P(X > n+m \wedge X > m)}{P(X > m)} = \frac{P(X > n+m)}{P(X > m)}$$

Como $P(X > m) = (1-p)^m$ (por eso se llama geométrica), obtenemos

$$\boxed{P(X > n+m | X > m) = \frac{(1-p)^{n+m}}{(1-p)^m} = (1-p)^n = \boxed{P(X > n)}}$$

(\impliedby) Suponemos que $P(X > n+m | X > m) = P(X > n)$

$$\implies \frac{P(X > n+m \wedge X > m)}{P(X > m)} = \frac{P(X > n)}{P(X > m)}$$

$$\implies P(X > n+m \wedge X > m) = P(X > n) \cdot P(X > m)$$

■

12. Sea X una v.a.d, $X \sim \text{BINNEG}(n, p) \iff P(X = k) = \binom{k-1}{n-1} p^n (1-p)^{k-n}$.

Esto significa que X es la suma de n v.a.d. independientes, con distribución $\text{GEOM}(p)$.

Comprobemos que $\sum_{k=n}^{\infty} \binom{k-1}{n-1} p^n (1-p)^{k-n} = 1$

$$\sum_{k=n}^{\infty} \binom{k-1}{n-1} p^n (1-p)^{k-n} = \sum_{l=0}^{\infty} \binom{l+n-1}{n-1} p^n (1-p)^l = p^n \sum_{l=0}^{\infty} \binom{l+n-1}{n-1} (1-p)^l$$

Como sabemos que $\frac{1}{(1-x)^{m+1}} = \sum_{l=0}^{\infty} \binom{l+m}{m} x^l$, podemos tomar $x = 1-p$ y $m = n-1$:

$$\implies \sum_{k=n}^{\infty} P(X = k) = \frac{p^n}{(1-(1-p))^{n-1+1}} = \frac{p^n}{p^n} = \boxed{1}$$

20. Cada día compramos 1 cromo de n totales que hay, con reposición. ¿Cuántos días esperamos hasta tener todos los cromos?

Solución: Sea T una v.a.d. igual a la cantidad de días hasta que terminamos la colección, queremos calcular $E(T)$. Se puede utilizar el modelo de distribución geométrica.

Si definimos T_i como la cantidad de días que esperamos hasta tener el cromo i -ésimo nuevo

sabiendo que tienes los $i - 1$ anteriores, entonces:

$$\begin{aligned} \implies T_1 = 1 \wedge T_2 &\sim \text{GEOM} \left(\frac{n-1}{n} \right) \wedge T_3 \sim \text{GEOM} \left(\frac{n-2}{n} \right) \wedge \dots \\ \implies \forall i \in \mathbb{N}_n : T_i &\sim \text{GEOM} \left(1 - \frac{i-1}{n} \right) \implies E(T_i) = \frac{n}{n-i} \end{aligned}$$

Además, $T = T_1 + T_2 + \dots + T_n$. Por linealidad de la esperanza:

$$\begin{aligned} E(T) &= \sum_{i=1}^n E(T_i) = \sum_{i=0}^{n-1} \frac{n}{n-i} = n \sum_{i=0}^{n-1} \frac{1}{n-i} = n \sum_{k=1}^n \frac{1}{k} = nH_n \sim \ln n - \gamma + O\left(\frac{1}{n}\right) \\ \implies E(T) &= nH_n \approx n \ln n \end{aligned}$$