
PROBABILIDAD I

Segundo del Grado en Matemáticas

Hugo Marquerie

Profesor: Pablo Fernández Gallardo

Facultad de Ciencias - Universidad Autónoma de Madrid

Segundo cuatrimestre 2023 - 2024

1 de Febrero, 2024

Índice

1	Tema 1: Sucesos y probabilidades	1
1.1	Formalizando	1
1.2	Probabilidad condicionada y total, independencia y Bayes	2
1.2.1	Probabilidad total	4
1.2.2	Continuidad de la probabilidad: detalle técnico	6
2	Tema 2: Variables aleatorias discretas	7
2.1	Funciones transformadoras de variables aleatorias (discretas)	9
2.2	Resúmenes: esperanza, varianza, momentos	9
2.2.1	Esperanza condicionada	14
2.3	Varias variables aleatorias	15
2.3.1	Detalle sobre independencia	19
2.4	Funciones generatrices de probabilidad	20
2.4.1	Series de potencias	20
2.4.2	Funciones generatrices	21
3	Variables aleatorias continuas	24
3.1	Funciones / Transformaciones de v.a.c.	26
3.2	Esperanzas de v.a.c.	28
3.2.1	Calculando con la normal ($N(\mu, \sigma^2)$)	30
3.3	Modelos multidimensionales (vectores aleatorios)	31
3.3.1	Normal multidimensional	32
3.3.2	Marginales e independencia	32
3.4	Condicionando	33
3.5	Transformaciones / cambio de variables	34
3.6	Convolución	36
3.7	Fuera de menú	38
4	Convergencia de variables aleatorias	39
4.1	Medias y varianzas de las sumas y las medias	39
4.2	Convergencia cuadrática	40
4.3	Convergencia en probabilidad (ley débil)	41
4.4	Cálculo de la distribución de la suma y el promedio	42
4.5	Convergencia en distribución	43
4.5.1	Teorema del límite central / central del límite	43

4.5.2	Variaciones del TCL	45
4.6	Funciones generatrices de momentos (y función característica)	45
4.6.1	¿Por qué ese nombre?	46
4.6.2	La gracia	47
4.6.3	El problema de los momentos	47
4.7	Función característica	48
4.7.1	Función característica para distribución de Cauchy: Variable compleja	50
5	Ejercicios	52
5.1	Hoja 1	52
5.2	Hoja 2	52
5.3	Hoja 3	53
5.4	Hoja 4	54
5.5	Hoja 5	56

1 Tema 1: Sucesos y probabilidades

1.1 Formalizando

Definición 1.1 (Espacio muestral). En un experimento aleatorio, el espacio muestral es el conjunto (no vacío) de sus posibles resultados y se denota por Ω . Puede ser:

1. Finito: $\Omega = \{\omega_1, \dots, \omega_N\}$
2. Infinito numerable: $\Omega = \{\omega_1, \omega_2, \dots\}$
3. Infinito no numerable, ej.: $\Omega = [0, 1) \vee \Omega = \mathcal{P}([0, 1))$

Definición 1.2 (Espacio de sucesos por Kolmogórov). Dado el espacio muestral Ω de un experimento aleatorio, $\mathcal{F} \subset \mathcal{P}(\Omega)$ es su espacio de sucesos

$$\iff (\mathcal{F} \neq \emptyset) \wedge (A \in \mathcal{F} \implies A^C \in \mathcal{F}) \wedge \left(A_1, A_2, \dots \in \mathcal{F} \implies \bigcup_{j=1}^{\infty} A_j \in \mathcal{F} \right)$$

Observación 1.1. De la definición se deduce:

$$\bullet \phi \in \mathcal{F} \wedge \Omega \in \mathcal{F} \quad \bullet A_1, \dots, A_n \in \mathcal{F} \implies \bigcup_{j=1}^n A_j \in \mathcal{F} \quad \bullet \forall A, B \in \mathcal{F} \implies A \cap B \in \mathcal{F}$$

Definición 1.3 (Función o medida de probabilidad). Dado espacio muestral (Ω) y de sucesos (\mathcal{F}) de un experimento aleatorio, la aplicación $P: \mathcal{F} \rightarrow [0, 1]$ es una medida de probabilidad

$$\iff (P(\Omega) = 1) \wedge \left[P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} P(A_j) \iff A_i \cap A_j = \emptyset \text{ cuando } i \neq j \right]$$

Proposición 1.1. De la definición se deduce:

$$\begin{aligned} 1. P\left(\bigcup_{j=1}^n A_j\right) &= \sum_{j=1}^n P(A_j) & 2. P(A^C) &= 1 - P(A) & 3. P(\emptyset) &= 0 \\ 4. P(A \cup B) &= P(A) + P(B) - P(A \cap B) & 5. A \subseteq B &\implies P(A) \leq P(B) \end{aligned}$$

Ejemplo 1.1. En un experimento aleatorio con espacio muestral finito, tomamos

$\Omega = \{\omega_1, \dots, \omega_N\} \wedge \mathcal{F} = \mathcal{P} \rightarrow 2^N$. Asignamos $P(\{\omega_j\}) = p_j \wedge j = 1, \dots, N$ tales que $p_j \geq 0 \wedge \sum_{j=1}^N p_j = 1$. Entonces, $\forall A \in \mathcal{F} : P(A) = \sum_{\omega \in A} P(\omega)$

Caso particular: $\forall j \in \mathbb{N}_N : p_j = \frac{1}{N} \implies \forall A \in \mathcal{F} : P(A) = \frac{|A|}{N} = \frac{\text{“Casos favorables”}}{\text{“Total de casos”}}$

Ejemplos varios:

1. (Muy tonto) $\Omega \neq \phi$, tomas $A \subset \Omega : A \neq \phi, \Omega$.
Dato $p \in (0, 1)$. $\mathcal{F} = \{\phi, A, A^c, \Omega\}$ con $P(A) = p$.
2. (Bastante general) $(\Omega = \{\omega_1, \dots, \omega_N\} \implies |\Omega| = N) \wedge (\mathcal{F} = P(\Omega) \rightarrow |\mathcal{F}| = 2^N)$.
Dato: $p_1, \dots, p_N \geq 0 \implies \sum_{j=1}^N p_j = 1$. Asignamos $\forall j \in \mathbb{N}_N : p_j := P(\{\omega_j\})$.
Definimos $\forall A \subset \Omega : P(A) = \sum_{\omega \in A} P(\omega)$.
3. Lanzas n veces una moneda. Dato: $p \in (0, 1)$.
 $\implies \Omega = \{111 \dots 1, \dots, 000 \dots 0\} \wedge |\Omega| = 2^N \wedge$ escogemos $\mathcal{F} = P(\Omega)$
 $\implies \forall \omega \in \Omega : P(\omega) = p^{\#\text{unos de } \omega} (1-p)^{\#\text{ceros de } \omega}$

Comprobamos:

$$\begin{aligned} \sum_{\omega \in \Omega} P(\omega) &= \sum_{k=0}^n \left(\sum_{\substack{\omega \in \Omega \\ \#\text{0s de } \omega = k}} P(\omega) \right) = \sum_{k=0}^n p^k (1-p)^{n-k} (|\{\omega \in \Omega : \#\text{1s de } \omega = k\}|) \\ &= \sum_{k=0}^n p^k (1-p)^{n-k} \binom{n}{k} = (p + 1 - p)^n = 1 \end{aligned}$$

4. Lanzamos moneda hasta que sale una cara. Dato $p \in (0, 1)$.
 $\implies \Omega = \{C, XC, XXC, \dots\} \wedge$ escogemos $\mathcal{F} = P(\Omega)$
 $P(C) =: p \implies P(XC) = p(1-p) \wedge P(XXC) = p(1-p)^2 \wedge \dots$

Comprobamos: $\sum_{j=1}^{\infty} p(1-p)^{j-1} = p \sum_{k=0}^{\infty} (1-p)^k = p \frac{1}{1-(1-p)} = 1$

1.2 Probabilidad condicionada y total, independencia y Bayes

Tienes (Ω, \mathcal{F}, P) y un suceso $A \in \mathcal{F} \rightarrow P(A)$. Llega “nueva información”: ha ocurrido el suceso $B \in \mathcal{F} \rightarrow$ ¿Debo reasignar la probabilidad de A ?

Ejemplo 1.2 (Dependencia). Lanzas 10 veces una moneda (regular).

$$A = \{\text{salen 6 caras}\} \implies P(A) = \frac{\binom{10}{6}}{2^{10}} \approx 20.51\%$$

$$B = \{\text{sale C en 1}^{\text{o}}\} \implies P(A) \text{ sube a } \frac{\binom{9}{5}}{2^9}$$

Definición 1.4. Sea (Ω, \mathcal{F}, P) un espacio de probabilidad y los sucesos $A, B \in \mathcal{F} : P(B) > 0$, $P(A|B)$ es la probabilidad de A condicionada a B

$$\Longleftrightarrow P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Observación 1.2. En general, $P(A|B) \neq P(B|A)$

Proposición 1.2 (Cálculo de $P(A|B)$ para cada $A \in \mathcal{F}$). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad y $B \in \mathcal{F}$ un suceso con $P(B) > 0$

$\implies (\Omega, \mathcal{F}, Q_B)$, con $Q_B: \mathcal{F} \longrightarrow [0, 1] : Q_B(A) = P(A|B)$, es un espacio de probabilidad

Demostración. Basta ver que Q_B es una función de probabilidad.

$$\left(Q_B(A) = P(A|B) = \frac{P(A \cap B)}{P(B)} \in [0, 1] \right) \wedge \left(Q_B(\Omega) = \frac{P(\Omega \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1 \right)$$

Sean $A_1, A_2, \dots \in \mathcal{F}$ disjuntos dos a dos.

$$\begin{aligned} \implies Q_B \left(\bigcup_{j=1}^{\infty} A_j \right) &= P \left(\bigcup_{j=1}^{\infty} A_j \mid B \right) = \frac{P \left(\bigcup_{j=1}^{\infty} A_j \cap B \right)}{P(B)} \\ &= \frac{1}{P(B)} P \left(\bigcup_{j=1}^{\infty} (A_j \cap B) \right) = \frac{1}{P(B)} \sum_{j=1}^{\infty} P(A_j \cap B) = \sum_{j=1}^{\infty} Q_B(A_j) \end{aligned}$$

■

Definición 1.5 (Independencia). Sean $A, B \in \mathcal{F}$ dos sucesos con $P(A), P(B) \geq 0$ son independientes

$$\Longleftrightarrow P(A|B) = P(A) \wedge P(B|A) = P(B) \text{ (para entender)}$$

$$\Longleftrightarrow P(A \cap B) = P(A) \cdot P(B) \text{ (la adecuada)}$$

• A, B disjuntos \implies no independientes.

• $A_1, \dots, A_N \in \mathcal{F}$ independientes $\Longleftrightarrow \forall J \subset \mathbb{N}_N : P \left(\bigcap_{j \in J} A_j \right) = \prod_{j \in J} P(A_j)$

$$\Longleftrightarrow P \left(\overline{A_1} \cap \dots \cap \overline{A_N} \right) = \prod_{i=1}^N P \left(\overline{A_i} \right) \text{ donde } \overline{A_i} = A_i, (A_i)^c$$

Ejercicio 1.2.1. Encontrar un espacio de probabilidad en el que haya un conjunto de sucesos independientes dos a dos pero no completamente independientes.

$$\text{SOL: } \Omega = \{1, 2, 3, 4\} \wedge A = \{1, 2\} \wedge B = \{2, 3\} \wedge C = \{1, 3\}$$

Proposición 1.3 (Regla de Bayes). Sean (Ω, \mathcal{F}, P) un espacio de probabilidad y $A, B \in \mathcal{F}$ sucesos con $P(A), P(B) > 0$

$$\implies P(A|B) = P(B|A) \cdot \frac{P(A)}{P(B)}$$

Demostración.

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \wedge P(B|A) = \frac{P(A \cap B)}{P(A)}$$

$$\implies P(A|B) \cdot P(B) = P(A \cap B) = P(B|A) \cdot P(A) \implies P(A|B) = P(B|A) \cdot \frac{P(A)}{P(B)}$$

■

07/02/2024

1.2.1 Probabilidad total

Proposición 1.4. Sean (Ω, \mathcal{F}, P) un espacio de probabilidad y $\{B_1, B_2, \dots\}$ una partición de $\Omega : (\forall i, j : i \neq j : B_i \cap B_j = \emptyset) \wedge \left(\bigcup_{j=1}^{\infty} B_j = \Omega \right)$

$$\implies \forall A \in \mathcal{F} : P(A) = P\left(\bigcup_{j=1}^{\infty} (A \cap B_j)\right) = \sum_{j=1}^{\infty} P(A \cap B_j) = \sum_{j=1}^{\infty} P(A|B_j) \cdot P(B_j)$$

$$\implies \forall A \in \mathcal{F} : \boxed{P(A) = \sum_{j=1}^{\infty} P(A|B_j) \cdot P(B_j)}$$

■

Ejemplo 1.3. Sean $U_1 = \{10b, 3n\} \wedge U_2 = \{5b, 5n\} \wedge U_3 = \{2b, 6n\}$ tres urnas con bolas blancas (b) y negras (n). Procedimiento:

1. Sorteamos una urna $P(U_1) = \frac{1}{4} \wedge P(U_2) = \frac{1}{4} \wedge P(U_3) = \frac{1}{2}$
2. Sacamos bola de la urna seleccionada.

¿Cuál es la probabilidad de que sea blanca?

$$P(b) = P(b|U_1)P(U_1) + P(b|U_2)P(U_2) + P(b|U_3)P(U_3)$$

Ejemplo 1.4 (Peso de la evidencia). Sean $U_1 = \{80\% b, 20\% n\} \wedge U_2 = \{20\% b, 80\% n\}$ dos urnas con bolas blancas (b) y negras (n). Procedimiento:

1. Sorteamos la urna con $1/2$ y $1/2$ de probabilidad.
2. Sacamos 10 bolas (con reemplazamiento).

Observamos la evidencia: $bb \dots nb$ ¿qué urna se usó?

$$P(U_1|5b5n) = P(5b5n|U_1) \frac{P(U_1)}{P(5b5n)} = \frac{P(5b5n|U_1)P(U_1)}{P(5b5n|U_1)P(U_1) + P(5b5n|U_2)P(U_2)}$$

$$\implies P(5b5n|U_1) = \binom{10}{5} 0.8^5 0.2^5 = P(5b5n|U_2) \implies P(U_1|5b5n) = \frac{1}{2}$$

Este es el resultado que esperábamos, prestemos atención a otro caso más contraintuitivo.


$$P(U_1|6b4n) = \frac{P(6b4n|U_1)P(U_1)}{P(6b4n|U_1)P(U_1) + P(6b4n|U_2)P(U_2)}$$

$$= \frac{\binom{10}{6} 0.8^6 0.2^4 \cdot 1/2}{\binom{10}{6} 0.8^6 0.2^4 \cdot 1/2 + \binom{10}{6} 0.8^4 0.2^6 \cdot 1/2} \approx 90\%$$

Si dibujamos la gráfica de la función

$$f(x) = P(U_1|xb(10-x)n)$$

podemos ver que el cambio es muy brusco. Es decir, una pequeña diferencia en la evidencia puede cambiar mucho la probabilidad de que se haya usado una urna u otra.




Ejemplo 1.5 (Falsos positivos/negativos). Hay una enfermedad ($E \vee S$) y hay una prueba para detectar ($+ \vee -$). Datos: $P(+|E) = 95\% \wedge P(-|S) = 99\%$.

Te haces la prueba y sale +:

$$P(E|+) = P(+|E) \frac{P(E)}{P(+)} = \frac{P(+|E)P(E)}{P(+|E)P(E) + P(+|S)P(S)}$$

Conozco todas estas probabilidades excepto $p := P(E) \implies P(S) = 1 - p$.



Si definimos $f(p) := P(E|+)$

$$\implies \{f(0.5) = 98.95\% \wedge f(1/100) = 48.97\% \wedge f(1/1000) = 8.68\%\}$$

Es decir, si la incidencia es muy baja, no tiene sentido hacer pruebas masivamente porque la mayoría de positivos serán falsos.

08/02/2024

Ejemplo 1.6 (Sobre independencia). $(\Omega, \mathcal{F}, P) \wedge A_1, \dots, A_n$ sucesos independientes tal

que $\forall j \in \mathbb{N}_n : P(A_j) = \frac{1}{n}$. ¿Qué sabemos sobre $P\left(\bigcup_{j=1}^n A_j\right)$?

$$\text{En general, sabemos que } \frac{1}{n} \leq P\left(\bigcup_{j=1}^n A_j\right) \leq \sum_{j=1}^n P(A_j) \leq 1$$

$$n = 2: P(A \cup B) = P(A) + P(B) - P(A \cap B) = 3/4$$

$$n = 3: P(A \cup B \cup C) = \binom{3}{1} \frac{1}{3} - \binom{3}{2} \frac{1}{3^2} + \binom{3}{3} \frac{1}{3^3} = 19/27$$

$$\begin{aligned}
n \text{ general: } P\left(\bigcup_{j=1}^n A_j\right) &= \sum_{j=1}^n P(A_j) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j) + \cdots \text{ (Inclusión exclusión)} \\
\Rightarrow P\left(\bigcup_{j=1}^n A_j\right) &= \binom{n}{1} \frac{1}{n} - \binom{n}{2} \frac{1}{n^2} + \binom{n}{3} \frac{1}{n^3} + \cdots = \sum_{j=1}^n \binom{n}{j} \frac{1}{n^j} (-1)^{j+1} \\
\Rightarrow P\left(\bigcup_{j=1}^n A_j\right) &= 1 - \sum_{j=0}^n \binom{n}{j} \left(\frac{-1}{n}\right)^j = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - \frac{1}{e}
\end{aligned}$$

1.2.2 Continuidad de la probabilidad: detalle técnico

Proposición 1.5. Sean (Ω, \mathcal{F}, P) un espacio de probabilidades y $A_1, \dots : A_1 \subset A_2 \subset \dots$ una sucesión creciente de conjuntos

$$\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) = \lim_{n \rightarrow \infty} P(A_n)$$

Demostración. Se trata de describir $\bigcup_{j=1}^n A_j$ como la unión de conjuntos disjuntos.

$$\begin{aligned}
P\left(\bigcup_{j=1}^n A_j\right) &= P\left(A_1 \cup \bigcup_{j=1}^{n-1} (A_{j+1} \setminus A_j)\right) = P(A_1) + \sum_{j=1}^{n-1} (P(A_{j+1}) - P(A_j)) = P(A_n) \\
\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) &= P(A_1) + \sum_{j=1}^{\infty} (P(A_{j+1}) - P(A_j)) = \lim_{n \rightarrow \infty} P(A_n)
\end{aligned}$$

■

Proposición 1.6. Si la sucesión A_1, \dots es decreciente $\Rightarrow P\left(\bigcap_{j=1}^{\infty} A_j\right) = \lim_{n \rightarrow \infty} P(A_n)$

Teorema 1.1 (Continuidad de la probabilidad). En el espacio de probabilidades (Ω, \mathcal{F}, P) , sea A_1, A_2, \dots una sucesión : $\forall j \in \mathbb{N} : A_j \in \mathcal{F}$

$$\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{j=1}^n A_j\right)$$

Demostración. Definimos $B_i := \bigcup_{j=1}^i A_j \Rightarrow \bigcup_{j=1}^{\infty} A_j = \bigcup_{i=1}^{\infty} B_i$ (B_i) es creciente.

$$\Rightarrow P\left(\bigcup_{j=1}^{\infty} A_j\right) = P\left(\bigcup_{i=1}^{\infty} B_i\right) = \lim_{n \rightarrow \infty} P(B_n) = P\left(\bigcup_{j=1}^n A_j\right)$$

■

2 Tema 2: Variables aleatorias discretas

Definición 2.1. Sea (Ω, \mathcal{F}, P) un espacio de probabilidades, $X: \Omega \rightarrow \mathbb{R}$ es una variable aleatoria discreta* (v.a.d.)

$$\iff (1) X(\Omega) \text{ es numerable}^* \wedge (2) \forall x \in \mathbb{R} : \{\omega \in \Omega : X(\omega) = x\} \in \mathcal{F}$$

En realidad, solo interesa (2) cuando $x = x_j$

Definición 2.2. Sea X una v.a.d. en (Ω, \mathcal{F}, P) , $p_X: \mathbb{R} \rightarrow [0, 1]$ es su función de masa

$$\iff x \mapsto p_X(x) = P(X = x) := P(\{\omega \in \Omega : X(\omega) = x\})$$

Vemos que

$$\sum_{j \geq 1} p_X(x_j) = \sum_{j \geq 1} P(X = x_j) = \sum_{j \geq 1} P(\{\omega \in \Omega : X(\omega) = x_j\}) = P\left(\bigcup_{\omega \in \Omega} \{\omega\}\right) = P(\Omega) = 1$$

Lo relevante es el conjunto de posibles valores de X ($\{x_1, x_2, \dots\}$) numerable y el conjunto (también numerable) de probabilidades $\{p_1, p_2, \dots\}$ donde

$$\left(\forall j \geq 1 : p_j = P(x = x_j) \wedge p_j \geq 0\right) \wedge \sum_{j \geq 1} p_j = 1$$

Teorema 2.1. Sea $S = \{x_1, x_2, \dots, x_j\}$ un conjunto y $(\Pi_1, \Pi_2, \dots, \Pi_j)$ una lista tal que

$$\forall i \leq j : \Pi_i \geq 0 \wedge \sum_{j \geq 1} \Pi_j = 1$$

$$\implies \exists (\Omega, \mathcal{F}, P) \wedge X \text{ v.a.d.} : (\forall x \notin S : p_X(x) = 0) \wedge p_X(x_i) = \Pi_i$$

Demostración. Fijamos $\Omega = S$ y $\mathcal{F} = \mathcal{P}(S)$.

$$A \in \mathcal{F} \implies P(A) = \sum_{j: x_j \in A} \Pi_j \wedge X(x_j) = x_j$$

■

Ejemplo 2.1 (Diferentes modelos de distribución de probabilidad).

1. X sigue una distribución **uniforme** en $\{1, \dots, N\}$, $N \geq 2$ ($X \sim \text{UNIF}(N)$).

$$\iff S = \{1, \dots, N\} \wedge \Pi_j = 1/N, \dots, 1/N$$

Se usa para modelizar un lanzamiento de un dado regular de N caras.

2. X sigue una distribución de **Bernoulli** con parámetro p ($X \sim \text{BER}(p)$)

$$\iff \begin{cases} p_X(x) = 0 \iff x \neq 0, 1 \\ p_X(1) = p \wedge p_X(0) = 1 - p \end{cases} \iff \begin{cases} P(X = 1) = p \\ P(X = 0) = 1 - p \end{cases}$$

donde 1 es éxito y 0 fracaso. Se usa para modelizar el resultado de un experimento con dos posibles resultados, i.e. una moneda no necesariamente regular.

13/02/2024

3. X sigue una distribución **binomial** de parámetros $n \geq 1 \wedge p \in (0, 1)$ ($X \sim \text{BIN}(n, p)$)

$$\iff S = \{0, 1, \dots, n\} \wedge \forall j \in \{0, 1, \dots, n\} : P(X = j) = \binom{n}{j} p^j (1 - p)^{n-j}$$

Sirve para modelizar el número de caras que salen al lanzar n veces una moneda de probabilidad p .

Podemos estimar cual es la probabilidad de que salgan $n/2$ caras con $p = 1/2$ mediante la fórmula de Stirling:

$$\begin{aligned} n! \sim n^n e^{-n} \sqrt{2\pi n} &\implies \binom{n}{n/2} \sim \frac{n^n e^{-n} \sqrt{2\pi n}}{(n/2)^{(n/2)} e^{-(n/2)} \sqrt{2\pi(n/2)} (n/2)^{(n/2)} e^{-(n/2)} \sqrt{2\pi(n/2)}} \\ &\implies \frac{n^n \sqrt{n}}{(n/2)^{(n/2)} \sqrt{2\pi(n/2)} (n/2)^{(n/2)} \sqrt{(n/2)}} = \frac{n^n \sqrt{n}}{(n/2)^n \sqrt{2\pi(n/2)}} = \frac{n^n \sqrt{2}}{(n/2)^n \sqrt{\pi n}} = 2^n \sqrt{\frac{2}{\pi n}} \\ &\implies P\left(X = \frac{n}{2}\right) = \binom{n}{n/2} \frac{1}{2^n} \approx 2^n \sqrt{\frac{2}{\pi n}} \frac{1}{2^n} = \sqrt{\frac{2}{\pi n}} \end{aligned}$$

4. X sigue una distribución **geométrica** de parámetro $p \in (0, 1)$ ($X \sim \text{GEOM}(p)$).

$$\iff S = \{1, 2, \dots\} \wedge \forall j \geq 1 : P(X = j) = p(1 - p)^{j-1}$$

Sirve para modelizar el número de lanzamientos hasta que sale un resultado C en cuestión con $P(X = C) = p$.

Observación 2.1. Cuidado porque existen variables aleatorias que también se dicen de distribución geométrica en las que $S = \{0, 1, 2, \dots\}$. Se habla de cuantas veces has obtenido el resultado complementario a C antes de que halla salido C .

5. X sigue una distribución de **Poisson** con parámetro $\lambda > 0$ ($X \sim \text{POISSON}(\lambda)$)

$$\iff S = \{0, 1, \dots\} \wedge \forall j \geq 0 : P(X = j) = e^{-\lambda} \frac{\lambda^j}{j!}$$

Se usa para modelizar la frecuencia de eventos determinados durante un intervalo de tiempo fijado a partir de la frecuencia media de aparición de dichos eventos.

Proposición 2.1. Sea $X \sim \text{BIN}(n, p)$ una v.a.d.

\implies cuando n es grande, $\text{BIN}(n, p) \sim \text{POISSON}(np)$

Demostración. Fijo $\lambda > 0$ \wedge $p = \frac{\lambda}{n}$.

$$\lim_{n \rightarrow \infty} \binom{n}{k} \frac{\lambda^k}{n^k} \left(1 - \frac{\lambda}{n}\right)^{n-k} = \frac{\lambda^k}{k!} \lim_{n \rightarrow \infty} \frac{n!}{(n-k)!} \frac{1}{n^k} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} = e^{-k} \frac{\lambda^k}{k!}$$

■

Ejemplo 2.2 (¿Hay más ejemplos?).

- Binomial negativa
- Hipergeométrica
- Sea cualquier serie convergente $\sum_{n=1}^{\infty} a_n = s$

\implies se puede definir la variable aleatoria $X : S = \{1, 2, \dots\} \wedge P(x = k) = \frac{a_k}{s}$

14/02/2024

2.1 Funciones transformadoras de variables aleatorias (discretas)

Sea X una v.a.d. y $g: \mathbb{R} \longrightarrow \mathbb{R}$ una función, definimos $Y := g(X)$.

$\implies \{\omega \in \Omega : Y(\omega) = g(X(\omega)) = y\} \in \mathcal{F} \implies Y$ es una v.a.d

Por otro lado,

$$\forall y \in \mathbb{R} : P(Y = y) = P(g(X) = y) = P(X \in g^{-1}(y)) = \sum_{x \in g^{-1}(y)} P(X = x) = \sum_{x \in g^{-1}(y)} p_X(x)$$

Ejemplo 2.3 ($Y = x^2$).

$$p_Y(y) = P(Y = y) = P(X^2 = y) = \begin{cases} 0, & y < 0 \\ P(X = 0) = p_X(0), & y = 0 \\ P(X = \pm\sqrt{y}) = p_X(\sqrt{y}) + p_X(-\sqrt{y}), & y > 0 \end{cases}$$

2.2 Resúmenes: esperanza, varianza, momentos

Definición 2.3 (Esperanza). Sea X una v.a.d. en el espacio de probabilidad (Ω, \mathcal{F}, P) y con función de masa p_X , $E(X)$ es la esperanza de X (también llamada media o *expectatio*)

$$\iff E(X) = \sum_{x \in X(\Omega)} x \cdot P(X = x) = \sum_{j \geq 1} x_j \cdot p_X(x_j)$$

Pero ojo, solo si la serie es absolutamente convergente.

- Si x_1, \dots, x_N finito, la suma obviamente converge.
- Si los x_j son positivos, la serie converge si y solo si es acotada. Si no lo es diverge a ∞ .

Ejemplo 2.4 (Cálculo de la esperanza).

- $x_1, \dots, x_N \wedge p_1, \dots, p_N \implies E(X) = \sum_{j=1}^N x_j \cdot p_j$
- $X \sim \text{BER}(p) \implies E(X) = 1 \cdot p + 0 \cdot (1 - p) \implies \boxed{E(X) = p}$
- $X \sim \text{UNIF}(1, \dots, N) \implies E(X) = \frac{1}{N} \sum_{n=1}^N n \implies \boxed{E(X) = \frac{N+1}{2}}$
- $X \sim \text{BIN}(n, p) \implies E(X) = \sum_{j=0}^n j \binom{n}{j} p^j (1-p)^{n-j} \implies \boxed{E(X) = np}$

Se obtiene derivando el binomio de Newton $(1+x)^n = \sum_{j=0}^n \binom{n}{j} x^j$

$$\implies \frac{d}{dx}(1+x)^n = \sum_{j=0}^n \binom{n}{j} j \cdot x^{j-1} \implies xn(1+x)^{n-1} = \sum_{j=0}^n \binom{n}{j} j x^j$$

$$\begin{aligned} \text{Si } x = \frac{p}{1-p} \implies \frac{p}{1-p} n \left(1 + \frac{p}{1-p}\right)^{n-1} &= \sum_{j=0}^n \binom{n}{j} j \left(\frac{p}{1-p}\right)^j \\ \implies \frac{p}{1-p} n \left(\frac{1}{1-p}\right)^{n-1} &= \sum_{j=0}^n \binom{n}{j} j \left(\frac{p}{1-p}\right)^j \\ \implies np = (1-p)^n \sum_{j=0}^n \binom{n}{j} j \left(\frac{p}{1-p}\right)^j &= \sum_{j=0}^n j \binom{n}{j} p^j (1-p)^{n-j} = E(X) \end{aligned}$$

■

- $X \sim \text{GEOM}(p) \implies E(X) = \sum_{k=1}^{\infty} k \cdot p \cdot (1-p)^{k-1} \implies \boxed{E(X) = \frac{1}{p}}$

$$\forall x : |x| < 1 : \frac{1}{1-x} = \sum_{n=0}^{\infty} x^n \implies \frac{1}{(1-x)^2} = \sum_{n=1}^{\infty} n x^{n-1} \implies E(X) = p \frac{1}{p^2} = \frac{1}{p}$$

■

- $X \sim \text{POISSON}(\lambda) \implies E(X) = \sum_{j=0}^{\infty} j \frac{\lambda^j}{j!} e^{-\lambda} \implies \boxed{E(X) = \lambda}$

$$\implies E(X) = e^{-\lambda} \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda$$

■

Ejemplo 2.5. Sea X una v.a.d. con $\forall k \geq 0 : P(X = k) = \frac{6}{\pi^2} \frac{1}{k^2}$

$$\implies E(X) = \sum_{k=1}^{\infty} k \frac{6}{\pi^2} \frac{1}{k^2} = \frac{6}{\pi^2} \sum_{k=1}^{\infty} \frac{1}{k} \text{ que diverge a } \infty$$

Ejemplo 2.6. Sea X una v.a.d. que toma valores en $\{(-1)^{k+1}k : k \geq 1\} = \{1, -2, 3, -4, \dots\}$

$$P(X = (-1)^{k+1}k) = \frac{6}{\pi^2} \frac{1}{k^2} \implies E(X) = \sum_{k=1}^{\infty} \frac{(-1)^{k+1}}{k} \text{ que sabemos que tiende a } \ln 2$$

Sin embargo, la serie no converge absolutamente, por tanto, mediante argumentos de reordenación, se puede argumentar que $E(X)$ toma cualquier valor real. Entonces $E(X)$ no tiene sentido.

Teorema 2.2. Sea X una v.a.d. que toma los valores x_j con probabilidades p_j para $j \geq 1$. Sea $g: \mathbb{R} \longrightarrow \mathbb{R}$ una función.

$$\implies E(g(X)) = \sum_{j \geq 1} g(x_j) p_j$$

Demostración. Sabemos que $g(X)$ es una v.a.d. que toma valores en $\{g(x_j) : j \geq 1\}$, donde $|\{g(x_j)\}| \leq |\{x_j\}|$ porque g puede no ser inyectiva.

$$\text{Como } P(g(X) = y) = \sum_{x \in g^{-1}(y)} P(X = x)$$

$$\implies E(g(X)) = \sum_{y \in g(X(\Omega))} y \cdot P(g(X) = y) = \sum_{y \in g(X(\Omega))} y \left(\sum_{x \in g^{-1}(y)} P(X = x) \right)$$

Como $\forall y \in g(X(\Omega)) : \exists |g^{-1}(y)|$ cantidad de $i_s \geq 1 : g(x_i) = y$ se tiene

$$E(g(X)) = \sum_{j \geq 1} g(x_j) p_j$$

■

Observación 2.2.

1. Si X es tal que $P(X = a) = 1 \implies E(X) = a$

2. $X \sim \text{UNIF}(\{-1, 0, 1\}) \wedge Y = X^2 \implies E(X) = 0 \wedge E(Y) = 2/3$

3. $E(aX + b) = aE(X) + b$ porque

$$\sum_{j \geq 1} (ax_j + b)p_j = a \sum_{j \geq 1} x_j p_j + b \sum_{j \geq 1} p_j = aE(X) + b$$

4. En general $E(g(X)) \neq g(E(X))$

(Motivo de excomunión)

Ejemplo 2.7 ($X \sim \text{POISSON}(\lambda) \implies E(X) = \lambda$). Si $Y = g(X) = e^X$

$$\implies E(Y) = E(e^Y) = \sum_{j=0}^{\infty} e^j \frac{\lambda^j}{j!} e^{-\lambda} = e^{-\lambda} \sum_{j=0}^{\infty} \frac{(e\lambda)^j}{j!} = e^{-\lambda} e^{e\lambda} = e^{\lambda(e-1)} \neq e^\lambda$$

21/02/2024

Definición 2.4 (Varianza). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad y X una v.a.d. con función de masa p_X , $V(X)$ es la varianza de X

$$\iff V(X) = E[(X - E(X))^2]$$

Si X toma valores x_1, x_2, \dots con probabilidades p_1, p_2, \dots y denominamos $\mu := E(X)$

$$\implies V(X) = \sum_{j \geq 1} (x_j - \mu)^2 \cdot p_j = \sum_{j \geq 1} (x_j - \mu)^2 \cdot p_j = \sum_{j \geq 1} (x_j^2 - 2x_j\mu + \mu^2) \cdot p_j$$

$$\implies V(X) = \sum_{j \geq 1} x_j^2 p_j - 2 \sum_{j \geq 1} x_j \mu p_j + \sum_{j \geq 1} \mu^2 p_j = E(X^2) - 2\mu^2 + \mu^2$$

$$\implies \boxed{V(X) = E[(X - E(X))^2] = E(X^2) - E(X)^2}$$

Observación 2.3.

1. $V(X)$ es medida de dispersión de X alrededor de $E(X)$.

2. $V(X) \geq 0$

3. $V(X) = 0 \implies P(X = E(X)) = 1$

4. $\boxed{V(aX + b)} = E[(aX + b - E(aX + b))^2] = E[(aX - aE(X))^2] = \boxed{a^2 V(X)}$

5. Las unidades de $V(X)$ son las de X^2

\implies definimos la desviación típica de X como $\boxed{\sigma(X) := \sqrt{V(X)}}$

6. ¿Por qué no $E(|X - E(X)|)$?

Porque el valor absoluto no es diferenciable y no se puede trabajar con él.

Ejemplo 2.8.

1. $X \sim \text{BER}(p) \implies E(X) = p \wedge \boxed{V(X)} = p - p^2 = \boxed{p(1 - p)}$

2. $X \sim \text{UNIF}(\{1, \dots, N\}) \implies E(X) = \frac{N+1}{2} \wedge \boxed{V(X) = \frac{N^2 - 1}{12}}$

$$\implies V(X) = \frac{1}{N} \sum_{j=1}^N j^2 = \frac{1}{N} \cdot \frac{N(N+1)(2N+1)}{6} = \frac{(N+1)(N-1)}{12}$$

$$3. X \sim \text{BIN}(n, p) \implies E(X) = np \wedge \boxed{V(X) = np(1-p)}$$

Demostración. ■

$$4. X \sim \text{GEOM}(p) \implies E(X) = \frac{1}{p} \wedge \boxed{V(X) = \frac{1-p}{p^2}}$$

Demostración. ■

$$5. X \sim \text{POISSON}(\lambda) \implies E(X) = \lambda \wedge \boxed{V(X) = \lambda}$$

Demostración.

$$E(X^2) = \sum_{k=0}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!}$$
■

Definición 2.5 (Momentos de X). Sea X una v.a.d. con función de masa p_X , μ_k es el **k -ésimo momento** de $X \iff \mu_k = E[(X - E(X))^k]$

Observación 2.4. Algunos momentos tienen nombre propio:

1. $\mu_1 = 0$ 2. $\mu_2 = V(X)$ 3. μ_3 es la **asimetría** de X 4. μ_4 es la **curtosis** de X

Teorema 2.3 (Desigualdad de Markov). Sea X una v.a.d. : $P(X < 0) = 0 \wedge E(X) < \infty$
 $\implies \forall t > 0 : P(X \geq t) \leq \frac{E(X)}{t}$

Demostración. Notación: En (Ω, \mathcal{F}, P) , $A \subset \mathcal{F}$ y $\mathbb{1}_A(\omega) = \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \notin A \end{cases}$

Fijamos $t > 0$ y definimos $Y_t(\omega) = t \cdot \mathbb{1}_{\{x \geq t\}}(\omega) = \begin{cases} t & \text{con probabilidad } P(x \geq t) \\ 0 & \text{con probabilidad } 1 - P(x \geq t) \end{cases}$

$$\implies \forall \omega : Y_t(\omega) \leq X(\omega) \implies E(Y_t) = t \cdot P(X \geq t) \leq E(X)$$

Así que $\forall t > 0 : P(X \geq t) \leq \frac{E(X)}{t}$ ■

Teorema 2.4 (Desigualdad de Chebyshev). Sea X una v.a.d. : $E(X), V(X) < \infty$.

$$\implies \forall \lambda > 0 : P(|X - E(X)| \geq \lambda \cdot \sigma(X)) \leq \frac{1}{\lambda^2}$$

$$\iff \forall \alpha > 0 : \boxed{P(|X - E(X)| \geq \alpha) \leq \frac{V(X)}{\alpha^2}}$$

Demostración. Definimos $Y = |X - E(X)|^2$ y aplicamos la desigualdad de Markov.

$$\implies \forall t > 0 : P(Y \geq t) \leq \frac{E(Y)}{t} \implies \forall t > 0 : P(|X - E(X)|^2 \geq t) \leq \frac{E(Y)}{t}$$

Como $E(Y) = E(|X - E(X)|^2) = V(X)$ por la def de varianza,

$$\implies \forall t > 0 : P(|X - E(X)| \geq \sqrt{t}) \leq \frac{V(X)}{t}$$

Definimos $\alpha := \sqrt{t} \implies \forall \alpha > 0 : P(|X - E(X)| \geq \alpha) \leq \frac{V(X)}{\alpha^2}$

y para la desigualdad equivalente definimos $\lambda := \frac{\alpha}{\sigma(X)}$

$$\implies \forall \lambda > 0 : P(|X - E(X)| \geq \lambda \cdot \sigma(X)) \leq \frac{1}{\lambda^2}$$

■

26/02/2024

2.2.1 Esperanza condicionada

Definición 2.6 (Esperanza condicionada). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad $B \in \mathcal{F}$ un suceso tal que $P(B) > 0$ y X una v.a.d. con esperanza $E(X)$, $E(X|B)$ es la **esperanza de X condicionada a B**

$$\iff E(X|B) := \sum_{x \in X(\Omega)} x \cdot P(X = x|B) = \sum_{x \in X(\Omega)} x \cdot \frac{P((X = x) \wedge B)}{P(B)}$$

(Siempre que la serie sea absolutamente convergente).

Teorema 2.5 (Esperanza total). En (Ω, \mathcal{F}, P) , sea X una v.a.d. y $\{B_1, B_2, \dots\}$ una partición de Ω

$$\implies E(X) = \sum_{i \geq 1} E(X|B_i) \cdot P(B_i)$$

(Siempre que la serie sea absolutamente convergente).

Demostración.

$$\begin{aligned} \sum_{i \geq 1} E(X|B_i) \cdot P(B_i) &= \sum_{i \geq 1} \sum_{x \in X(\Omega)} x \cdot P(X = x|B_i) \cdot P(B_i) \\ &= \sum_{x \in X(\Omega)} x \cdot \sum_{i \geq 1} \frac{P((X = x) \wedge B_i)}{P(B_i)} \cdot P(B_i) = \sum_{x \in X(\Omega)} x \cdot P(X = x) \end{aligned}$$

■

Ejemplo 2.9. Lanzamos una moneda con probabilidad p de cara y $1 - p$ de cruz y definimos X como la longitud de la racha inicial, i.e. el número de caras/cruces consecutivas.

$$\begin{aligned} \implies E(X) &= E(X|C) \cdot p + E(X|\times) \cdot (1 - p) \\ \implies E(X) &= \left(\sum_{j \geq 1} j \cdot P(X = j|C) \right) p + \left(\sum_{j \geq 1} j \cdot P(X = j|\times) \right) (1 - p) \end{aligned}$$

$$\begin{aligned}\implies E(X) &= p \sum_{k=1}^{\infty} k p^{k-1} (1-p) + (1-p) \sum_{k=1}^{\infty} k (1-p)^{k-1} p \\ \implies E(X) &= \frac{1}{1-p} \cdot p + \frac{1}{p} \cdot (1-p) = \frac{1}{p(1-p)} - 2\end{aligned}$$

También se puede abordar el problema pensando en las variables geométricas:

$$\begin{aligned}E(X) &= E(X|C) \cdot p + E(X|\times) \cdot (1-p) = \frac{p}{1-p} + \frac{1-p}{p} = \frac{p^2 + (1-p)^2}{p(1-p)} \\ \implies E(X) &= \frac{p^2 + 1 - 2p + p^2}{p(1-p)} = \frac{2p(p-1) + 1}{p(1-p)} = \frac{1}{p(1-p)} - 2\end{aligned}$$

27/02/2024

2.3 Varias variables aleatorias

En (Ω, \mathcal{F}, P) , sea $\mathcal{X} = X_1, X_2, \dots, X_n$ una colección de variables aleatorias discretas.

En el caso $n = 2$, tenemos X e Y variables aleatorias discretas, se genera una tabla con las probabilidades conjuntas:

$$p_{X,Y}(x, y) := P(\omega \in \Omega : X(\omega) = x \wedge Y(\omega) = y) = P(X = x \wedge Y = y)$$

Definición 2.7 (Función de masa conjunta). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., $p_{X,Y}$ es su función de masa conjunta

$$\iff p_{X,Y} : \mathbb{R}^2 \longrightarrow [0, 1] \wedge \forall (x, y) \in X(\Omega) \times Y(\Omega) : p_{X,Y}(x, y) = P(X = x \wedge Y = y)$$

tal que $\sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) = 1$ y $\forall (x, y) \notin X(\Omega) \times Y(\Omega) : p_{X,Y}(x, y) = 0$

Ya tenemos X e Y en (Ω, \mathcal{F}, P) con $P_{X,Y}$

1. ¿Qué sabemos de X e Y por separado?
2. Esperanzas: nos interesa calcular $E(X)$, $E(Y)$, $E(X + Y)$, $E(X \cdot Y)$
3. Independencia

Definición 2.8 (Funciones marginales). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., p_X, p_Y son sus funciones de masa marginales

$$\iff p_X(x) = \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) \quad \wedge \quad p_Y(y) = \sum_{x \in X(\Omega)} p_{X,Y}(x, y)$$

Teorema 2.6. En (Ω, \mathcal{F}, P) , sean X e Y v.a.d. y sea $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ una función

$$\implies E(g(X, Y)) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x, y) \cdot p_{X,Y}(x, y)$$

Si converge absolutamente.

Demostración. Si consideramos la variable aleatoria Z que toma valores en $X(\Omega) \times Y(\Omega)$ con función de masa $p_Z = p_{X,Y}$, entonces $E(g(X, Y)) = E(g(Z))$. Como $X(\Omega) \times Y(\Omega)$ es numerable, podemos renombrar sus elementos como $\{z_1, z_2, \dots\}$ y entonces del teorema 2.2 obtenemos:

$$E(g(X, Y)) = E(g(Z)) = \sum_{j \geq 1} g(z_j) \cdot p_Z(z_j) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x, y) \cdot p_{X,Y}(x, y)$$

■

Observación 2.5. Si $g: \mathbb{R} \rightarrow \mathbb{R}$

$$\begin{aligned} \implies E(g(X)) &= \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x) \cdot p_{X,Y}(x, y) = \sum_{x \in X(\Omega)} \left(g(x) \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) \right) \\ &\implies E(g(X)) = \sum_{x \in X(\Omega)} g(x) p_X(x) \end{aligned}$$

De manera análoga, $E(g(Y)) = \sum_{y \in Y(\Omega)} g(y) p_Y(y)$

Ejemplo 2.10 ($E(aX + bY) = aE(X) + bE(Y)$).

$$\begin{aligned} E(aX + bY) &= \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} (ax + by) \cdot p_{X,Y}(x, y) \\ \implies E(aX + bY) &= a \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} x \cdot p_{X,Y}(x, y) + b \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} y \cdot p_{X,Y}(x, y) \end{aligned}$$

28/02/2024

Definición 2.9 (Independencia de v.a.d.). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., X e Y son independientes

$$\iff \forall (x, y) \in X(\Omega) \times Y(\Omega) : X = x \text{ y } Y = y \text{ son sucesos independientes.}$$

$$\iff \forall (x, y) \in X(\Omega) \times Y(\Omega) : P(X = x \wedge Y = y) = P(X = x) \cdot P(Y = y)$$

Teorema 2.7. En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., X e Y son independientes

$$\iff \exists g, h: \mathbb{R} \rightarrow \mathbb{R} : p_{X,Y}(x, y) = g(x) \cdot h(y)$$

Demostración. (\implies) Trivial: $g(x) = p_X(x) \wedge h(y) = p_Y(y)$.

(\impliedby) Suponemos que $\exists g, h: \mathbb{R} \longrightarrow \mathbb{R} : p_{X,Y}(x, y) = g(x) \cdot h(y)$, veamos las funciones marginales.

$$\implies p_X(x) = \sum_{y \in Y(\Omega)} p_{X,Y}(x, y) = \sum_{y \in Y(\Omega)} g(x) \cdot h(y) = g(x) \sum_{y \in Y(\Omega)} h(y)$$

$$\text{Análogamente } p_Y(y) = h(y) \sum_{x \in X(\Omega)} g(x)$$

$$\implies p_X(x) \cdot p_Y(y) = \left(g(x) \sum_{z \in Y(\Omega)} h(z) \right) \left(h(y) \sum_{w \in X(\Omega)} g(w) \right)$$

$$\implies p_X(x) \cdot p_Y(y) = g(x) \cdot h(y) \sum_{z \in Y(\Omega)} \sum_{w \in X(\Omega)} g(w) \cdot h(z) = g(x) \cdot h(y) = p_{X,Y}(x, y)$$

$$\forall (x, y) \in X(\Omega) \times Y(\Omega) : P(X = x \wedge Y = y) = p_X(x) \cdot p_Y(y) = P(X = x) \cdot P(Y = y)$$

■

Ejemplo 2.11. Sean X e Y dos v.a.d. tales que

$$p_{X,Y}(x, y) = e^{-(\lambda+\mu)} \frac{\lambda^x \mu^y}{x!y!} \text{ con } x, y \in \mathbb{Z} \text{ y } \lambda, \mu > 0$$

\implies Se puede interpretar como $X \sim \text{POISSON}(\lambda)$ e $Y \sim \text{POISSON}(\mu)$ independientes.

Observación 2.6. Si X e Y son independientes $\implies E(X \cdot Y) = E(X) \cdot E(Y)$.

Sin embargo, la implicación recíproca no es cierta.

(Motivo de excomuni3n)

Definici3n 2.10 (Covarianza). En (Ω, \mathcal{F}, P) , sean X e Y v.a.d., $\text{cov}(X, Y)$ es la covarianza de X e Y

$$\iff \boxed{\text{cov}(X, Y) = E[(X - E(X)) \cdot (Y - E(Y))] = E(X \cdot Y) - E(X) \cdot E(Y)}$$

29/02/2024

Observaci3n 2.7.


1. C3lculo de la covarianza

$$\text{cov}(X, Y) = \sum_{i,j} x_i y_j P(X = x_i \wedge Y = y_j) - \left(\sum_i x_i P(X = x_i) \right) \left(\sum_j y_j P(Y = y_j) \right)$$

2. Signo de la covarianza (y coeficiente de correlaci3n)

$$\text{cov}(X, Y) = \sum_{i,j} (x_i - E(X))(y_j - E(Y)) P(X = x_i \wedge Y = y_j)$$

Entonces, si la covarianza es positiva, X e Y tienden a crecer juntas. Si es negativa, tienden a decrecer juntas. Si es 0, no hay relación lineal entre X e Y .



3. Cálculo fundamental

$$\begin{aligned}
 V(X + Y) &= E((X + Y)^2) - (E(X + Y))^2 \\
 &= E(X^2 + 2XY + Y^2) - (E(X) + E(Y))^2 \\
 &= E(X^2) + 2E(XY) + E(Y^2) - (E(X))^2 - 2E(Y)E(X) - (E(Y))^2 \\
 &\implies \boxed{V(X + Y) = V(X) + V(Y) + 2\text{cov}(X, Y)}
 \end{aligned}$$

Pero cuidado: $V(X - Y) = V(X) + V(Y) - 2\text{cov}(X, Y)$

De forma más general:

$$\begin{aligned}
 V(aX + bY) &= V(aX) + V(bY) + 2\text{cov}(aX, bY) \\
 &= a^2V(X) + b^2V(Y) + 2ab\text{cov}(X, Y) \\
 &\implies \boxed{V(aX + bY) = a^2V(X) + b^2V(Y) + 2ab\text{cov}(X, Y)}
 \end{aligned}$$

4. Si X e Y son independientes $\implies \text{cov}(X, Y) = 0$

Definición 2.11 (coeficiente de correlación). Sean X e Y dos v.a.d., ρ es su coeficiente de correlación $\iff \rho := \frac{\text{cov}(X, Y)}{\sqrt{V(X) \cdot V(Y)}} \implies \rho$ no tiene unidades y $|\rho(X, Y)| \leq 1$.

Proposición 2.2 (Desigualdad de Cauchy-Schwarz). Sean X e Y dos v.a.d.

$$\implies E(X \cdot Y)^2 \leq E(X^2) \cdot E(Y^2)$$

La igualdad se da cuando una variable es transformación lineal de la otra, i.e. $Y = aX + b$.

Demostración. Definimos $W = sX + Y$, $W^2 \geq 0$ con probabilidad 1.

$$\begin{aligned}
 \implies 0 &\leq E(W^2) = E((sX + Y)^2) = E(s^2X^2 + Y^2 + 2sXY) \\
 &= s^2E(X^2) + E(Y^2) + 2sE(XY) \\
 &= E(X^2) \cdot s^2 + 2E(XY) \cdot s + E(Y^2)
 \end{aligned}$$

Vemos que el resultado es una parábola si se toma como función de s .

Como $\forall s \in \mathbb{R} : E(X) \geq 0$ y $E(X^2) \geq 0$, sabemos que la parábola o bien toca el eje X una única vez, o no lo hace nunca. Esto es equivalente a pedir que el valor del discriminante

sea menor o igual que 0.

$$4E(XY)^2 - 4E(X^2)E(Y^2) \leq 0 \implies E(XY)^2 \leq E(X^2)E(Y^2)$$

■

Por tanto, $\overline{\text{cov}(X, Y)^2} = E((X - E(X))(Y - E(Y)))^2 \leq \overline{V(X) \cdot V(Y) \cdot \text{cov}(X, Y)}$

Además $\rho(aX + b, cY + d) = \text{sgn}(ac) \cdot \rho(X, Y)$.

04/03/2024

2.3.1 Detalle sobre independencia

Teorema 2.8. Sean X e Y dos v.a.d. en (Ω, \mathcal{F}, P) y $g, h: \mathbb{R} \rightarrow \mathbb{R}$ dos funciones

$$X \text{ e } Y \text{ independientes} \iff E(g(X) \cdot h(Y)) = E(g(X)) \cdot E(h(Y))$$

Demostración. (\implies) $E(g(X) \cdot h(Y)) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x) \cdot h(y) \cdot P(X = x \wedge Y = y)$

Como X e Y son independientes, $P(X = x \wedge Y = y) = P(X = x) \cdot P(Y = y)$, entonces

$$E(g(X) \cdot h(Y)) = \left(\sum_{x \in X(\Omega)} g(x) P(X = x) \right) \left(\sum_{y \in Y(\Omega)} h(y) P(Y = y) \right) = E(g(X)) \cdot E(h(Y))$$

(\impliedby) Sean $\hat{x}, \hat{y} \in \mathbb{R}$, queremos probar que $P(X = \hat{x} \wedge Y = \hat{y}) = P(X = \hat{x}) \cdot P(Y = \hat{y})$

$$\text{Definimos } g(x) := \begin{cases} 1 & \text{si } x = \hat{x} \\ 0 & \text{si } x \neq \hat{x} \end{cases} \quad \wedge \quad h(y) := \begin{cases} 1 & \text{si } y = \hat{y} \\ 0 & \text{si } y \neq \hat{y} \end{cases}$$

$$\implies E(g(X) \cdot h(Y)) = \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x) h(y) P(X = \hat{x} \wedge Y = \hat{y}) = P(X = \hat{x} \wedge Y = \hat{y})$$

Como $E(g(X)) = P(X = \hat{x})$ y $E(h(Y)) = P(Y = \hat{y})$ y $E(g(X)h(Y)) = E(g(X))E(h(Y))$

$$\overline{P(X = \hat{x} \wedge Y = \hat{y})} = E(g(X) \cdot h(Y)) = E(g(X)) \cdot E(h(Y)) = \overline{P(X = \hat{x}) \cdot P(Y = \hat{y})}$$

■

¿Qué pasaría con (X_1, \dots, X_n) para $n = 2$?

1. Modelo \rightarrow función de masa conjunta $p_{X_1, \dots, X_n}(x_1, \dots, x_n)$

$$\begin{cases} \sum_{x_1 \in X_1(\Omega)} \cdots \sum_{x_n \in X_n(\Omega)} p_{X_1, \dots, X_n}(x_1, \dots, x_n) = 1 \\ p_{X_1, \dots, X_n}(x_1, \dots, x_n) \geq 0 \end{cases}$$

2. Marginales $p_{X_1}(x_1) = \sum_{x_2 \in X_2(\Omega)} \cdots \sum_{x_n \in X_n(\Omega)} p_{X_1, \dots, X_n}(x_1, \dots, x_n)$

3. Independencia (la función de masa conjunta se factoriza)

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = p_{X_1}(x_1) \cdots p_{X_n}(x_n) \iff \text{independencia completa}$$

Pero puede haber otras nociones de independencia (ej: 2 a 2).

4. **Matriz varianzas-covarianzas y matriz correlaciones** respectivamente

$$V = \begin{pmatrix} V(X_1) & \cdots & \text{cov}(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \cdots & V(X_n) \end{pmatrix} \wedge \Sigma = \begin{pmatrix} 1 & \cdots & \rho(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \rho(X_n, X_1) & \cdots & 1 \end{pmatrix}$$

Ambas son simétricas y definidas positivas.

Ejemplo 2.12. Queremos modelizar experimentos del tipo lanzar 18 veces un dado y sumar los resultados obtenidos.

$$S_n = X_1 + \cdots + X_n \implies \begin{cases} E(S_n) = \sum_{i=1}^n E(X_i) \\ V(S_n) = \sum_{i=1}^n V(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j) \end{cases}$$

Si suponemos las X_i independientes e idénticas $\implies \forall i \in \mathbb{N}_n : E(X_i) =: \mu \wedge V(X_i) =: \sigma^2$

$$\implies E(S_n) = n\mu \wedge V(S_n) = n\sigma^2$$

Si definimos $Z_n := \frac{1}{n}S_n = \frac{1}{n}(X_1 + \cdots + X_n) \implies E(Z_n) = \mu \wedge V(Z_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$
 $\implies Z_n$ no es aleatoria si $n \rightarrow \infty$ (ley de los grandes números)

05/03/2024

2.4 Funciones generatrices de probabilidad

2.4.1 Series de potencias

Sea $(a_n)_{n=0}^\infty$ una sucesión y $f(x) := \sum_{n=0}^\infty a_n x^n$ una función, ¿en qué valores de x está definida?

Sabemos que existe $R \in [0, \infty)$ radio de convergencia tal que

$$\sum_{n=0}^\infty a_n x^n \rightarrow \begin{cases} \text{converge} & \text{si } |x| < R \\ \text{diverge} & \text{si } |x| > R \end{cases} \iff \frac{1}{R} = \limsup_{n \rightarrow \infty} |a_n|^{1/n}$$

Ejemplo 2.13.

$$\sum_{n=0}^\infty \frac{x^n}{n!} = e^x \quad \wedge \quad \sum_{n=0}^\infty x^n = \frac{1}{1-x}, |x| < 1 \quad \wedge \quad \sum_{n=0}^m \binom{m}{n} x^n = (1+x)^m$$

2.4.2 Funciones generatrices

$$(a_n)_{n=0}^{\infty} \longleftrightarrow f(x) = \sum_{n=0}^{\infty} a_n x^n \implies \begin{cases} x \cdot f(x) \longleftrightarrow (0, a_0, \dots) \\ x \cdot f'(x) \longleftrightarrow (0a_0, 1a_1, 2a_2, \dots) \end{cases}$$

$$f(x) \cdot g(x) = \sum_{n=0}^{\infty} a_n x^n \sum_{n=0}^{\infty} b_n x^n = \sum_{n=0}^{\infty} \left(\sum_{k=0}^n a_k b_{n-k} \right) x^n$$

Definición 2.12 (Función generatriz de probabilidad). Sea X una variable aleatoria discreta que toma valores en $\{0, 1, 2, \dots\}$ donde $\forall j \geq 0 : p_j = P(X = j)$, $G_X(s)$ es su función

generatriz de probabilidad $\iff \boxed{G_X(s) = \sum_{n=0}^{\infty} p_n s^n}$

Ejemplo 2.14.

1. $X \sim \text{BER}(p) \implies G_X(s) = (1-p) + ps$

2. $X \sim \text{BIN}(n, p) \implies G_X(s) = \sum_{j=1}^n \binom{n}{j} (1-p)^{n-j} (ps)^j = (1-p + ps)^n$

3. $X \sim \text{GEOM}(p) \implies G_X(s) = \sum_{j=1}^{\infty} (1-p)^{j-1} ps^j = \frac{ps}{1 - (1-p)s}$

Demostración.

$$G_X(s) = \sum_{j=1}^{\infty} (1-p)^{j-1} ps^j = p \sum_{k=0}^{\infty} (1-p)^k s^{k+1} = ps \sum_{k=0}^{\infty} ((1-p)s)^k = \frac{ps}{1 - (1-p)s}$$

■

4. $X \sim \text{POISSON}(\lambda) \implies G_X(s) = \sum_{j=0}^{\infty} e^{-\lambda} \frac{\lambda^j}{j!} s^j = e^{\lambda(s-1)}$

Demostración. $G_X(s) = \sum_{j=0}^{\infty} e^{-\lambda} \frac{\lambda^j}{j!} s^j = e^{-\lambda} \sum_{j=0}^{\infty} \frac{(\lambda s)^j}{j!} = e^{-\lambda} e^{\lambda s} = e^{\lambda(s-1)}$

■

¿Para qué?

1. Cálculo de momentos con $(p_n)_{n=0}^{\infty}$

$$G_X(s) = \sum_{n=0}^{\infty} p_n s^n \implies G'_X(s) = \sum_{n=1}^{\infty} n p_n s^{n-1} \implies G'_X(1) = \sum_{n=1}^{\infty} n p_n = E(X)$$

Si seguimos derivando, obtenemos

$$\implies G''_X(s) = \sum_{n=2}^{\infty} n(n-1) p_n s^{n-2} = \sum_{n=2}^{\infty} n^2 p_n s^{n-2} - \sum_{n=2}^{\infty} n p_n s^{n-2}$$

$$\begin{aligned} \implies G_X''(1) &= \sum_{n=2}^{\infty} n^2 p_n - \sum_{n=2}^{\infty} n p_n = E(X^2) - E(X) \\ \implies V(X) &= E(X^2) - E(X)^2 = G_X''(1) + G_X'(1)(1 - G_X'(1)) \end{aligned}$$

Ejemplo 2.15.

$$\begin{aligned} \text{(a) } X \sim \text{BER}(p) &\implies G_X(s) = (1 - p) + ps \\ &\implies G_X'(s) = p = E(X) \wedge G_X''(s) = 0 \implies V(X) = p(1 - p) \\ \text{(b) } X \sim \text{BIN}(n, p) &\implies G_X(s) = (1 - p + ps)^n \\ &\implies G_X'(s) = n(1 - p + ps)^{n-1}p \implies G_X'(1) = np = E(X) \\ &\implies G_X''(s) = n(n-1)(\dots)^{n-2}p^2 \implies G_X''(1) = n(n-1)p^2 \\ &\implies V(X) = n(n-1)p^2 + np(1 - np) = np(1 - p) \end{aligned}$$

2. Suma de independientes

Teorema 2.9. Sean X, Y dos v.a.d. independientes con valores en $\{0, 1, 2, \dots\}$ y con funciones generatrices de probabilidad $G_X(s), G_Y(s)$ respectivamente

$$\implies G_{X+Y}(s) = G_X(s) \cdot G_Y(s)$$

Demostración.

$$G_{X+Y}(s) = \sum_{n=0}^{\infty} P(X + Y = n) s^n = \sum_{n=0}^{\infty} \left(\sum_{k=0}^n P(X = k \wedge Y = n - k) \right) s^n$$

Por otro lado,

$$\begin{aligned} G_X(s) \cdot G_Y(s) &= \left(\sum_{n=0}^{\infty} P(X = n) s^n \right) \left(\sum_{n=0}^{\infty} P(Y = n) s^n \right) \\ &= \sum_{n=0}^{\infty} \left(\sum_{k=0}^n P(X = k) P(Y = n - k) \right) s^n \implies G_{X+Y}(s) = G_X(s) \cdot G_Y(s) \end{aligned}$$

■

Otra manera:

$$G_X(s) = E(s^X) \wedge G_{X+Y}(s) = E(s^{X+Y}) = E(s^X \cdot s^Y) = E(s^X) \cdot E(s^Y) = G_X(s) \cdot G_Y(s)$$

■

Corolario 2.1. Sean X_1, X_2, \dots, X_n v.a.d. independientes con valores en $\{0, 1, 2, \dots\}$ y con

funciones generatrices de probabilidad $G_{X_1}(s), G_{X_2}(s), \dots, G_{X_n}(s)$ respectivamente

$$\implies G_{X_1+X_2+\dots+X_n}(s) = \prod_{i=1}^n G_{X_i}(s)$$

Si las X_i son “idénticas” $\implies G_{X_1+X_2+\dots+X_n}(s) = (G_{X_1}(s))^n$

06/03/2024

Teorema 2.10 (Unicidad). Sean X, Y dos v.a.d. con valores en $\{0, 1, 2, \dots\}$ y con funciones generatrices de probabilidad $G_X(s), G_Y(s)$ respectivamente

$$\implies G_X(s) = G_Y(s) \iff \forall n \geq 0 : P(X = n) = P(Y = n)$$

Ejemplo 2.16. Sean $X \sim \text{POISSON}(\lambda) \wedge Y \sim \text{POISSON}(\mu)$ independientes con $\lambda, \mu > 0$. Definimos $Z = X + Y$.

$$\implies \forall x \geq 0 : P(Z = k) = P(X + Y = k) = \sum_{j=0}^k P(X = j \wedge Y = k - j) = \dots$$

Pero, a través de funciones generatrices obtenemos:

$$G_X(s) = e^{\lambda(s-1)} \wedge G_Y(s) = e^{\mu(s-1)} \implies G_Z(s) = e^{(\lambda+\mu)(s-1)} \implies Z \sim \text{POISSON}(\lambda + \mu)$$

Ejemplo 2.17.

1. Sean I_1, I_2, \dots, I_n v.a.d. independientes con $\forall k \in \mathbb{N}_n : I_k \sim \text{BER}(p)$ y definimos $Z = I_1 + I_2 + \dots + I_n$.

$$\implies G_Z(s) = [(1-p) + ps]^n \implies Z \sim \text{BIN}(n, p)$$

2. Sean $X \sim \text{BIN}(n, p) \wedge Y \sim \text{POISSON}(\lambda)$ independientes y definimos $Z = X + Y$.

$$\implies G_Z(s) = ((1-p) + ps)^n \cdot e^{\lambda(s-1)}$$

3 Variables aleatorias continuas

Hasta ahora en (Ω, \mathcal{F}, P) , una variable aleatoria X discreta era una función $X: \Omega \rightarrow \mathbb{R}$ tal que $\exists N \subseteq \mathbb{N} : |X(\Omega)| = |N|$ y $P(X = k) = P(X^{-1}(k))$.

Definición 3.1 (Variable aleatoria). Sea (Ω, \mathcal{F}, P) un espacio de probabilidad, la función $X: \Omega \rightarrow \mathbb{R}$ es una variable aleatoria $\iff \forall x \in \mathbb{R} : \{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}$

Proposición 3.1. X es v.a.d. $\implies X$ es variable aleatoria.

Demostración. Puedo describir el suceso $\{X \leq x\}$ como unión numerable de sucesos

$$\{\omega \in \Omega : X(\omega) \leq x\} = \bigcup_{y \in X(\Omega)} \{\omega \in \Omega : X(\omega) = y\}$$

Como la unión numerable de sucesos es un suceso, $\{X \leq x\} \in \mathcal{F}$. ■

Definición 3.2 (Función de distribución). Sea X una variable aleatoria, $F_X: \mathbb{R} \rightarrow [0, 1]$ es su función de distribución $\iff \forall x \in X(\Omega) : \boxed{F_X(x) = P(X \leq x)}$

Sea X una v.a.d. que toma los valores x_1, x_2, \dots con probabilidades p_1, p_2, \dots y con función de masa $p_X \implies F_X(x) = \sum_{x_i \leq x} P(X = x_i)$. Es decir, es la función de masa acumulada.

Lema 3.1. En (Ω, \mathcal{F}, P) , sea X una variable aleatoria con función de distribución F_X .

1. $\lim_{x \rightarrow \infty} F_X(x) = 1 \wedge \lim_{x \rightarrow -\infty} F_X(x) = 0$
- \implies 2. F_X es no decreciente
3. F_X es continua por la derecha

Demostración.

1. Definimos $A_n := \{\omega \in \Omega : X(\omega) \leq n\}$ que es creciente según $n \rightarrow \infty$.

$$\implies \lim_{n \rightarrow \infty} F_X(n) = \lim_{n \rightarrow \infty} P(X \leq n) = \lim_{n \rightarrow \infty} P\left(\bigcup_{j=1}^n A_j\right) = P\left(\bigcup_{n=1}^{\infty} A_n\right) = P(\Omega) = 1$$

2. $x < y \implies \{X \leq x\} \subseteq \{X \leq y\} \implies F_X(x) \leq F_X(y)$.

3. Definimos $A_h := \{\omega \in \Omega : X(\omega) \leq x + h\}$.

$$\implies \lim_{h \rightarrow 0^+} F_X(x + h) = \lim_{h \rightarrow 0^+} P(A_h) = P\left(\lim_{h \rightarrow 0^+} A_h\right) = P(A_0) = P(X \leq x) = F_X(x)$$

■

Teorema 3.1. Sea $F: U \subset \mathbb{R} \rightarrow [0, 1]$ una función que cumpla los puntos del lema anterior.

$$\implies \exists! X \text{ variable aleatoria} : F_X = F$$

Demostración. Suponemos que $\exists X, Y: \Omega \rightarrow \mathbb{R}$ v.a. tales que $F_X = F = F_Y$.

$$\implies \forall x \in X(\Omega) = U = Y(\Omega) : P(X \leq x) = F_X(x) = F(x) = F_Y(x) = P(Y \leq x)$$

Por tanto, $\forall x \in U : P(X \leq x) = P(Y \leq x) \implies X = Y$. ■

Moraleja: Una variable aleatoria queda determinada por su función de distribución.

13/03/2024

Sea X una variable aleatoria con función de distribución F_X y $a, b \in \mathbb{R}$.

$$\implies P(a < X \leq b) = P(\{x \leq b\} \setminus \{x \leq a\}) = P(x \leq b) - P(x \leq a) = F_X(b) - F_X(a)$$

Definición 3.3 (Variable aleatoria continua). Sea X una variable aleatoria con función de distribución F_X , X es continua (v.a.c.)

$$\iff \exists f_X: \mathbb{R} \rightarrow \mathbb{R} \geq 0 : \left(F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(y) dy \right) \wedge \left(\int_{-\infty}^{\infty} f_X(y) dy = 1 \right)$$

f_X se denomina la **función de densidad** de X .

Observación 3.1.

$$1. \forall a \in \mathbb{R} : P(X = a) = 0$$

Demostración. Por continuidad de la probabilidad:

$$\begin{aligned} \overline{P(X = a)} &= \lim_{h \rightarrow 0^+} P(a - h < X \leq a + h) = \lim_{h \rightarrow 0^+} F_X(a + h) - F_X(a - h) \\ &= \lim_{h \rightarrow 0^+} \left(\int_{-\infty}^a f_X(y) dy - \int_{-\infty}^{a-h} f_X(y) dy \right) = \lim_{h \rightarrow 0^+} \int_{a-h}^{a+h} f_X(y) dy = \overline{0} \end{aligned}$$
■

$$2. \text{ Cálculo de probabilidades: } \forall a \leq b : P(a \leq X \leq b) = \int_a^b f_X(y) dy$$

$$3. \forall x \in \mathbb{R} : f_X(x) = \begin{cases} \frac{d}{dx} F_X(x), & \text{si } F_X \text{ es derivable en } x \\ 0, & \text{en otro caso} \end{cases}$$

Ejemplo 3.1.

$$1. \text{ Para cualquier } f \geq 0 \text{ tal que } \int_{-\infty}^{\infty} f(x) dx = c \in \mathbb{R} \text{ tenemos una v.a.c.}$$

$$2. X \sim U(0, 1) \iff f_X(u) = \begin{cases} 1, & \text{si } u \in [0, 1] \\ 0, & \text{en otro caso} \end{cases} \implies F_X(u) = \begin{cases} 0, & \text{si } u < 0 \\ u, & \text{si } u \in [0, 1] \\ 1, & \text{si } u > 1 \end{cases}$$

$$3. X \sim \text{EXP}(\lambda) \iff f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{si } x \geq 0 \\ 0, & \text{en otro caso} \end{cases} = \lambda e^{-\lambda x} \cdot \mathbb{1}_{\{x \geq 0\}}(x) \\ \implies \forall x > 0 : F_X(x) = \int_0^x \lambda e^{-\lambda y} dy = [-e^{-\lambda y}]_0^x = 1 - e^{-\lambda x} \implies \lim_{x \rightarrow \infty} F_X(x) = 1$$

$$4. X \sim N(\mu, \sigma^2) \iff f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\text{La guay es } X \sim N(0, 1) \iff \phi(x) := \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}. \text{ Veamos que } \int_{-\infty}^{\infty} \phi(x) dx = 1.$$

Demostración.

$$I := \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \implies I^2 = \left(\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \right) \left(\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy \right) \\ \implies I^2 = \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(x^2+y^2)} dx dy = \frac{1}{2\pi} \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}} r dr d\theta \\ = \frac{1}{2\pi} \int_0^{2\pi} [-e^{-\frac{r^2}{2}}]_0^{\infty} d\theta = \frac{1}{2\pi} \int_0^{2\pi} 1 d\theta = 1$$

■

18/03/2024

3.1 Funciones / Transformaciones de v.a.c.

Sea X una v.a.c. con función de densidad f_X y $g: X(\Omega) \rightarrow \mathbb{R}$ una función real y $Y := g(X)$:

- Y es variable aleatoria $\iff \forall y \in \mathbb{R} : \{\omega \in \Omega : g(X(\omega)) \leq y\} \in \mathcal{F}$.
Esto es cierto para las g “habituales” (continuas, monótonas, etc.), para más detalle, hay que esperar a teoría de la medida.
- ¡Cuidado! Y puede no ser continua.
- Y v.a. $\implies Y$ tiene función de distribución $F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = ???$

Ejemplo 3.2. $g(x) = ax + b$ con $a \neq 0 \wedge b \in \mathbb{R}$.

$$\implies F_Y(y) = P(aX + b \leq y) = \begin{cases} P(X \leq \frac{y-b}{a}), & \text{si } a > 0 \\ P(X \geq \frac{y-b}{a}) = 1 - P(X < \frac{y-b}{a}), & \text{si } a < 0 \end{cases}$$

$$\text{Para } X \text{ v.a. continua, } F_Y(y) = \begin{cases} F_X\left(\frac{y-b}{a}\right), & \text{si } a > 0 \\ 1 - F_X\left(\frac{y-b}{a}\right) & \text{si } a < 0 \end{cases}.$$

$$\implies f_Y(y) = \frac{d}{dy} F_Y(y) = \begin{cases} \frac{1}{a} f_X\left(\frac{y-b}{a}\right), & \text{si } a > 0 \\ -\frac{1}{a} f_X\left(\frac{y-b}{a}\right), & \text{si } a < 0 \end{cases} = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$$

Teorema 3.2. En (Ω, \mathcal{F}, P) , sea X una v.a.c. con función de densidad f_X y $g: \mathbb{R} \rightarrow \mathbb{R}$ una función diferenciable y estrictamente creciente.

$$\implies f_Y(y) = f_X(g^{-1}(y)) \frac{1}{g'(g^{-1}(y))}$$

De manera similar, si g es estrictamente decreciente $\implies f_Y(y) = -f_X(g^{-1}(y)) \frac{1}{g'(g^{-1}(y))}$

Demostración.

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = P(X \leq g^{-1}(y)) = F_X(g^{-1}(y))$$

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy} F_X(g^{-1}(y)) = f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y) = f_X(g^{-1}(y)) \frac{1}{g'(g^{-1}(y))}$$

En el caso de g decreciente tenemos:

$$F_Y(y) = P(g(X) \leq y) = P(X \geq g^{-1}(y)) = 1 - P(X \leq g^{-1}(y)) = 1 - F_X(g^{-1}(y))$$

$$f_Y(y) = -\frac{d}{dy} F_X(g^{-1}(y)) = -f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y) = -f_X(g^{-1}(y)) \frac{1}{g'(g^{-1}(y))}$$

■

20/03/2024

Ejercicio 3.1.1. Sea X una variable aleatoria con función de densidad $f_X(x)$ y $Y = g(X)$ con $g(x) = x^2$. ¿Cuál es la función de densidad de Y ?

$$F_Y(y) = P(X^2 \leq y) = \begin{cases} y < 0 \implies 0 \\ y \geq 0 \implies P(-\sqrt{y} \leq X \leq \sqrt{y}) = F_X(\sqrt{y}) - F_X(-\sqrt{y}) \end{cases}$$

$$\implies f_Y(y) = \begin{cases} y \leq 0 \implies 0 \\ y > 0 \implies \frac{d}{dy} F_X(\sqrt{y}) - \frac{d}{dy} F_X(-\sqrt{y}) = \frac{1}{2\sqrt{y}} f_X(\sqrt{y}) + \frac{1}{2\sqrt{y}} f_X(-\sqrt{y}) \end{cases}$$

Ejemplo 3.3. Sea $X \sim N(\mu, \sigma^2) \implies \forall x \in \mathbb{R} : f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ e $Y = e^X$ (se denomina lognormal). Calculamos la derivada y la inversa de $g(x) = e^x$.

$$\implies g'(x) = e^x \quad \wedge \quad g^{-1}(y) = \ln y \quad \wedge \quad \frac{d}{dy} g^{-1}(y) = \frac{1}{y}$$

Como g es estrictamente creciente, aplicamos el teorema anterior:

$$f_Y(y) = \begin{cases} 0, & \text{si } y \leq 0 \\ \frac{1}{\sqrt{2\pi}\sigma} \frac{1}{y} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}, & \text{si } y > 0 \end{cases}$$

Ejemplo 3.4. Sea $X \sim \text{EXP}(\lambda)$, $\lambda > 0$ y $Y = 3X + 2$. Calculamos la función de densidad de Y .

$$g'(x) = 3 \quad \wedge \quad \frac{d}{dy} g^{-1}(y) = \frac{d}{dy} \left(\frac{y-2}{3} \right) = \frac{1}{3}$$

Como g es estrictamente creciente, aplicamos el teorema anterior:

$$f_Y(y) = f_X \left(\frac{y-2}{3} \right) \cdot \frac{1}{3} = \begin{cases} 0, & \text{si } y < 2 \\ \frac{1}{3} \lambda e^{-\lambda \frac{y-2}{3}}, & \text{si } y \geq 2 \end{cases}$$

3.2 Esperanzas de v.a.c.

Definición 3.4 (Esperanza). Sea X una v.a.c. con función de densidad f_X . $E(X)$ es la esperanza de $X \iff \boxed{E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx}$

Siempre que haya convergencia absoluta $\left(\iff \int_{-\infty}^{\infty} |x| \cdot f_X(x) dx < \infty \right)$.

Teorema 3.3. Sea X una v.a.c. con función de densidad f_X y $g: \mathbb{R} \rightarrow \mathbb{R}$ una función diferenciable y estrictamente creciente $\implies E(g(X)) = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$

Demostración.

$$E(g(X)) = \int_{-\infty}^{\infty} y \cdot f_Y(y) dy = \int_{-\infty}^{\infty} y \cdot f_X(g^{-1}(y)) \frac{1}{g'(g^{-1}(y))} dy$$

Por el cambio de variable $y = g(x) \implies g^{-1}(y) = x \wedge dy = g'(x) dx$.

$$\implies E(g(X)) = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) \frac{1}{g'(x)} \cdot g'(x) dx = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$$

■

Ejemplo 3.5.

1. Sea $X \sim \text{UNIF}(a, b)$, entonces $f_X(x) = \frac{1}{b-a} \cdot \mathbb{1}_{[a,b]}(x)$.

$$\implies \boxed{E(X)} = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \boxed{\frac{a+b}{2}}$$

$$\begin{aligned}
\Rightarrow \overline{V(X)} &= E(X^2) - E(X)^2 = \int_a^b x^2 \cdot \frac{1}{b-a} dx - \left(\frac{a+b}{2}\right)^2 = \frac{1}{b-a} \left[\frac{x^3}{3}\right]_a^b - \left(\frac{a+b}{2}\right)^2 \\
&= \frac{b^3 - a^3}{3(b-a)} - \left(\frac{a+b}{2}\right)^2 = \frac{b^2 + ab + a^2}{3} - \frac{a^2 + 2ab + b^2}{4} \\
&= \frac{4b^2 - 4ab + 4a^2 - 3a^2 - 6ab - 3b^2}{12} = \frac{b^2 - 2ab + a^2}{12} = \overline{\frac{(b-a)^2}{12}}
\end{aligned}$$

2. Sea $X \sim \text{EXP}(\lambda)$, $\lambda > 0$, entonces $f_X(x) = \lambda e^{-\lambda x} \cdot \mathbb{1}_{[0, \infty)}(x)$.

$$\begin{aligned}
\Rightarrow \overline{E(X)} &= \int_0^\infty x \cdot \lambda e^{-\lambda x} dx = [-x e^{-\lambda x}]_0^\infty + \int_0^\infty e^{-\lambda x} dx = 0 + \left[-\frac{1}{\lambda} e^{-\lambda x}\right]_0^\infty = \overline{\frac{1}{\lambda}} \\
\Rightarrow \overline{V(X)} &= E(X^2) - E(X)^2 = \int_0^\infty x^2 \cdot \lambda e^{-\lambda x} dx - \left(\frac{1}{\lambda}\right)^2 = \overline{\frac{1}{\lambda^2}} \text{ porque} \\
&\int_0^\infty x^2 \cdot \lambda e^{-\lambda x} dx = [-x^2 e^{-\lambda x}]_0^\infty + 2 \int_0^\infty x e^{-\lambda x} dx = 0 + 2 \cdot \frac{1}{\lambda^2} = \frac{2}{\lambda^2}
\end{aligned}$$

3. Sea $X \sim N(0, 1)$, entonces $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$.

$$\begin{aligned}
\overline{E(X)} &= \int_{-\infty}^\infty x \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \overline{0} \text{ (integrando impar en regi3n centrada en el origen).} \\
\overline{V(X)} &= E(X^2) - E(X)^2 = \int_{-\infty}^\infty x^2 \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty x^2 \cdot e^{-\frac{x^2}{2}} dx \\
&= \frac{1}{\sqrt{2\pi}} \left(\left[-x e^{-\frac{x^2}{2}}\right]_{-\infty}^\infty + \int_{-\infty}^\infty e^{-\frac{x^2}{2}} dx \right) = \frac{1}{\sqrt{2\pi}} (0 + \sqrt{2\pi}) = \overline{1}
\end{aligned}$$

4. Sea $X \sim N(\mu, \sigma^2)$, entonces $f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$.

$$E(X) = \int_{-\infty}^\infty x \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^\infty x \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Con el cambio de variable $t = \frac{x-\mu}{\sigma} \Rightarrow x = \sigma t + \mu \wedge dx = \sigma dt$.

$$\begin{aligned}
\Rightarrow \overline{E(X)} &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^\infty (\sigma t + \mu) e^{-\frac{t^2}{2}} \sigma dt = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^\infty (\sigma t + \mu) e^{-\frac{t^2}{2}} dt \\
&= \frac{1}{\sqrt{2\pi}} \left(\sigma \int_{-\infty}^\infty t e^{-\frac{t^2}{2}} dt + \mu \int_{-\infty}^\infty e^{-\frac{t^2}{2}} dt \right) = \frac{1}{\sqrt{2\pi}} (0 + \mu \sqrt{2\pi}) = \overline{\mu} \\
\Rightarrow V(X) &= E[(X - E(X))^2] = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^\infty (x - \mu)^2 e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx
\end{aligned}$$

Con el cambio de variable $t = \frac{x-\mu}{\sigma} \Rightarrow x = \sigma t + \mu \wedge dx = \sigma dt$.

$$V(X) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^\infty (\sigma t)^2 e^{-\frac{t^2}{2}} \sigma dt = \frac{\sigma^2}{\sqrt{\pi}} \int_{-\infty}^\infty t^2 e^{-\frac{t^2}{2}} dt = \frac{4\sigma^2}{\sqrt{\pi}} \int_0^\infty t^2 e^{-t^2} dt$$

Consideramos $\Gamma(x) := \int_0^\infty t^{x-1} e^{-t} dt$ y el cambio de variable $t^2 = u \implies 2t dt = du$.

$$\begin{aligned} \implies \overline{V(X)} &= \frac{4\sigma^2}{\sqrt{\pi}} \int_0^\infty u e^{-u} \frac{1}{2\sqrt{u}} du = \frac{2\sigma^2}{\sqrt{\pi}} \int_0^\infty u^{\frac{3}{2}-1} e^{-u} du = \frac{2\sigma^2}{\sqrt{\pi}} \Gamma\left(\frac{3}{2}\right) \\ &= \frac{2\sigma^2}{\sqrt{\pi}} \cdot \frac{1}{2} \cdot \Gamma\left(\frac{1}{2}\right) = \frac{\sigma^2}{\cancel{\sqrt{\pi}}} \cdot \cancel{\sqrt{\pi}} = \overline{\sigma^2} \end{aligned}$$


21/03/2024

3.2.1 Calculando con la normal ($N(\mu, \sigma^2)$)

Sea $X \sim N(\mu, \sigma^2)$ con parámetros $\mu \in \mathbb{R}$, $\sigma^2 > 0$

$$\implies f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \wedge \quad F(x) = \int_{-\infty}^x f(y) dy$$

El caso particular de $N(0, 1)$ se denota por $\phi(x) := f(x)$ y $\Phi(x) := F(x)$.



¡Basta con $N(0, 1)$!

$$X \sim N(0, 1) \implies Y := \sigma X + \mu \sim N(\mu, \sigma^2)$$

$$Y \sim N(\mu, \sigma^2) \implies X := \frac{Y - \mu}{\sigma} \sim N(0, 1)$$

Podemos tipificar cualquier v.a.c. X con esperanza $E(X)$ y varianza $V(X)$.

$$Y := \frac{X - E(X)}{\sqrt{V(X)}} \implies E(Y) = 0 \quad \wedge \quad V(Y) = 1$$

¿Qué cálculos queremos hacer con $Y \sim N(\mu, \sigma^2)$?

$$E(Y) = E(\mu + \sigma X) = \mu + \sigma E(X) = \mu \quad \wedge \quad V(Y) = V(\mu + \sigma X) = \sigma^2 V(X) = \sigma^2$$

$$E(Y^7) = E((\mu + \sigma X)^7) = \sum_{k=0}^7 \binom{7}{k} \mu^7 \sigma^{7-k} E(X^{7-k})$$

$$\text{Caso particular de } X \sim N(0, 1) \implies E(X^k) = \begin{cases} 0, & \text{si } k \text{ es impar} \\ \frac{1}{2^{k/2}} \frac{k!}{(k/2)!} = \frac{(k-1)!!}{k!!}, & \text{si } k \text{ es par} \end{cases}$$

¿Cómo calculamos las probabilidades de $X \sim N(0, 1)$?

$$\forall a, b \in \mathbb{R} : P(a \leq X \leq b) = \Phi(b) - \Phi(a) \quad (\text{se calcula numéricamente})$$

$$\forall a \in \mathbb{R} : P(|X| \leq a) = P(-a \leq X \leq a) = \Phi(a) - \Phi(-a) = 2\Phi(a) - 1$$

¿Qué hago si me dan $P(X \leq a)$ y me piden a ?

$\Phi(a) = P(X \leq a) \implies a = \Phi^{-1}(P(X \leq a))$ que también se hace numericamente.

Observación 3.2. $\text{erf}(x) = \frac{2}{\sqrt{2}} \int_0^x e^{-y^2} dy \implies \text{erf}(x) = 2\Phi(\sqrt{2}x) - 1$

Para $X \sim N(\mu, \sigma^2)$, se tiene $P(Y \leq a) = P(\mu + \sigma X \leq a) = P\left(X \leq \frac{a - \mu}{\sigma}\right) = \Phi\left(\frac{a - \mu}{\sigma}\right)$.

Un famoso resultado: El percentil 95

$$P(|X| \leq a) = \frac{95}{100} \implies 2\Phi(a) - 1 = \frac{95}{100} \implies a = \Phi\left(\frac{1 + 0.95}{2}\right) \approx 1.96$$

02/04/2024

3.3 Modelos multidimensionales (vectores aleatorios)

Definición 3.5 (Función de distribución conjunta). Sean X e Y dos variables aleatorias, $F_{X,Y}$ es su función de distribución conjunta

$$\iff \forall (x, y) \in \mathbb{R}^2 : F_{X,Y}(x, y) = P(X \leq x \wedge Y \leq y)$$

Observación 3.3. • $\lim_{x, y \rightarrow \infty} F_{X,Y}(x, y) = 1$ • $\forall \hat{x} \leq x, \hat{y} \leq y : F_{X,Y}(\hat{x}, \hat{y}) \leq F_{X,Y}(x, y)$

Funciones de densidad marginales: $\forall x \in \mathbb{R} : F_X(x) = P(X \leq x) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y)$

¿Independencia de X e Y ? X, Y independientes $\iff F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y)$

Definición 3.6 (Función de densidad conjunta). Sean X e Y dos variables aleatorias, $f_{X,Y}$ es su función de densidad conjunta

$$\iff \forall (x, y) \in \mathbb{R}^2 : F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) du dv$$

Observación 3.4. • $\forall (x, y) \in \mathbb{R}^2 : f_{X,Y}(x, y) \geq 0$ • $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(u, v) du dv = 1$

Cálculo de probabilidades: $\forall A \subset \mathbb{R}^2 : P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy$

Si $F_{X,Y}(x, y)$ es el dato, $f_{X,Y}(x, y) = \begin{cases} \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y) & \text{si la derivada existe} \\ 0 & \text{si no existe} \end{cases}$

Ejemplo 3.6. Sean $a, b \in \mathbb{R}$ y $(X, Y) \sim \text{UNIF}(\mathcal{R} := [0, a] \times [0, b])$

$$\begin{aligned} \Rightarrow f_{X,Y} &= \begin{cases} 0, & \text{si } (x, y) \notin \mathcal{R} \\ \frac{1}{ab}, & \text{si } (x, y) \in \mathcal{R} \end{cases} \\ \Rightarrow \forall A \subset \mathcal{R} : P((x, y) \in A) &= \iint_A \frac{1}{ab} dx dy = \frac{1}{ab} \text{Área}(A) \end{aligned}$$

03/04/2024

Ejemplo 3.7 (Normal bidimensional). Sean X, Y dos variables aleatorias con función de densidad conjunta dependiente de cinco parámetros: $\mu_1 \in \mathbb{R}$, $\mu_2 \in \mathbb{R}$, $\sigma_1 > 0$, $\sigma_2 > 0$, $\rho \in (-1, 1)$; (X, Y) siguen una distribución normal bidimensional

$$\Leftrightarrow f_{X,Y}(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right)}$$

Para $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 1$ se tiene la normal bidimensional estándar (dependiente de ρ)

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2 - 2\rho xy + y^2)}$$

Notación matricial

$$\begin{aligned} \vec{\mu} &= \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \quad \mathbb{X} = \begin{pmatrix} X \\ Y \end{pmatrix} \quad \Sigma := \begin{pmatrix} \sigma^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \Rightarrow \Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{pmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix} \\ \Rightarrow f_{\mathbb{X}}(\vec{x}) &= \frac{1}{2\pi\sqrt{|\Sigma|}} e^{-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})} \end{aligned}$$

3.3.1 Normal multidimensional

$\mathbb{X} = (X_1, \dots, X_n)$ $\vec{\mu} = (\mu_1, \dots, \mu_n)$ Σ simétrica definida positiva $n \times n$

$$\Rightarrow f_{\mathbb{X}}(\vec{x}) = \frac{1}{(2\pi)^{n/2}\sqrt{|\Sigma|}} e^{-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})}$$

3.3.2 Marginales e independencia

$$\forall x \in \mathbb{R} : f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy \quad \wedge \quad \forall y \in \mathbb{R} : f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx$$

Teorema 3.4. Sean X, Y dos variables aleatorias con función de densidad conjunta $f_{X,Y}$
 X e Y independientes $\iff \exists h, g : \forall (x, y) \in \mathbb{R} : f_{X,Y}(x, y) = h(x) \cdot g(y)$

Ejemplo 3.8. 1. $f(x, y) = \begin{cases} e^{-x-y} & \text{si } x, y \geq 0 \\ 0 & \text{en otro caso} \end{cases} \implies f(x, y) = e^{-x-y} \cdot \mathbb{1}_{\{x>0 \wedge y>0\}}(x, y)$
 $\implies f(x, y) = (e^{-x} \cdot \mathbb{1}_{\{x \geq 0\}}(x)) \cdot (e^{-y} \cdot \mathbb{1}_{\{y \geq 0\}}(y)) \implies$ son independientes

2. $f(x, y) = \begin{cases} 2e^{-x-y} & \text{si } 0 < x < y \\ 0 & \text{en otro caso} \end{cases} \implies f(x, y) = 2e^{-x-y} \cdot \mathbb{1}_{\{0 < x < y\}}(x, y)$

Por tanto, no son independientes porque si lo fueran, tendríamos

$$P(c < X < d \wedge b < Y < a) = P(c < X < d) \cdot P(b < Y < a)$$

04/04/2024

3.4 Condicionando

Sean X e Y dos variables aleatorias con función de densidad conjunta $f_{X,Y}$ y $f_X(x)$.

En general $\forall A, B \subset \mathbb{R}^2 : P((X, Y) \in A | (X, Y) \in B) = \frac{P((X, Y) \in A \wedge (X, Y) \in B)}{P((X, Y) \in B)}$ con $P((X, Y) \in B) > 0$. Sin embargo a veces la información “nueva” $((X, Y) \in B)$ es muy precisa, por ejemplo $X = 3$, entonces la fórmula no vale porque $P(X = 3) = 0$.

Definición 3.7 (Función de densidad condicionada). Sean X, Y dos variables aleatorias con función de densidad conjunta $f_{X,Y}$ y funciones de densidad marginales $f_X(x)$ y $f_Y(y)$.

- $f_{Y|X}(y|x) = f_{Y|X=x}(y)$ es la función de densidad de Y condicionada a $X = x$

$$\iff f_{Y|X=x}(y) := \frac{f_{X,Y}(x, y)}{f_X(x)} \quad (\text{allá donde } f_X(x) > 0)$$

- $f_{X|Y}(x|y) = f_{X|Y=y}(x)$ es la función de densidad de X condicionada a $Y = y$

$$\iff f_{X|Y=y}(x) := \frac{f_{X,Y}(x, y)}{f_Y(y)} \quad (\text{allá donde } f_Y(y) > 0)$$

Una comprobación necesaria es que $\int_{-\infty}^{\infty} f_{Y|X=x}(y) dy = 1$ y $\int_{-\infty}^{\infty} f_{X|Y=y}(x) dx = 1$:

$$\int_{-\infty}^{\infty} f_{Y|X=x}(y) dy = \frac{1}{f_X(x)} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy = \frac{1}{f_X(x)} f_X(x) = 1$$

Ejemplo 3.9. $f_{X,Y}(x, y) = \begin{cases} 2e^{-x}e^{-y} & \text{si } 0 < x < y \\ 0 & \text{en otro caso} \end{cases}$

$$\begin{aligned} \implies \forall x > 0 : f_X(x) &= \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy = \int_x^{\infty} 2e^{-x}e^{-y} dy = 2e^{-x} \int_x^{\infty} e^{-y} dy \\ &= 2e^{-x}e^{-x} = 2e^{-2x} \end{aligned}$$

$$\forall y > 0 : \overline{f_Y(y)} = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx = \int_0^y 2e^{-x}e^{-y} dx = 2e^{-y} \int_0^y e^{-x} dx = \overline{2e^{-y}(1 - e^{-y})}$$

$$f_{Y|X=3}(y) = \frac{f_{X,Y}(3, y)}{f_X(3)} = \frac{2e^{-3}e^{-y}}{2e^{-6}} = e^{3-y} \cdot \mathbb{1}_{\{y>3\}}(y)$$

$$\implies f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{2e^{-x}e^{-y}}{2e^{-y}(1 - e^{-y})} = \frac{e^{-x}}{1 - e^{-y}} \cdot \mathbb{1}_{\{0 < x < y\}}(x)$$

¡Cuidado! No se nos puede olvidar el soporte. (Motivo de excomuni3n)

Nota sobre independencia: X, Y indep. $\implies f_{X|Y=y}(x) = f_X(x) \wedge f_{Y|X=x}(y) = f_Y(y)$

3.5 Transformaciones / cambio de variables

Sean X, Y dos v.a. con funci3n de densidad conjunta $f_{X,Y} \wedge T: \mathbb{R}^2 \longrightarrow \mathbb{R}^2$
 $(x, y) \longmapsto (u(x, y), v(x, y))$

Definimos las variables aleatorias $U := u(X, Y)$ y $V := v(X, Y)$.

Por ejemplo, si tenemos T lineal con matriz asociada $\begin{pmatrix} a & b \\ c & d \end{pmatrix} \implies \begin{cases} U = aX + cY \\ V = bX + dY \end{cases}$
pero tambi3n hay transformaciones no lineales como $U = X + Y \wedge V = \frac{X}{X+Y}$.

Definimos $D := \{(x, y) \in \mathbb{R}^2 : f_{X,Y}(x, y) > 0\}$ y sea $B \subset T(D)$.

$$\begin{aligned} \implies P((U, V) \in B) &= \iint_B f_{U,V}(u, v) du dv = \iint_{T^{-1}(B)} f_{X,Y}(x, y) dx dy \\ &= \iint_B f_{X,Y}(x(u, v), y(u, v)) |J(u, v)| du dv \end{aligned}$$

Teorema 3.5. Sean X, Y dos variables aleatorias con funci3n de densidad conjunta $f_{X,Y}$ y sea $T: \mathbb{R}^2 \longrightarrow \mathbb{R}^2 : (x, y) \mapsto T(x, y) = (u(x, y), v(x, y))$ una biyecci3n de D en $T(D)$ de clase C^1 con inversa de clase C^1 .

$$\implies f_{U,V}(u, v) = \begin{cases} f_{X,Y}(x(u, v), y(u, v)) |J(u, v)| & \text{si } (u, v) \in T(D) \\ 0 & \text{en otro caso} \end{cases}$$

09/04/2024

Ejemplo 3.10. Sean X, Y v.a. con $\forall x, y > 0 : f_{X,Y}(x, y) := \frac{1}{4}e^{-\frac{1}{2}(x+y)}$.

Sea $T(x, y) = \left(\frac{x-2}{2}, y\right)$. Definimos $(U, V) := T(X, Y)$.

$$\implies \forall x, y > 0 : T(x, y) = \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix} \implies \begin{cases} x = 2u + 2 \\ y = v \end{cases}$$

$$\implies T^{-1}(u, v) = (2u + 2, v) \wedge J(u, v) = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix} = \begin{vmatrix} 2 & 1 \\ 0 & 1 \end{vmatrix} = 2$$

$$\implies f_{U,V}(u, v) = \begin{cases} 2\frac{1}{4}e^{-\frac{1}{2}[2u+v+v]} = \frac{1}{2}e^{-(u+v)} & \text{si } v > 0 \wedge u > -\frac{v}{2} \\ 0 & \text{en otro caso} \end{cases}$$

Ejemplo 3.11. Sean X, Y v.a. con $\forall x, y > 0 : f_{X,Y}(x, y) := e^{-x-y}$.

Sea $T(x, y) = \left(x + y, \frac{x}{x + y}\right)$. Definimos $(U, V) := T(X, Y)$.

$$\implies T^{-1}(u, v) = (u \cdot v, u(1 - v)) \wedge J(u, v) = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix} = \begin{vmatrix} v & u \\ 1 - v & -u \end{vmatrix} = -u$$

$$\implies f_{U,V}(u, v) = \begin{cases} |-u| e^{-u \cdot v - u(1-v)} = ue^{-u} & \text{si } u > 0 \wedge 0 < v < 1 \\ 0 & \text{en otro caso} \end{cases}$$

$$\implies \forall v \in (0, 1) : f_V(v) = \int_{-\infty}^{\infty} f_{U,V}(u, v) du = \int_0^{\infty} ue^{-u} du = [-e^{-u}(u + 1)]_0^{\infty} = 1$$

$$\implies V \sim \text{UNIF}(0, 1)$$

10/04/2024

Sean X, Y dos variables con función de densidad conjunta $f_{X,Y}$, consideramos una función $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ “razonable”^(*) y definimos $Z := g(X, Y)$. Queremos calcular $E(Z), V(Z)$.

(*) g cumple que $\forall z \in \mathbb{R} : \{\omega \in \Omega : g(X(\omega), Y(\omega)) \leq z\} \in \mathcal{F}$

Teorema 3.6. Sean X, Y dos variables aleatorias con $f_{X,Y}$ y $Z := g(X, Y)$ con $g: \mathbb{R}^2 \rightarrow \mathbb{R}$

$$\implies E(Z) = \int_{-\infty}^{\infty} z \cdot f_Z(z) dz = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) \cdot f_{X,Y}(x, y) dx dy$$

Observación 3.5. 1. $\forall \alpha, \beta \in \mathbb{R} : E(\alpha X + \beta Y) = \alpha E(X) + \beta E(Y)$

$$2. E(X \cdot Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot y \cdot f_{X,Y}(x, y) dx dy$$

$$\text{cov}(X, Y) = E(X \cdot Y) - E(X)E(Y) \quad \wedge \quad \rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{V(X)V(Y)}}$$

$$\implies X, Y \text{ indep} \not\iff \rho(X, Y) = 0$$

3. X, Y indep. $\iff f_{X,Y}$ se factoriza

$$\implies X, Y \text{ indep.} \iff \forall g, h: \mathbb{R} \longrightarrow \mathbb{R} : E(g(X)h(Y)) = E(g(X))E(h(Y))$$

4. Esperanza condicionada y total

$$E(Y|X = x) = \int_{-\infty}^{\infty} y \cdot f_{Y|X=x}(y) dy = \int_{-\infty}^{\infty} y \cdot \frac{f_{X,Y}(x, y)}{f_X(x)} dy$$

$$\implies E(Y) = \int_{-\infty}^{\infty} E(Y|X = x) \cdot f_X(x) dx$$

¿Y qué hay de $f_Z(z)$? Definimos $A_g(z) := \{(x, y) \in \mathbb{R}^2 : g(x, y) \leq z\}$

$$\forall z \in \mathbb{R} : F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = P((X, Y) \in A_g(z)) = \iint_{A_g(z)} f_{X,Y}(x, y) dx dy$$

$$\implies \forall z \in \mathbb{R} : f_Z(z) = \begin{cases} \frac{\partial}{\partial z} F_Z(z) & \text{si la derivada existe} \\ 0 & \text{en otro caso} \end{cases}$$

Ejemplo 3.12 (El caso de la suma). Sean X, Y dos v.a. con $f_{X,Y}$ y $Z := X + Y$. Entonces $A_+(z) := \{(x, y) \in \mathbb{R}^2 : x + y \leq z\}$.

$$\implies \forall z \in \mathbb{R} : F_Z(z) = \iint_{A_+(z)} f_{X,Y}(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{z-x} f_{X,Y}(x, y) dy dx$$

Mediante el cambio de variables $u = x \wedge v = x + y$ se tiene

$$T(x, y) = (x, x + y) \implies T^{-1}(u, v) = (u, v - u) \implies J(u, v) = \begin{vmatrix} 1 & 0 \\ -1 & 1 \end{vmatrix} = 1$$

$$\implies F_Z(z) = \int_{-\infty}^z \int_{-\infty}^{\infty} f_{X,Y}(u, v-u) du dv \implies \boxed{f_Z(z) = \frac{d}{dz} F_Z(z) = \int_{-\infty}^{\infty} f_{X,Y}(u, z-u) du}$$

Caso particular: Si X, Y independientes $\implies f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$

$$\implies \forall z \in \mathbb{R} : \boxed{f_{X+Y}(z)} = \int_{-\infty}^{\infty} f_X(u) \cdot f_Y(z-u) du =: \boxed{(f_X * f_Y)(z)}$$

11/04/2024

3.6 Convolución

Sean X e Y dos v.a.d. indep. que toman valores en $\mathbb{Z}_{\geq 0}$. Sea $Z = X + Y$.

$$\implies P(Z = k) = \sum_{j=0}^k P(X = j \wedge Y = k - j) = \sum_{j=0}^k P(X = j) \cdot P(Y = k - j)$$

Ahora, sean X e Y dos v.a.c. indep. con funciones de densidad f_X y f_Y respectivamente.

$$\implies \int_{-\infty}^{\infty} f_X(x) \cdot f_Y(z-x) dx = (f_X * f_Y)(z)$$

Ejemplo 3.13. Sean $X, Y \sim N(0, 1)$ independientes. Queremos f_Z con $Z := X + Y$.

$$\begin{aligned} \forall z \in \mathbb{R} : f_Z(z) &= \int_{-\infty}^{\infty} f_X(u) \cdot f_Y(z-u) du = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{(z-u)^2}{2}} du \\ &= \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-\frac{1}{2}[z^2+2u^2-2uz]} du \stackrel{(*)}{=} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{4}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}\left(\sqrt{2}u - \frac{z}{\sqrt{2}}\right)^2} du \end{aligned}$$

$$(*) \text{ porque } -\frac{1}{2}(z^2 + 2u^2 - 2uz) = -\frac{1}{2}\left(2u^2 - 2uz + \frac{z^2}{2} + \frac{z^2}{2}\right) = -\frac{1}{2}\left[\left(\sqrt{2}u - \frac{z}{\sqrt{2}}\right)^2 + \frac{z^2}{2}\right].$$

Por el cambio de variables $w = \sqrt{2}u - \frac{z}{\sqrt{2}} \implies dw = \sqrt{2} du$, se tiene

$$\forall z \in \mathbb{R} : f_Z(z) = \frac{1}{\sqrt{2}} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{4}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{w^2}{2}} dw \stackrel{1}{=} \frac{1}{2\sqrt{\pi}} e^{-\frac{z^2}{4}} \implies Z \sim N\left(0, (\sqrt{2})^2\right)$$

Moraleja: la suma de normales independientes es una normal.

Ejemplo 3.14 (Normal bidimensional). Sean X, Y dos variables aleatorias con función

de densidad conjunta $\forall x, y \in \mathbb{R} : f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2-2\rho xy+y^2)}$.

$$\implies f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy = \int_{-\infty}^{\infty} \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2-2\rho xy+y^2)} dy$$

Por tanto, $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ y $f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$ (ambas normales estándar).

Ahora veamos que $\rho(X, Y) := \frac{\text{cov}(X, Y)}{\sqrt{V(X)V(Y)}} = \rho$.

$$E(X \cdot Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot y \cdot \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2-2\rho xy+y^2)} dx dy$$

Usando esperanza total, $E(g(X, Y)) = \int_{-\infty}^{\infty} E(g(X, Y)|X = x) \cdot f_X(x) dx$

$$E(X \cdot Y) = \int_{-\infty}^{\infty} E(X \cdot Y|X = x) \cdot f_X(x) dx = \int_{-\infty}^{\infty} x \cdot E(Y|X = x) \cdot f_X(x) dx$$

Necesitamos calcular $E(Y|X = x) = \int_{-\infty}^{\infty} y \cdot f_{Y|X=x}(y) dy$.

$$f_{Y|X=x}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)} = \frac{\frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2-2\rho xy+y^2)}}{\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}} = \frac{1}{\sqrt{2\pi(1-\rho^2)}} e^{-\frac{1}{2(1-\rho^2)}(y-\rho x)^2}$$

Es decir, $Y|X = x \sim N(\rho x, 1 - \rho^2)$.

$$\begin{aligned} \implies E(Y|X = x) &= \int_{-\infty}^{\infty} y \cdot \frac{1}{\sqrt{2\pi(1-\rho^2)}} e^{-\frac{1}{2(1-\rho^2)}(y-\rho x)^2} dy = \rho x \\ \implies \overline{E(X \cdot Y)} &= \int_{-\infty}^{\infty} x \cdot \rho x \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \rho \underbrace{\int_{-\infty}^{\infty} x^2 f_X(x) dx}_{E(X^2)} = \overline{\rho} \end{aligned}$$

17/04/2024

3.7 Fuera de menú

Tenemos X_1, X_2 siguiendo una distribución normal bidimensional con $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ conocidos.

$$\implies f_{X,Y}(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right)}$$

Podemos escribir X_1 y X_2 como transformaciones de $Z_1, Z_2 \sim N(0, 1)$.

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} + \begin{pmatrix} \sigma_1 & 0 \\ \rho\sigma_2 & \sigma_2\sqrt{1-\rho^2} \end{pmatrix} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} + \begin{pmatrix} \sigma_1 Z_1 \\ \sigma_2(\rho Z_1 + \sqrt{1-\rho^2} Z_2) \end{pmatrix}$$

Esta transformación facilita muchos cálculos como $E(X_1 \cdot X_2)$.

Tenemos $\mathbb{X}^T = (X_1, \dots, X_n)$ normal n -dimensional con $\vec{\mu} = (\mu_1, \dots, \mu_n)$ y \mathbb{V} matriz de covarianzas definida positiva.

$$\implies f_{\mathbb{X}}(\vec{x}) = \frac{1}{(2\pi)^{n/2}\sqrt{\det \mathbb{V}}} e^{-\frac{1}{2}(\vec{x}-\vec{\mu})^T \mathbb{V}^{-1}(\vec{x}-\vec{\mu})}$$

Si ahora tenemos en cuenta que A definida positiva $\iff \exists R$ tal que $A = R^T R$ con B no singular, podemos escribir $\mathbb{V} = U^T U$.

Teorema 3.7 (de representación). $\mathbb{X} \sim N(\vec{\mu}, \mathbb{V}) \iff \mathbb{X} = \vec{\mu} + U \cdot \mathbb{Z}$ con $\mathbb{Z} \sim N(\vec{0}, I)$

4 Convergencia de variables aleatorias

Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de variables aleatorias en un espacio de probabilidad (Ω, \mathcal{F}, P) , queremos estudiar las series

$$(S_n)_{n \in \mathbb{N}} := \left(\sum_{i=1}^n X_i \right)_{n \in \mathbb{N}} \quad \wedge \quad (Z_n)_{n \in \mathbb{N}} := \left(\frac{1}{n} \sum_{i=1}^n X_i \right)_{n \in \mathbb{N}}$$

Interesan, específicamente, los límites cuando $n \rightarrow \infty$ de estas series.

1. Sabemos que significa $\lim_{n \rightarrow \infty} E(S_n)$ y $\lim_{n \rightarrow \infty} V(S_n)$ pero, ¿qué significa $\lim_{n \rightarrow \infty} S_n = S$?
Requerimos de técnicas más avanzadas que se denominan **modos de convergencia**.
2. Asumiremos que $\{X_n\}$ son **independientes e idénticamente distribuidas (i.i.d.)**.
 - Todas las X_i tienen la misma distribución. Por tanto, es habitual definir una **X de referencia** que tenga la misma distribución que todas las X_i .
 - Las X_i son **completamente independientes**, es decir, para todo subconjunto finito $I \subset \mathbb{N}$, $\{X_i\}_{i \in I}$ son independientes.
3. Descubriremos que, para n grande y X de referencia, Z_n se comporta como $E(X)$.
Además, veremos el teorema central del límite, que nos dice que $\frac{Z_n - E(X)}{\sigma(Z_n)/\sqrt{n}} \approx N(0, 1)$.

4.1 Medias y varianzas de las sumas y las medias

Las medias de S_n y Z_n resultan sencillas de calcular.

$$E(S_n) = E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) \stackrel{(\star)}{=} nE(X)$$

$$E(Z_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) \stackrel{(\star)}{=} E(X)$$

(\star) Si X_i tienen la misma media.

Nótese que, en la mayoría de casos, $E(S_n) \xrightarrow{n \rightarrow \infty} \infty$ mientras que $E(Z_n)$ tenderá a al promedio de las medias de las X_i .

Las varianzas de S_n y Z_n son más intrincadas de calcular y debemos tener en cuenta, no solo el caso de que las X_i tengan la misma varianza, sino también si son incorreladas.

$$\begin{aligned}
V(S_n) &= V\left(\sum_{i=1}^n X_i\right) = V(X_1) + V\left(\sum_{i=2}^n X_i\right) + 2 \operatorname{cov}\left(X_1, \sum_{i=2}^n X_i\right) \\
&= V(X_1) + 2 \sum_{i=2}^n \operatorname{cov}(X_1, X_i) + V\left(\sum_{i=2}^n X_i\right) \\
&= V(X_1) + 2 \sum_{i=2}^n \operatorname{cov}(X_1, X_i) + V(X_2) + 2 \sum_{i=3}^n \operatorname{cov}(X_2, X_i) + V\left(\sum_{i=3}^n X_i\right) \\
&= \sum_{i=1}^n V(X_i) + 2 \sum_{1 \leq i < j \leq n} \operatorname{cov}(X_i, X_j) \stackrel{(*)_1}{=} \sum_{i=1}^n V(X_i) \stackrel{(*)_2}{=} n(\sigma(X))^2 \\
V(Z_n) &= V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} V\left(\sum_{i=1}^n X_i\right) \stackrel{(*)_1}{=} \frac{1}{n^2} \sum_{i=1}^n V(X_i) \stackrel{(*)_2}{=} \frac{(\sigma(X))^2}{n} \xrightarrow{n \rightarrow \infty} 0
\end{aligned}$$

$(*)_1$ Si X_i incorreladas, $(*)_2$ Si (además) X_i tienen la misma varianza.

De forma similar a como ocurre con las medias, (en la mayoría de casos) la varianza de S_n tiende a infinito mientras que la de Z_n tiende a 0 cuando $n \rightarrow \infty$.

4.2 Convergencia cuadrática

Definición 4.1 (Convergencia cuadrática). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de v.a. y X v.a. en el mismo espacio de probabilidad (Ω, \mathcal{F}, P) , $\boxed{X_n \xrightarrow{\text{cuad.}} X \iff E(|X_n - X|^2) \xrightarrow{n \rightarrow \infty} 0}$

Teorema 4.1. Sean $(X_n)_{n \in \mathbb{N}}$ v.a. i.i.d. con X v.a. de referencia $\implies Z_n \xrightarrow{\text{cuad.}} E(X)$

Demostración. Si denominamos $\mu = E(X) \wedge V(X) = \sigma^2$, entonces

$$E(|Z_n - \mu|^2) = E(|Z_n - E(Z_n)|^2) = V(Z_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$$

■

Basta con que sean incorreladas y tengan la misma media y varianza porque es lo único que se ha usado en la demostración. Podemos incluso ofrecer un teorema más general que no requiera que tengan la misma media y varianza.

Teorema 4.2. Sean $(X_n)_{n \in \mathbb{N}}$ v.a. en (Ω, \mathcal{F}, P) con $E(X_i) = \mu_i$ y $V(X_i) = \sigma_i^2$. Suponemos que $\mu_n := \frac{1}{n} \sum_{i=1}^n \mu_i \xrightarrow{n \rightarrow \infty} \mu \in \mathbb{R}$ y $V(Z_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2 \rightarrow 0 \implies Z_n \xrightarrow{\text{cuad.}} \mu$

Demostración. (Buen ejercicio de examen)

$$\begin{aligned}
 E(|Z_n - \mu|^2) &= E(|Z_n - \mu_n + \mu_n - \mu|^2) \\
 &= E(|Z_n - \mu_n|^2 + |\mu_n - \mu|^2 + 2(Z_n - \mu_n)(\mu_n - \mu)) \\
 &= E((Z_n - \mu_n)^2) + (\mu_n - \mu)^2 + 2(\mu_n - \mu) \cancel{E(Z_n - \mu_n)} \xrightarrow{0} \\
 &= E((Z_n - \mu_n)^2) + (\mu_n - \mu)^2 \xrightarrow{n \rightarrow \infty} 0
 \end{aligned}$$

■

Es decir, si el promedio de las medias tiende a un número finito y la varianza del promedio tiende a 0, entonces el promedio tiende al límite del promedio de las medias.

23/04/2024

4.3 Convergencia en probabilidad (ley débil)

J. Bernoulli (1713) *Ars Conjectandi*: Si tienes un dado regular, cuantas más veces lo lances, más se aproximará la frecuencia relativa de un número a su probabilidad.

Definición 4.2 (Convergencia en probabilidad). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de v.a. y X v.a. en el mismo espacio de probabilidad (Ω, \mathcal{F}, P) ,

$$X_n \xrightarrow{P} X \iff \forall \varepsilon > 0 : \lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

Teorema 4.3 (Ley débil de los grandes números). Sean $(X_n)_{n \in \mathbb{N}}$ v.a. i.i.d. en (Ω, \mathcal{F}, P) con X v.a. de referencia tal que $\mu := E(X) < \infty \wedge \sigma^2 := V(X) < \infty \implies Z_n := \frac{1}{n} \sum_{j=1}^n X_j \xrightarrow{P} \mu$

Demostración. Dado $\varepsilon > 0$, por la desigualdad de Chebyshev

$$P(|Z_n - \mu| > \varepsilon) \leq \frac{V(Z_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

■

Observación 4.1. 1. Hay una ley fuerte de los grandes números.

2. Hipótesis: No hace falta que sean independientes, basta con que sean incorreladas. Tampoco hace falta que sean idénticas, basta con que tengan la misma media y varianza.
3. Se podría incluso hacer una variante del teorema para variables aleatorias que no tengan la misma media y varianza.
4. Existe la posibilidad de adaptar el teorema para que no haga falta que sean incorreladas, solo que tengan una correlación “pequeña”.

Teorema 4.4. Sean $(X_n)_{n \in \mathbb{N}}$ v.a. incorreladas en (Ω, \mathcal{F}, P) con $E(X_i) = \mu_i$ y $V(X_i) = \sigma_i^2$.

Suponemos $V(Z_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2 \xrightarrow{n \rightarrow \infty} 0 \implies Z_n \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n \mu_i$

Demostración. Por la desigualdad de Chebyshev

$$P \left(\left| Z_n - \frac{1}{n} \sum_{i=1}^n \mu_i \right| > \varepsilon \right) \leq \frac{V(Z_n)}{\varepsilon^2} = \frac{1}{n^2 \varepsilon^2} \sum_{i=1}^n \sigma_i^2 \xrightarrow{n \rightarrow \infty} 0$$

■

Es decir, si la varianza del promedio tiende a 0, entonces el promedio tiende al promedio de las medias.

Usos en estadística: Sean X_1, \dots, X_n v.a. i.i.d. con $X \sim \text{BER}(p)$ de referencia. Queremos estimar p (desconocido), ¿cuánto de grande tiene que ser n para estar razonablemente seguros

que el estimador $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$ está cerca de p ?

$$P(|\bar{X}_n - p| > \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2} \leq \delta \implies n \geq \frac{1}{4\varepsilon^2\delta}$$

Es decir, si queremos estar δ seguros de que el estimador está a una distancia menor que ε de p , necesitamos que n sea mayor que $\frac{1}{4\varepsilon^2\delta}$.

4.4 Cálculo de la distribución de la suma y el promedio

Sean $(X_n)_{n \in \mathbb{N}}$ v.a. i.i.d. en (Ω, \mathcal{F}, P) con X v.a. de referencia.

1. $X \sim \text{BER}(p) \implies S_n \sim \text{BIN}(n, p)$ y $Z_n \in \{0, \frac{1}{n}, \frac{2}{n}, \dots, 1\}$ con las mismas probabilidades que una $\text{BIN}(n, p)$.
2. $X \sim \text{POISSON}(\lambda) \implies S_n \sim \text{POISSON}(n\lambda)$. Ya vimos que la suma de dos poisson es poisson. Ahora, por inducción asumimos que se cumple para $n-1$.

$$\begin{aligned} P(S_n = k) &= P\left(\sum_{i=1}^n X_i = k\right) = \sum_{i=0}^k P\left(\sum_{i=1}^{n-1} X_i = k-i \wedge X_n = i\right) \\ &= \sum_{i=0}^k P\left(\sum_{i=1}^{n-1} X_i = k-i\right) P(X_n = i) = \sum_{i=0}^k \frac{(n-1)^{k-i} \lambda^{k-i}}{(k-i)!} e^{-(n-1)\lambda} \frac{\lambda^i}{i!} e^{-\lambda} \\ &= e^{-n\lambda} \lambda^k \sum_{i=0}^k \frac{(n-1)^{k-i}}{(k-i)! i!} = \frac{\lambda^k}{k!} e^{-n\lambda} \sum_{i=0}^k \binom{k}{i} (n-1)^{k-i} = \frac{(n\lambda)^k}{k!} e^{-n\lambda} \end{aligned}$$

3. $X \sim \text{GEOM}(p) \implies S_n \sim \text{binomialnegativa}(n, p)$.
4. $X \sim \text{N}(\mu, \sigma^2) \implies S_n \sim \text{N}(n\mu, n\sigma^2)$.

5. $X \sim \mathbf{EXP}(\lambda) \implies S_n \sim \text{Gamma}(n, \lambda)$.

Técnicas generales (Funciones generatrices)

24/04/2024

4.5 Convergencia en distribución

Definición 4.3 (Convergencia en distribución). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de v.a. y X v.a. en el mismo espacio de probabilidad (Ω, \mathcal{F}, P) ,

$$\left(X_n \xrightarrow{d} X \right) \iff \forall t \in \mathbb{R}^{(*)} : P(X_n \leq t) \xrightarrow{n \rightarrow \infty} F_X(t) := P(X \leq t)$$

(*) F_X debe ser continua en t .

4.5.1 Teorema del límite central / central del límite

Vamos a tipificar $S_n := \sum_{i=1}^n X_i$ y $Z_n := \frac{1}{n} \sum_{i=1}^n X_i$ con $(X_n)_{n \in \mathbb{N}}$ i.i.d. con X de referencia.

$$W_n := \frac{S_n - n\mu}{\sigma\sqrt{n}} \quad \wedge \quad V_n := \frac{Z_n - \mu}{\sigma/\sqrt{n}}$$

Teorema 4.5 (del límite central). Sean $(X_n)_{n \in \mathbb{N}}$ v.a. i.i.d. en (Ω, \mathcal{F}, P) con X de referencia.

$$\implies \forall t \in \mathbb{R} : P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) \xrightarrow{n \rightarrow \infty} \Phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{x^2}{2}} dx$$

Es decir, este teorema nos dice que $\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} U$ donde $U \sim N(0, 1)$

Ejemplo 4.1. Sea $X \sim \text{BER}(p)$ la v.a. de referencia de $(X_n)_{n \in \mathbb{N}}$ i.i.d., entonces $S_n \sim \text{BIN}(n, p)$ y $Z_n \in \{0, \frac{1}{n}, \frac{2}{n}, \dots, 1\}$ con las mismas probabilidades que una $\text{BIN}(n, p)$.

Si $p = 1/2$ y $n = 1000$ (lanzamos una moneda regular 1000 veces) y nos piden:

$$P(480 \leq S_{1000} \leq 530) = \sum_{j=480}^{530} \binom{1000}{j} \left(\frac{1}{2}\right)^{1000} \approx 87.578\%$$

Pero podemos aproximar la respuesta usando la normal por el teorema del límite central:

$$\begin{aligned} P(480 \leq S_{1000} \leq 530) &= P\left(\frac{480 - 500}{\sqrt{250}} \leq \frac{S_{1000} - 500}{\sqrt{250}} \leq \frac{530 - 500}{\sqrt{250}}\right) \\ &\approx \Phi\left(\frac{30}{\sqrt{250}}\right) - \Phi\left(\frac{-20}{\sqrt{250}}\right) \approx 86.816\% \end{aligned}$$

Ejemplo 4.2. Lanzamos un dado 10000 veces y nos piden $P(3400 \leq S \leq 3500)$.

Tenemos $X \sim \text{UNIF}(1, 6) \implies E(X) = \frac{7}{2} \wedge V(X) = \frac{35}{12}$ y,

por tanto, $S = \sum_{i=1}^{1000} X_i \implies E(S) = 3500 \wedge V(S) = 1000 \frac{35}{12}$.

$$\begin{aligned} P(3400 \leq S \leq 3500) &= P\left(\frac{-100}{\sqrt{1000 \cdot \frac{35}{12}}} \leq \frac{S - 3500}{\sqrt{1000 \cdot \frac{35}{12}}} \leq 0\right) \\ &\approx \Phi(0) - \Phi\left(\frac{-100}{\sqrt{1000 \cdot \frac{35}{12}}}\right) \approx 46.79\% \end{aligned}$$

Ejemplo 4.3 (Intervalo de confianza). Sea $X \sim \text{BER}(p)$ de referencia con p desconocido de $(X_n)_{n \in \mathbb{N}}$ i.i.d. y \bar{X}_n el promedio de las X_i .

Fijamos $\alpha \in \mathbb{R}$ “pequeño” y definimos $z_{\alpha/2} := \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)$.

$$\begin{aligned} \implies P\left(-z_{\alpha/2} \leq \frac{\bar{X}_n - p}{\sqrt{p(1-p)/n}} \leq z_{\alpha/2}\right) &\approx 1 - \alpha \\ = P\left(-\frac{z_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}} \leq \bar{X}_n - p \leq \frac{z_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}}\right) \\ = P\left(\bar{X}_n - \frac{z_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}} \leq p \leq \bar{X}_n + \frac{z_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}}\right) \end{aligned}$$

Tenemos confianza $1 - \alpha$ de que p está en el intervalo $\left(\bar{x}_n - \frac{z_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}}, \bar{x}_n + \frac{z_{\alpha/2}\sqrt{p(1-p)}}{\sqrt{n}}\right)$ donde \bar{x}_n es el valor observado de \bar{X}_n . Sin embargo, este intervalo depende de p , pero podemos acotarlo por $\left(\bar{x}_n - \frac{z_{\alpha/2}}{2\sqrt{n}}, \bar{x}_n + \frac{z_{\alpha/2}}{2\sqrt{n}}\right)$.

Por tanto, el error sería $\frac{z_{\alpha/2}}{2\sqrt{n}}$. Si queremos que sea menor que ε , necesitamos que $n \geq \frac{(z_{\alpha/2})^2}{4\varepsilon^2}$.

25/04/2024

Ejercicio 4.5.1 (4 b del examen). Sea $(X, Y) \sim 2\text{-dim N}(0, 1)$ con correlación ρ .

Calcula la varianza de $X \cdot Y$. Tenemos que

$$V(X \cdot Y) = E(X^2 \cdot Y^2) - E(X \cdot Y)^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^2 y^2 \frac{1}{2\pi\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}(x^2 - 2\rho xy + y^2)} dx dy - \rho^2$$

porque $E(X \cdot Y) = \rho$. Completando cuadrados, obtenemos

$$\begin{aligned} V(X \cdot Y) &= \frac{1}{2\pi\sqrt{1-\rho^2}} \int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}} \left(\int_{-\infty}^{\infty} y^2 e^{-\frac{1}{2}\left(\frac{y-\rho x}{\sqrt{1-\rho^2}}\right)^2} dy \right) dx - \rho^2 \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}} \left(\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sqrt{1-\rho^2}} y^2 e^{-\frac{1}{2}\left(\frac{y-\rho x}{\sqrt{1-\rho^2}}\right)^2} dy \right) dx - \rho^2 \end{aligned}$$

El término entre paréntesis es $E(W^2)$ donde $W \sim N(\rho x, 1 - \rho^2)$ y como $V(W) = E(W^2) - E(W)^2 = 1 - \rho^2$, tenemos $E(W^2) = V(W) + E(W)^2 = 1 - \rho^2 + (\rho x)^2$.

$$\begin{aligned}
\Rightarrow \overline{V(X \cdot Y)} &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}} (1 - \rho^2 + \rho^2 x^2) dx - \rho^2 \\
&= (1 - \rho^2) \int_{-\infty}^{\infty} x^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx + \rho^2 \int_{-\infty}^{\infty} x^4 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx - \rho^2 \\
&= (1 - \rho^2) + \rho^2 E((N(0, 1))^4) - \rho^2 = 1 - \rho^2 + \rho^2 (0^4 + 6 \cdot 0^2 1^2 + 3(1^4)) - \rho^2 \\
&= 1 - \rho^2 + 3\rho^2 - \rho^2 = \overline{1 + \rho^2}
\end{aligned}$$

29/06/2024

4.5.2 Variaciones del TCL

Si consideramos $(X_n)_{n \in \mathbb{N}}$ v.a. independientes no idénticas con $E(X_i) = \mu_i$ y $V(X_i) = \sigma_i^2$

$$\Rightarrow \text{La suma tipificada es } T_n := \frac{\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mu_i}{\sqrt{\frac{1}{n^2} \sum_{i=1}^n \sigma_i^2}} = \frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}}$$

Ahora, según las condiciones de Lyapunov, definimos $S_n^\alpha := \sum_{i=1}^n \sigma_i^\alpha$, entonces

$$\exists \delta > 0 : \frac{1}{S_n^{2+\delta}} \sum_{i=1}^n E(|X_i - \mu_i|^{2+\delta}) \xrightarrow{n \rightarrow \infty} 0 \Rightarrow T_n \xrightarrow{d} N(0, 1)$$

Teorema 4.6 (Cota de Berry-Esseen). Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de v.a. i.i.d. con $E(X) = \mu$ y $V(X) = \sigma^2 < \infty$ y $E(|X|^3) < \infty$.

$$\Rightarrow \sup_{t \in \mathbb{R}} \left| P\left(\frac{\sum X_i - n\mu}{\sigma\sqrt{n}} \leq t\right) - \Phi(t) \right| \leq C \frac{E(|X|^3)}{\sigma^3} \frac{1}{\sqrt{n}} \text{ con } C \text{ constante universal}$$

4.6 Funciones generatrices de momentos (y función característica)

Recordamos: Sea X v.a. que toma valores en $\{0, 1, \dots\}$ con probabilidades p_0, p_1, \dots , entonces la función generatriz de probabilidad de X es $G_X(s) := \sum_{n=0}^{\infty} p_n s^n = E(s^X)$.

Definición 4.4. Sea X v.a., su función generatriz de momentos es $M_X(t) := E(e^{tX})$.

Observación 4.2. • Si X toma valores en $\{0, 1, \dots\}$, entonces $M_X(t) = G_X(e^t)$.

$$\text{porque } M_X(t) = E(e^{tX}) = \sum_{n=0}^{\infty} e^{tn} p_n = \sum_{n=0}^{\infty} p_n (e^t)^n = G_X(e^t)$$

• Si X es discreta $\implies E(e^{tX}) = \sum_{x \in X(\Omega)} e^{tx} P(X = x)$.

Si X es continua $\implies E(e^{tX}) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx$.

Ejemplo 4.4. • $X \sim \text{EXP}(\lambda) \implies M_X(t) = \int_0^{\infty} e^{tx} \lambda e^{-\lambda x} dx = \begin{cases} \frac{\lambda}{\lambda-t} & \text{si } t < \lambda \\ \infty & \text{si } t \geq \lambda \end{cases}$
 porque $E(e^{tX}) = \int_0^{\infty} e^{tx} \lambda e^{-\lambda x} dx = \lambda \int_0^{\infty} e^{-(\lambda-t)x} dx = \begin{cases} \frac{\lambda}{\lambda-t} & \text{si } t < \lambda \\ \infty & \text{si } t \geq \lambda \end{cases}$

• $X \sim N(0, 1) \implies M_X(t) = \int_{-\infty}^{\infty} e^{tx} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{tx - \frac{x^2}{2}} dx$
 $\implies M_X(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(x-t)^2} e^{\frac{t^2}{2}} dx = e^{\frac{t^2}{2}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(x-t)^2} dx = e^{\frac{t^2}{2}}$

30/04/2024

Ejemplo 4.5. X sigue una distribución de Cauchy $\iff \forall x \in \mathbb{R} : f_X(x) = \frac{1}{\pi} \frac{1}{1+x^2}$.

$\implies M_X(t) = \int_{-\infty}^{\infty} e^{tx} \frac{1}{\pi} \frac{1}{1+x^2} dx$ que solo converge cuando $t = 0$

Es decir, muchas veces M_X genera problemas porque e^{tX} se hace grande.

Por tanto, se define la transformada de Fourier de X como $\hat{f}_X(t) := \int_{-\infty}^{\infty} e^{itx} f_X(x) dx$. En este caso, $\forall t, x \in \mathbb{R} : |e^{itx}| = 1$.

4.6.1 ¿Por qué ese nombre?

Si tenemos en cuenta el desarrollo de Taylor de $e^z = \sum_{n=0}^{\infty} \frac{z^n}{n!}$, entonces

$$\begin{aligned} \forall t \in \mathbb{R} : M_X(t) &= E(e^{tX}) = E\left(1 + tx + \frac{t^2 x^2}{2} + \frac{t^3 x^3}{3!} + \dots\right) \\ &= 1 + tE(X) + \frac{t^2 E(X^2)}{2} + \frac{t^3 E(X^3)}{3!} + \dots = \sum_{n=0}^{\infty} \frac{E(X^n) t^n}{n!} \end{aligned}$$

Es decir, $M_X(t)$ es función generatriz (exponencial) de la sucesión de momentos.

Teorema 4.7. Sea X v.a. con función generatriz de momentos $M_X(t)$.

$M_X(t)$ converge en $|t| < \delta$ para cierto $\delta \implies \forall k \in \mathbb{Z}_{\geq 0} : E(X^k) = M_X^{(k)}(0)$

Ejemplo 4.6. Sea $X \sim N(0, 1) \implies M_X(t) = e^{\frac{t^2}{2}}$.

$$M'_X(t) = te^{\frac{t^2}{2}} \implies M'_X(0) = 0$$

$$M''_X(t) = e^{\frac{t^2}{2}} + t^2 e^{\frac{t^2}{2}} \implies M''_X(0) = 1$$

$$M'''_X(t) = 2te^{\frac{t^2}{2}} + t^3 e^{\frac{t^2}{2}} \implies M'''_X(0) = 0$$

$$M^{(4)}_X(t) = 3e^{\frac{t^2}{2}} + 3t^2 e^{\frac{t^2}{2}} + t^4 e^{\frac{t^2}{2}} \implies M^{(4)}_X(0) = 3$$

4.6.2 La gracia

- Sea X v.a. con función generatriz de momentos $M_X(t)$. Definimos $Y := aX + b$ con $a, b \in \mathbb{R} \implies M_Y(t) = E(e^{tY}) = E(e^{t(aX+b)}) = e^{tb} E(e^{(at)X}) = e^{tb} M_X(at)$.

- Sean X e Y v.a. independientes con funciones generatrices de momentos $M_X(t)$ y $M_Y(t) \implies M_{X+Y}(t) = E(e^{t(X+Y)}) = E(e^{tX} e^{tY}) = E(e^{tX}) E(e^{tY}) = M_X(t) M_Y(t)$.

Si, en su lugar, tenemos X_1, \dots, X_n v.a. independientes con funciones generatrices de momentos $M_{X_i}(t)$, entonces $M_{X_1+\dots+X_n}(t) = M_{X_1}(t) \cdots M_{X_n}(t)$.

4.6.3 El problema de los momentos

Supongamos que para X v.a. tenemos todos sus momentos, ¿podemos recuperar X ?

La respuesta es que no. Por ejemplo, si X sigue una distribución dada por la función de densidad $\forall x > 0 : f_X(x) = \frac{1}{x\sqrt{2\pi}} e^{-\frac{1}{2}\ln^2(x)}$.

Entonces, la familia de variables aleatorias $\{X_a : a \in (-1, 1)\}$ dada por la familia de funciones de densidad $\{f_{X_a}(x) = (1 + a \sin(2\pi \ln x)) f_X(x) : a \in (-1, 1)\}$ tiene los mismos momentos.

Teorema 4.8. (Unicidad) Sea $M_X(t) = E(e^{tX}) < \infty$ para $|t| < \delta$ para cierto $\delta > 0$.

$\implies \exists! X$ v.a. con función generatriz de momentos M_X

En este caso, además, $\forall k \in \mathbb{Z}_{\geq 0} : E(X^k) < \infty$ y $\forall t : |t| < \delta : M_X(t) = \sum_{k=0}^{\infty} \frac{E(X^k) t^k}{k!}$.

Ejemplo 4.7. Sean $X_1 \sim N(\mu_1, \sigma_1^2)$ y $X_2 \sim N(\mu_2, \sigma_2^2)$ v.a. independientes.

$$\implies M_{X_1+X_2}(t) = M_{X_1}(t) M_{X_2}(t) = e^{\mu_1 t + \frac{1}{2}\sigma_1^2 t^2} e^{\mu_2 t + \frac{1}{2}\sigma_2^2 t^2} = e^{(\mu_1 + \mu_2)t + \frac{1}{2}(\sigma_1^2 + \sigma_2^2)t^2}$$

$$\implies X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

Sean $a, b \in \mathbb{R}$, definimos $Z := aX_1 + bX_2$.

$$\begin{aligned} \implies M_Z(t) &= M_{aX_1+bX_2}(t) = M_{X_1}(at)M_{X_2}(bt) = e^{a\mu_1 t + \frac{1}{2}a^2\sigma_1^2 t^2} e^{b\mu_2 t + \frac{1}{2}b^2\sigma_2^2 t^2} \\ &= e^{(a\mu_1+b\mu_2)t + \frac{1}{2}(a^2\sigma_1^2+b^2\sigma_2^2)t^2} \\ \implies Z &\sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2) \end{aligned}$$

06/05/2024

Demostración (del TCL). Sean $(X_n)_{n \in \mathbb{N}}$ v.a. i.i.d. con X de referencia y $E(X) = \mu \wedge V(X) = \sigma^2$.

Suponemos, además, que $M_X(t)$ está bien definida en $|t| < \delta$ para cierto $\delta > 0$. (esto no estaba entre las hipótesis del teorema).

Definimos $(U_n)_{n \in \mathbb{N}}$ como $\forall n \in \mathbb{N} : U_n := X_n - \mu \implies E(U_n) = 0 \wedge V(U_n) = \sigma^2$ y son i.i.d.

Definimos $S_n := \sum_{i=1}^n X_i \implies E(S_n) = n\mu \wedge V(S_n) = n\sigma^2$

$$\implies \tilde{S}_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{1}{\sigma\sqrt{n}} \sum_{i=1}^n U_i \implies E(\tilde{S}_n) = 0 \wedge V(\tilde{S}_n) = 1$$

$$\implies M_{\tilde{S}_n}(t) = E\left(e^{t\tilde{S}_n}\right) = E\left(e^{\frac{t}{\sigma\sqrt{n}} \sum_{i=1}^n U_i}\right) = E\left(e^{\frac{t}{\sigma\sqrt{n}} U_1} \dots e^{\frac{t}{\sigma\sqrt{n}} U_n}\right) = \left(M_U\left(\frac{t}{\sigma\sqrt{n}}\right)\right)^n$$

$$M_U(x) = \sum_{k=0}^{\infty} \frac{E(U^k)}{k!} x^k = 1 + \cancel{E(U)}x + \frac{E(U^2)}{2} x^2 + o(x^2) = 1 + \frac{\sigma^2}{2} x^2 + o(x^2)$$

$$\implies \forall t \in \mathbb{R} : M_{\tilde{S}_n}(t) = \left(1 + \frac{\cancel{\sigma^2}}{2} \frac{t^2}{\cancel{\sigma^2} n} + o\left(\frac{1}{n}\right)\right)^n = \left(1 + \frac{t^2/2}{n} + o\left(\frac{1}{n}\right)\right)^n \xrightarrow{n \rightarrow \infty} e^{\frac{t^2}{2}}$$

Como $e^{\frac{t^2}{2}}$ es la función generatriz de momentos de una $N(0, 1)$, entonces $\tilde{S}_n \xrightarrow{d} N(0, 1)$. ■

Para que la demostración anterior fuese válida, habría que primero haber demostrado el siguiente teorema.

Teorema 4.9. Sean Z_1, Z_2, \dots v.a. con funciones generatrices de momentos $M_{Z_i}(t)$ definidas entorno al origen. Si $\forall t \in \mathbb{R} : \lim_{n \rightarrow \infty} M_{Z_n}(t) = M(t)$, entonces exists Z v.a. con función generatriz de momentos $M(t) : Z_n \xrightarrow{d} Z$

4.7 Función característica

Definición 4.5 (Función característica). Sea X v.a., $\forall t \in \mathbb{R} : \phi_X(t) := E(e^{itX})$.

¿Cómo se calcula? Suponemos que X tiene función de densidad $f_X(x)$.

$$\implies E(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} f_X(x) dx \text{ que es una función de } \mathbb{R} \text{ a } \mathbb{C}$$

Ejemplo 4.8. Sea $X \sim \text{BER}(p)$ con $p \in (0, 1)$.

$$\implies \phi_X(t) = E(e^{itX}) = e^{it \cdot 0}(1-p) + e^{it \cdot 1}p = (1-p) + pe^{it}$$

¿Por qué esto mola?

$$1. \forall t \in \mathbb{R} : |\phi_X(t)| \leq 1.$$

2. Siempre está bien definida.

3. Sean X e Y v.a. independientes con funciones características $\phi_X(t)$ y $\phi_Y(t)$.

$$\implies \phi_{aX+b}(t) = E(e^{it(aX+b)}) = e^{itb} E(e^{iatX}) = e^{itb} \phi_X(at)$$

$$\implies \phi_{X+Y}(t) = E(e^{it(X+Y)}) = E(e^{itX} e^{itY}) = E(e^{itX}) E(e^{itY}) = \phi_X(t) \phi_Y(t)$$

4. (Unicidad) Sean X e Y con funciones características $\phi_X(t)$ y $\phi_Y(t)$.

$$\forall t \in \mathbb{R} : \phi_X(t) = \phi_Y(t) \iff X \text{ e } Y \text{ tienen la misma distribución}$$

5. (Continuidad) Sean $(Z_n)_{n \geq 1}$ v.a. con funciones características $\phi_{Z_n}(t)$.

$$z_n \xrightarrow{d} Z \iff \forall t \in \mathbb{R} : \lim_{n \rightarrow \infty} \phi_{Z_n}(t) = \phi_Z(t)$$

Ejemplo 4.9. • $X \sim \text{EXP}(\lambda) \implies \phi_X(t) = \int_0^{\infty} e^{itx} \lambda e^{-\lambda x} dx = \frac{\lambda}{\lambda - it}$

• $X \sim N(0, 1) \implies \phi_X(t) = \int_{-\infty}^{\infty} e^{itx} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = e^{-\frac{t^2}{2}}$

07/05/2024

$$\phi_X(t) = E(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} f_X(x) dx = \int_{-\infty}^{\infty} \cos(tx) f_X(x) dx + i \int_{-\infty}^{\infty} \sin(tx) f_X(x) dx$$

Teorema 4.10. Sea X v.a. con función generatriz de momentos $M_X(t)$ definida en un entorno del origen $\implies \phi_X(t) = M_X(it)$.

Por ejemplo, $X \sim N(\mu, \sigma^2) \implies \phi_X(t) = e^{i\mu t - \frac{\sigma^2 t^2}{2}}$.

Demostración (del TCL). Sean $(X_n)_{n \in \mathbb{N}}$ v.a. i.i.d. con X de referencia y $E(X) =$

$$\mu \wedge V(X) = \sigma^2.$$

$$\phi_{Z_n}(t) = \phi_{S_n}\left(\frac{t}{n}\right) = \phi_X\left(\frac{t}{n}\right)^n$$

Desarrollando por Taylor tenemos: $\phi_X(w) = 1 + itE(X) + o(w)$.

$$\implies \phi_{Z_n}(t) = \left(1 + \frac{it\mu}{n} + o\left(\frac{1}{n}\right)\right)^n \xrightarrow{n \rightarrow \infty} e^{it\mu}$$

Si X es una v.a. constante ($X = \mu$) $\implies \phi_X(t) = e^{it\mu}$. Por tanto, $Z_n \xrightarrow{d} \mu$.

Ahora, podemos demostrar la ley débil de los grandes números.

Basta ver que $Z_n \xrightarrow{d} \mu \implies Z_n \xrightarrow{P} \mu$ cuando μ es constante (ejs 7 y 9 de la hoja 5).

Definimos $U_n := X_n - \mu \implies E(U_n) = 0 \wedge V(U_n) = \sigma^2$ y son i.i.d. Estudiemos

$$\tilde{S}_n := \frac{\sum_{j=1}^n X_j - n\mu}{\sigma\sqrt{n}} = \frac{1}{\sigma\sqrt{n}} \sum_{j=1}^n U_j \implies \phi_{\tilde{S}_n}(t) = \left(\phi_U\left(\frac{t}{\sigma\sqrt{n}}\right)\right)^n$$

Por Taylor tenemos $\phi_U(w) = 1 + iwE(U) + \frac{(iw)^2}{2!}E(U^2) + o(w^2)$.

$$\implies \phi_{\tilde{S}_n}(t) = \left(1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n \xrightarrow{n \rightarrow \infty} e^{-\frac{t^2}{2}}$$

■

4.7.1 Función característica para distribución de Cauchy: Variable compleja

Sea $X \sim \text{Cauchy} \iff \forall x \in \mathbb{R} : f_X(x) = \frac{1}{\pi} \frac{1}{1+x^2}$. Queremos calcular su función característica.

$$\implies \phi_X(t) = \int_{-\infty}^{\infty} e^{itx} \frac{1}{\pi} \frac{1}{1+x^2} dx = \dots = e^{-|t|}$$

Veamos una técnica de variable compleja para calcular la integral. Consideramos $t > 0$.

Definimos $\forall z \in \mathbb{C} : g(z) := \frac{e^{itz}}{1+z^2}$ con un $t \in \mathbb{R}_{>0}$ fijo. Esta función tiene dos polos en i y $-i$ y hay un teorema en variable compleja que dice que si f es holomorfa en un entorno de un camino cerrado γ y f no tiene polos en el interior de γ , entonces $\int_{\gamma} f(z) dz = 0$.

Si, en su defecto, f tiene un polo en z_0

$$\implies \int_{\gamma} f(z) dz = 2\pi i \text{Res}(f, z_0) \text{ donde } \text{Res}(f, z_0) = \lim_{z \rightarrow z_0} (z - z_0)f(z)$$

Definimos $\Gamma_R \subset \mathbb{C}$ como el camino (orientado) que va de $-R$ a R por la recta real y luego vuelve a $-R$ por la semicircunferencia superior de radio R en \mathbb{C} donde $R \in \mathbb{R}_{>1}$. Podemos separar este camino en dos partes: $\Gamma_R = \Gamma_R^1 \cup \Gamma_R^2$ donde Γ_R^1 es la parte de la recta real y Γ_R^2 es la semicircunferencia superior y se cumple que:

$$\int_{\Gamma_R} g(z) dz = \int_{\Gamma_R^1} g(z) dz + \int_{\Gamma_R^2} g(z) dz = 2\pi i \text{Res}(g, i)$$

Tenemos $\text{Res}(g, i) = \lim_{z \rightarrow i} (z - i) \frac{e^{itz}}{(z + i)(z - i)} = \frac{e^{-t}}{2i} \implies \int_{\Gamma_R} g(z) dz = 2\pi i \frac{e^{-t}}{2i} = \pi e^{-t}$.

Observamos que, claramente, $\lim_{R \rightarrow \infty} \int_{\Gamma_R^1} g(z) dz = \int_{-\infty}^{\infty} e^{itx} \frac{1}{1+x^2} dx = \pi \cdot \phi_X(t)$. Ahora

$$\left| \int_{\Gamma_R^2} g(z) dz \right| \leq \int_{\Gamma_R^2} |g(z)| dz \leq \pi R \max_{z \in \Gamma_R^2} |g(z)| = \pi R \max_{z \in \Gamma_R^2} \left| \frac{e^{itz}}{1+z^2} \right|$$

Como $z \in \Gamma_R^2 \implies |z| = R$, entonces $|e^{itz}| \leq |e^{itRe^{i\theta}}| = |e^{itR \cos \theta} e^{-tR \sin \theta}|$, y como $t > 0$

$$-tR \sin \theta \leq 0 \implies \left| \frac{e^{itz}}{1+z^2} \right| \leq \frac{|e^{itR \cos \theta}|}{|1+z^2|} \leq \frac{1}{|1+z^2|}$$

Ahora, dado que $|1+z^2| \geq |z^2| - 1 = R^2 - 1$, tenemos $\left| \frac{e^{itz}}{1+z^2} \right| \leq \frac{1}{R^2 - 1}$.

$$\implies \left| \int_{\Gamma_R^2} g(z) dz \right| \leq \pi R \max_{z \in \Gamma_R^2} \left| \frac{e^{itz}}{1+z^2} \right| \leq \frac{\pi R}{R^2 - 1} \implies \lim_{R \rightarrow \infty} \int_{\Gamma_R^2} g(z) dz = 0$$

Concluimos que para todo t positivo, $\phi_X(t) = e^{-t}$:

$$\pi e^{-t} = \lim_{R \rightarrow \infty} \int_{\Gamma_R} g(z) dz = \lim_{R \rightarrow \infty} \left[\int_{\Gamma_R^1} g(z) dz + \int_{\Gamma_R^2} g(z) dz \right] = \pi \phi_X(t) + 0 \implies \phi_X(t) = e^{-t}$$

Para $t < 0$ se puede hacer un razonamiento análogo con un Γ que vaya por la semicircunferencia inferior y luego vuelva por la recta real. Finalmente llegamos a

$$\forall t > 0 : \phi(t) = e^{-t} \quad \wedge \quad \forall t < 0 : \phi(t) = e^t \implies \boxed{\forall t \in \mathbb{R} : \phi(t) = e^{-|t|}}$$

Como además, tenemos $\phi(t) = \int_{-\infty}^{\infty} e^{itx} \frac{1}{\pi} \frac{1}{1+x^2} dx = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{\cos(tx)}{1+x^2} dx + i \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{\sin(tx)}{1+x^2} dx$

$$\implies \int_{-\infty}^{\infty} \frac{\cos(tx)}{1+x^2} dx = \pi e^{-|t|} \quad \wedge \quad \int_{-\infty}^{\infty} \frac{\sin(tx)}{1+x^2} dx = 0$$

5 Ejercicios

5.1 Hoja 1

5.2 Hoja 2

7. b $X \sim \text{GEOM}(p) \iff P(X > n+m | X > m) = P(X > n)$

Solución: Lo que nos está diciendo la caracterización es que una distribución geométrica no tiene memoria, la probabilidad de no tener éxito en los próximos n intentos no depende de los intentos anteriores.

Demostración. (\implies) Suponemos que $X \sim \text{GEOM}(p)$

$$\implies P(X > n+m | X > m) = \frac{P(X > n+m \wedge X > m)}{P(X > m)} = \frac{P(X > n+m)}{P(X > m)}$$

Como $P(X > m) = (1-p)^m$ (por eso se llama geométrica), obtenemos

$$\boxed{P(X > n+m | X > m) = \frac{(1-p)^{n+m}}{(1-p)^m} = (1-p)^n = \boxed{P(X > n)}}$$

(\impliedby) Suponemos que $P(X > n+m | X > m) = P(X > n)$

$$\implies \frac{P(X > n+m \wedge X > m)}{P(X > m)} = \frac{P(X > n)}{P(X > m)}$$

$$\implies P(X > n+m \wedge X > m) = P(X > n) \cdot P(X > m)$$

■

12. Sea X una v.a.d, $X \sim \text{BINNEG}(n, p) \iff P(X = k) = \binom{k-1}{n-1} p^n (1-p)^{k-n}$.

Esto significa que X es la suma de n v.a.d. independientes, con distribución $\text{GEOM}(p)$.

Comprobemos que $\sum_{k=n}^{\infty} \binom{k-1}{n-1} p^n (1-p)^{k-n} = 1$

$$\sum_{k=n}^{\infty} \binom{k-1}{n-1} p^n (1-p)^{k-n} = \sum_{l=0}^{\infty} \binom{l+n-1}{n-1} p^n (1-p)^l = p^n \sum_{l=0}^{\infty} \binom{l+n-1}{n-1} (1-p)^l$$

Como sabemos que $\frac{1}{(1-x)^{m+1}} = \sum_{l=0}^{\infty} \binom{l+m}{m} x^l$, podemos tomar $x = 1-p$ y $m = n-1$:

$$\implies \sum_{k=n}^{\infty} P(X = k) = \frac{p^n}{(1-(1-p))^{n-1+1}} = \frac{p^n}{p^n} = \boxed{1}$$

20. Cada día compramos 1 cromo de n totales que hay, con reposición. ¿Cuántos días esperamos hasta tener todos los cromos?

Solución: Sea T una v.a.d. igual a la cantidad de días hasta que terminamos la colección, queremos calcular $E(T)$. Se puede utilizar el modelo de distribución geométrica.

Si definimos T_i como la cantidad de días que esperamos hasta tener el cromo i -ésimo nuevo

sabiendo que tienes los $i - 1$ anteriores, entonces:

$$\begin{aligned} \implies T_1 = 1 \wedge T_2 &\sim \text{GEOM} \left(\frac{n-1}{n} \right) \wedge T_3 \sim \text{GEOM} \left(\frac{n-2}{n} \right) \wedge \dots \\ \implies \forall i \in \mathbb{N}_n : T_i &\sim \text{GEOM} \left(1 - \frac{i-1}{n} \right) \implies E(T_i) = \frac{n}{n-i} \end{aligned}$$

Además, $T = T_1 + T_2 + \dots + T_n$. Por linealidad de la esperanza:

$$\begin{aligned} E(T) &= \sum_{i=1}^n E(T_i) = \sum_{i=0}^{n-1} \frac{n}{n-i} = n \sum_{i=0}^{n-1} \frac{1}{n-i} = n \sum_{k=1}^n \frac{1}{k} = nH_n \sim \ln n - \gamma + O\left(\frac{1}{n}\right) \\ \implies E(T) &= nH_n \approx n \ln n \end{aligned}$$

5.3 Hoja 3

8. Sea $X \sim N(0, 1)$. Definimos $Y := e^X$. $\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ es la función de densidad de X .

Queremos calcular $E(Y)$ y $V(Y)$.

$$\begin{aligned} \implies E(Y) &= E(e^X) = \int_{-\infty}^{\infty} e^x \phi(x) dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{x-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{x^2-2x+1}{2}+1} dx \\ &= e^{\frac{1}{2}} \left(\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{(x-1)^2}{2}} dx \right) \xrightarrow{\text{cambio de variable}} e^{\frac{1}{2}} \\ \implies V(Y) &= E(Y^2) - E(Y)^2 = E(e^{2X}) - e = e^2 - e = e(e-1) \end{aligned}$$

Si $X \sim N(\mu, \sigma^2)$ en su lugar y $Z \sim N(0, 1)$

$$\begin{aligned} \implies E(e^X) &= E(e^{\mu+\sigma Z}) = e^\mu E(e^{\sigma Z}) = e^{\mu+\frac{\sigma^2}{2}} \\ \implies V(e^X) &= E(e^{2X}) - E(e^X)^2 = e^{2\mu+2\sigma^2} - e^{2\mu+\sigma^2} = e^{2\mu+\sigma^2} (e^{\sigma^2} - 1) \end{aligned}$$

11. Sea X una v.a. con función de distribución F_X no decreciente con inversa. Definimos $Y := F_X(X)$. Queremos ver que $Y \sim \text{UNIF}([0, 1])$.

$$\forall y \in (0, 1) : P(Y \leq y) = P(F_X(X) \leq y) = P(X \leq F_X^{-1}(y)) = F_X(F_X^{-1}(y)) = y$$

12. Sea F una función de distribución y $U \sim \text{UNIF}([0, 1])$. Definimos $X := F^{-1}(U)$ y queremos ver que $X \sim F$.

$$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$$

Lo que nos dice este resultado es que cualquier variable aleatoria es una transformación de una variable aleatoria uniforme (Método de inversión).

13. Sea $X \sim N(0, 1)$.

$$\implies \text{a) } \Phi(1.25) \wedge \text{b) } 1 - \Phi(-0.4) = \Phi(0.4) \wedge \text{c) } 2\Phi(1.35) - 1$$

14. Sea $X \sim N(\mu, \sigma^2)$ con $\mu = 100 \wedge \sigma = 15$. Si definimos $Z \sim N(0, 1)$:

$$P(X > 120) = P(\mu + \sigma Z > 120) = P\left(Z > \frac{120 - 100}{15}\right) = P\left(Z > \frac{4}{3}\right) = 1 - \Phi\left(\frac{4}{3}\right)$$

15. Sea $X \sim N(0, 1)$. Queremos a tal que $P(|X| > a) = 0.95$.

$$P(|X| > a) = 2P(X > a) = 2\Phi(a) - 1 = 0.95 \iff \Phi(a) = 0.975 \iff a = \Phi^{-1}(0.975)$$

Si $X \sim N(\mu, \sigma^2)$ en su lugar:

$$\begin{aligned} P(|X| > a) &= P(-a < X < a) = P(-a < \mu + \sigma Z < a) \\ &= P\left(-\frac{a + \mu}{\sigma} < Z < \frac{a - \mu}{\sigma}\right) = \Phi\left(\frac{a - \mu}{\sigma}\right) - \Phi\left(-\frac{a + \mu}{\sigma}\right) = 0.95 \end{aligned}$$

19. Sea $T \sim \text{lognormal}(\mu, \sigma^2)$ una variable aleatoria que mide la longitud de una conferencia (en minutos).

$$\begin{aligned} \begin{cases} 0.60 = P(T > 40) = P(e^{\mu + \sigma Z} > 40) = P\left(Z > \frac{\ln 40 - \mu}{\sigma}\right) = 1 - \Phi\left(\frac{\ln 40 - \mu}{\sigma}\right) \\ 0.55 = P(T > 50) = P(e^{\mu + \sigma Z} > 50) = P\left(Z > \frac{\ln 50 - \mu}{\sigma}\right) = 1 - \Phi\left(\frac{\ln 50 - \mu}{\sigma}\right) \end{cases} \\ \implies \begin{cases} \frac{\ln 40 - \mu}{\sigma} = \Phi^{-1}(0.40) \implies \mu = \ln 40 - \Phi^{-1}(0.40)\sigma \\ \frac{\ln 50 - \mu}{\sigma} = \Phi^{-1}(0.45) \implies \mu = \ln 50 - \Phi^{-1}(0.45)\sigma \end{cases} \\ \implies \sigma = \frac{\ln 50 - \ln 40}{\Phi^{-1}(0.45) - \Phi^{-1}(0.40)} \end{aligned}$$

5.4 Hoja 4

4. Sean X, Y dos variables aleatorias independientes idénticas ($f := f_X \equiv f_Y$).

Definimos $M := \max X, Y \wedge m := \min X, Y$.

$$\begin{aligned} F_m(z) &= P(\min X, Y \leq z) = 1 - P(\min X, Y > z) = 1 - P(X > z \wedge Y > z) \\ &= 1 - P(X > z) \cdot P(Y > z) = 1 - P(X > z)^2 = 1 - (1 - F(z))^2 \\ \implies f_M(z) &= \frac{d}{dz} F_M(z) = 2(1 - F(z))f(z) \end{aligned}$$

Análogamente $F_m(z) = F(z)^2 \implies f_m(z) = 2F(z)f(z)$

Si ahora tenemos X_1, \dots, X_n independientes con F_i, f_i , $M := \max\{X_1, \dots, X_n\}$
 $m := \min\{X_1, \dots, X_n\}$:

$$\implies F_m(z) = 1 - \prod_{i=1}^n (1 - F_i(z)) \wedge F_M(z) = \prod_{i=1}^n F_i(z)$$

6. Sean $X, Y \sim \text{EXP}(\lambda)$ independientes $\implies P(\max\{X, Y\} \leq aX) = \begin{cases} 0 & \text{si } a \leq 1 \\ \frac{a}{1+a} & \text{si } a > 1 \end{cases}$

Demostración.

$$\implies \forall x, y > 0 : f_{X,Y}(x, y) = \lambda^2 e^{-\lambda x} e^{-\lambda y}$$

■

7. Sean X, Y con función de densidad conjunta $f_{X,Y}$ y $Z := \frac{Y}{X}$

$$\implies f_Z(z) = \int_{-\infty}^{\infty} |x| f_{X,Y}(x, z-x) dx$$

Demostración.

$$F_Z(z) = P(Z \leq z) = P\left(\frac{Y}{X} \leq z\right) = \begin{cases} P(Y \leq zX) & \text{si } X > 0 \\ P(Y \geq zX) & \text{si } X < 0 \end{cases}$$


■

8. Sean X e Y dos v.a. indep. con $f_X = xe^{-\frac{x^2}{2}} \cdot \mathbb{1}_{\{x>0\}}(x)$ e $Y \sim \text{UNIF}([- \varepsilon, \varepsilon])$

$$\implies f_Y(y) = \frac{1}{2\varepsilon} \cdot \mathbb{1}_{\{-\varepsilon < y < \varepsilon\}}(y). \text{ Definimos } Z := X + Y.$$

Nota: En un escenario de la vida real, Y representa un error.

$$\begin{aligned} \forall z \geq -\varepsilon : f_Z(z) &= \int_{-\infty}^{\infty} f_X(u) f_Y(z-u) du = \int_{-\infty}^{\infty} ue^{-\frac{u^2}{2}} \cdot \mathbb{1}_{\{u>0\}}(u) \cdot \frac{1}{2\varepsilon} \cdot \mathbb{1}_{\{-\varepsilon < z-u < \varepsilon\}}(u) du \\ &= \begin{cases} \frac{1}{2\varepsilon} \int_{-\infty}^{\infty} ue^{-\frac{u^2}{2}} \cdot \mathbb{1}_{\{0 < u < z+\varepsilon\}}(u) du & z < \varepsilon \\ \frac{1}{2\varepsilon} \int_{-\infty}^{\infty} ue^{-\frac{u^2}{2}} \cdot \mathbb{1}_{\{z-\varepsilon < u < z+\varepsilon\}}(u) du & z \geq \varepsilon \end{cases} = \begin{cases} \frac{1}{2\varepsilon} \int_0^{z+\varepsilon} ue^{-\frac{u^2}{2}} du & z < \varepsilon \\ \frac{1}{2\varepsilon} \int_{z-\varepsilon}^{z+\varepsilon} ue^{-\frac{u^2}{2}} du & z \geq \varepsilon \end{cases} \\ \implies \forall z \geq -\varepsilon : f_Z(z) &= \begin{cases} \frac{1}{2\varepsilon} \left[-e^{-\frac{u^2}{2}} \right]_0^{z+\varepsilon} & z < \varepsilon \\ \frac{1}{2\varepsilon} \left[-e^{-\frac{u^2}{2}} \right]_{z-\varepsilon}^{z+\varepsilon} & z \geq \varepsilon \end{cases} = \begin{cases} \frac{1}{2\varepsilon} \left(1 - e^{-\frac{(z+\varepsilon)^2}{2}} \right) & z < \varepsilon \\ \frac{1}{2\varepsilon} \left(e^{-\frac{(z-\varepsilon)^2}{2}} - e^{-\frac{(z+\varepsilon)^2}{2}} \right) & z \geq \varepsilon \end{cases} \end{aligned}$$



5.5 Hoja 5

17. Sea $(X_n)_{n \in \mathbb{N}}$ una sucesión de v.a. independientes con $E(X_i) = m_i \wedge V(X_i) = \sigma_i^2 < R \in \mathbb{R}$. Definimos $M_n = \frac{1}{n} \sum_{i=1}^n M_i$ y queremos ver que

$$P \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - M_n \right| < \varepsilon \right) \xrightarrow{n \rightarrow \infty} 1$$

Por la desigualdad de Chebyshev:

$$P \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - M_n \right| > \varepsilon \right) \leq \frac{V \left(\frac{1}{n} \sum_{i=1}^n X_i \right)}{\varepsilon^2} = \frac{\frac{1}{n^2} \sum_{j=1}^n \sigma_j^2}{\varepsilon^2} \leq \frac{R}{n^2 \varepsilon^2} = \frac{R}{n \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

9. Sean $(Z_n)_{n \in \mathbb{N}}$ una sucesión de v.a. y quiero probar que $Z_n \xrightarrow[n \rightarrow \infty]{\text{cuad}} Z \implies Z_n \xrightarrow[n \rightarrow \infty]{P} Z$.

Demostración. Por la desigualdad de Markov:

$$P(|Z_n - Z| > \varepsilon) = P(|Z_n - Z|^2 > \varepsilon^2) \leq \frac{E(|Z_n - Z|^2)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

■

Ahora queremos demostrar que $Z_n \xrightarrow[n \rightarrow \infty]{P} Z \implies Z_n \xrightarrow[n \rightarrow \infty]{d} Z$.

Demostración. Sea $t \in \mathbb{R}$ un punto de continuidad de F_Z :

$$\begin{aligned} \forall \varepsilon > 0 : P(Z_n \leq t) &= P(Z_n \leq t \wedge Z \leq t + \varepsilon) + P(Z_n \leq t \wedge Z > t + \varepsilon) \\ &\leq P(Z \leq t + \varepsilon) + P(|Z_n - Z| > \varepsilon) \end{aligned}$$

Porque F_Z es continua en t . Análogamente:

$$\begin{aligned} \forall \varepsilon > 0 : P(Z \leq t - \varepsilon) &= P(Z \leq t - \varepsilon \wedge Z_n \leq t) + P(Z \leq t - \varepsilon \wedge Z_n > t) \\ &\leq P(Z_n \leq t) + P(|Z_n - Z| > \varepsilon) \end{aligned}$$

Para todo $t \in \mathbb{R}$ punto de continuidad de F_Z y para todo $\varepsilon > 0$:

$$\begin{aligned} P(Z \leq t - \varepsilon) + P(|Z_n - Z| > \varepsilon) &\leq P(Z_n \leq t) \leq P(Z \leq t + \varepsilon) + P(|Z_n - Z| > \varepsilon) \\ \implies F_Z(t - \varepsilon) &= P(Z \leq t - \varepsilon) \leq \lim_{n \rightarrow \infty} P(Z_n \leq t) \leq P(Z \leq t + \varepsilon) = F_Z(t + \varepsilon) \end{aligned}$$

$$\implies \lim_{n \rightarrow \infty} F_{Z_n}(t) = F_Z(t) \implies Z_n \xrightarrow[n \rightarrow \infty]{d} Z \text{ porque } F_Z \text{ es continua en } t$$

■

11. Sean $(X_n)_{n \in \mathbb{N}}, (Y_n)_{n \in \mathbb{N}}$ dos sucesiones de v.a. tales que $X_n \xrightarrow[n \rightarrow \infty]{\text{cuad}} X \wedge Y_n \xrightarrow[n \rightarrow \infty]{\text{cuad}} Y$.

Queremos ver que $X_n + Y_n \xrightarrow[n \rightarrow \infty]{\text{cuad}} X + Y$.

Demostración.

$$E(|X_n + Y_n - X - Y|^2) = E(|X_n - X|^2) + E(|Y_n - Y|^2) + 2E((X_n - X)(Y_n - Y))$$

Ahora, por Cauchy-Schwarz:

$$2E((X_n - X)(Y_n - Y)) \leq \sqrt{E(|X_n - X|^2) E(|Y_n - Y|^2)}$$

■

Ahora queremos demostrar que $X_n \xrightarrow[n \rightarrow \infty]{P} X \wedge Y_n \xrightarrow[n \rightarrow \infty]{P} Y \implies X_n + Y_n \xrightarrow[n \rightarrow \infty]{P} X + Y$.

Demostración.

$$\begin{aligned} \forall \varepsilon > 0 : P(|X_n + Y_n - X - Y| > \varepsilon) &= P(|X_n - X + Y_n - Y| > \varepsilon) \\ &\leq P(\{|X_n - X| > \varepsilon/2\} \cup \{|Y_n - Y| > \varepsilon/2\}) \\ &\leq P(|X_n - X| > \varepsilon/2) + P(|Y_n - Y| > \varepsilon/2) \end{aligned}$$

Como $X_n \xrightarrow[n \rightarrow \infty]{P} X \wedge Y_n \xrightarrow[n \rightarrow \infty]{P} Y$:

■